

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



Báo cáo đề tài
Xây dựng hệ thống pipeline dữ liệu chứng khoán phục vụ
phân tích và trực quan hóa

Học phần	: Hệ quản trị cơ sở dữ liệu
Giảng viên hướng dẫn	: Trần Quốc Khánh
Nhóm học phần	: Nhóm 01
Thành viên nhóm 6	: Đỗ Văn Tân - B23DCKH102 : Vũ Minh Phước - B23DCKH091 : Hoàng Minh Sơn - B23DCKH100 : Nguyễn Đức Sinh - B23DCKH098 : Nguyễn Quốc Triệu - B23DCKH120

Hà Nội – 2026

MỤC LỤC

PHÂN CÔNG CÔNG VIỆC VÀ ĐÁNH GIÁ.....	7
1. Phần làm chung.....	7
2. Phần làm cá nhân.....	7
3. Link dự án.....	8
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI.....	9
1.1 Giới thiệu bối cảnh và lý do chọn đề tài.....	9
1.1.1 Bối cảnh.....	9
1.1.2 Lý do chọn đề tài.....	9
1.2 Mục tiêu đề tài.....	10
1.2.1 Mục tiêu tổng quát.....	10
1.2.2 Mục tiêu cụ thể.....	10
1.3 Phạm vi đề tài.....	10
1.3.1 Phạm vi dữ liệu.....	10
1.3.2 Phạm vi hệ thống.....	11
1.3.3 Phạm vi dự đoán.....	11
1.4 Đối tượng nghiên cứu.....	11
1.5 Phương pháp thực hiện.....	11
1.6 Ý nghĩa thực tiễn.....	12
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG.....	13
2.1 Tổng quan về dữ liệu chứng khoán.....	13
2.1.1 Khái niệm dữ liệu chứng khoán.....	13
2.1.2 Các thuộc tính cơ bản của dữ liệu chứng khoán.....	13
2.1.3 Đặc điểm của dữ liệu chứng khoán.....	13
2.2 Tổng quan về Data Pipeline.....	14
2.2.1 Khái niệm Data Pipeline.....	14
2.2.2 Các thành phần của Data Pipeline.....	14
2.2.3 Vai trò của Data Pipeline trong đề tài.....	14
2.3 ETL và ELT.....	15
2.3.1 Khái niệm ETL.....	15
2.3.2 Khái niệm ELT.....	15
2.3.3 Mô hình được sử dụng trong đề tài.....	15
2.4 Data Warehouse.....	16
2.4.1 Khái niệm Data Warehouse.....	16
2.4.2 Kiến trúc Data Warehouse.....	16
2.4.3 Staging Area.....	16
2.4.4 Data Warehouse trong hệ thống.....	16
2.5 Data Mart.....	17
2.5.1 Khái niệm Data Mart.....	17

2.5.2	Vai trò Data Mart trong đề tài.....	17
2.5.3	Các Data Mart sử dụng.....	17
2.6	Feature Engineering.....	17
2.6.1	Khái niệm.....	17
2.6.2	Các Feature sử dụng trong đề tài.....	17
2.6.3	Feature Store.....	17
2.7	Các mô hình học máy sử dụng.....	18
2.7.1	XGBoost.....	18
2.7.2	LightGBM.....	18
2.8	ClickHouse.....	18
2.8.1	Giới thiệu ClickHouse.....	18
2.8.2	Đặc điểm của ClickHouse.....	18
2.8.3	Lý do lựa chọn ClickHouse.....	18
2.9	Công nghệ sử dụng.....	20
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG.....		21
3.1	Phân tích yêu cầu nghiệp vụ.....	21
3.1.1	Bài toán thực tế.....	21
3.1.2	Yêu cầu phi chức năng.....	21
3.1.3	Yêu cầu phi chức năng.....	22
3.2	Phân tích nguồn dữ liệu.....	22
3.2.1	Nguồn dữ liệu.....	22
3.2.2	Phạm vi dữ liệu.....	22
3.2.3	Cấu trúc dữ liệu.....	22
3.2.4	Đặc điểm dữ liệu.....	23
3.3	Thiết kế kiến trúc tổng thể hệ thống.....	23
3.3.1	Kiến trúc tổng thể.....	23
3.3.2	Mô tả các tầng.....	24
3.4	Thiết kế ETL Pipeline.....	24
3.4.1	Luồng ETL.....	24
3.4.2	Giai đoạn Extract.....	25
3.4.3	Giai đoạn Transform.....	26
3.4.4	Giai đoạn Load.....	27
3.5	Thiết kế Data Warehouse.....	28
3.5.1	Mục tiêu thiết kế Data Warehouse.....	28
3.5.2	Lựa chọn ClickHouse làm Data Warehouse.....	29
3.6	Thiết kế Feature Store.....	29
3.6.1	Mục tiêu.....	29
3.6.2	Feature Engineering.....	29
3.7	Thiết kế tầng Machine Learning - Data Mart tương ứng.....	30
3.7.1	Model 1 – Price Forecasting.....	30

3.7.2 Model 2 – Future Return Prediction.....	34
3.7.3 Model 3 – Trading Signal Classification.....	37
3.7.4 Model 4 – Benchmark Outperformance.....	40
3.7.5 Model 5 – Risk Alert.....	45
CHƯƠNG 4: XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG.....	48
4.1 Xây dựng quy trình thu thập dữ liệu.....	48
4.1.1 Mục tiêu thu thập dữ liệu.....	48
4.1.2 Xây dựng module thu thập dữ liệu.....	48
4.1.3 Tự động hóa thu thập dữ liệu.....	48
4.2 Xây dựng quy trình xử lý dữ liệu.....	48
4.2.1 Merge dữ liệu hằng ngày.....	49
4.2.2 Khảo sát chất lượng dữ liệu.....	49
4.2.3 Làm sạch dữ liệu.....	50
4.3 Xây dựng Data Warehouse trên ClickHouse.....	53
4.3.1 Kết nối với ClickHouse bằng Python.....	53
4.3.2 Xây dựng bảng stock_prices.....	55
4.3.3 Xây dựng bảng stock_symbols.....	56
4.3.4 Xây dựng bảng features_all.....	59
4.4 Xây dựng các mô hình dự báo - Data Mart và Insight.....	61
4.4.1 Model 1 - Price Forecasting.....	61
4.4.2 Model 2 - Future Return Prediction.....	66
4.4.3 Model 3 - Trading Signal Classification.....	70
4.4.4 Model 4 - Benchmark Outperformance.....	74
4.4.5 Model 5 - Risk Alert.....	79
4.5 Tự động hóa Pipeline.....	85
CHƯƠNG 5: TRỰC QUAN HÓA DỮ LIỆU HỆ THỐNG.....	86
5.1 Mục tiêu trực quan hóa dữ liệu.....	86
5.1.1 Vai trò của trực quan hóa dữ liệu.....	86
5.1.2 Mục tiêu của Dashboard.....	86
5.2 Kiến trúc Dashboard.....	86
5.2.1 Kiến trúc tổng thể.....	86
5.2.2 Luồng dữ liệu Dashboard.....	89
5.3. Các chức năng chính của Dashboard.....	91
5.3.1. Tổng quan dashboard.....	91
5.3.2. Tra Cứu Dữ Liệu Cổ Phiếu.....	91
5.3.3. Feature Engineering.....	92
5.3.4. Data Mart.....	92
CHƯƠNG 6: ĐÁNH GIÁ KẾT QUẢ, ĐỀ XUẤT QUYẾT ĐỊNH.....	95
6.1 Đánh giá chất lượng dữ liệu.....	95
6.1.1 Đánh giá dữ liệu trước khi làm sạch.....	95

6.1.2 Kết quả sau khi làm sạch.....	97
6.2 Đánh giá Data Warehouse.....	98
6.2.1 Đánh giá khả năng lưu trữ.....	98
6.2.2 Đánh giá khả năng truy vấn.....	99
CHƯƠNG 7: HẠN CHẾ, HƯỚNG CẢI TIẾN VÀ KẾT LUẬN.....	100
7.1. Hạn chế.....	100
7.2. Hướng cải tiến.....	101
7.3. Kết luận.....	102
TÀI LIỆU THAM KHẢO.....	103

Lời cảm ơn

Trong suốt quá trình thực hiện đề tài **“Xây dựng hệ thống pipeline dữ liệu chứng khoán phục vụ phân tích và trực quan hóa”**, nhóm chúng em đã nhận được rất nhiều sự quan tâm, hướng dẫn và hỗ trợ quý báu từ phía nhà trường, giảng viên và các bạn trong nhóm.

Trước hết, nhóm xin gửi lời cảm ơn chân thành và sâu sắc đến **Thầy Trần Quốc Khánh**, giảng viên phụ trách học phần **Hệ quản trị cơ sở dữ liệu**, người đã tận tình hướng dẫn, định hướng và hỗ trợ nhóm trong suốt quá trình thực hiện đề tài. Những kiến thức chuyên môn, các ý kiến đóng góp và những kinh nghiệm thực tiễn mà thầy chia sẻ đã giúp nhóm có cái nhìn toàn diện hơn về việc xây dựng hệ thống dữ liệu, thiết kế kho dữ liệu cũng như triển khai các giải pháp phân tích và trực quan hóa dữ liệu trong thực tế.

Nhóm cũng xin chân thành cảm ơn quý thầy cô của **Khoa Công nghệ Thông tin I – Học viện Công nghệ Bưu chính Viễn thông** đã truyền đạt những kiến thức nền tảng và chuyên sâu trong suốt quá trình học tập. Đây chính là cơ sở quan trọng giúp nhóm vận dụng vào quá trình nghiên cứu và triển khai đề tài.

Bên cạnh đó, nhóm xin cảm ơn các thành viên trong nhóm đã luôn đoàn kết, hỗ trợ lẫn nhau trong quá trình tìm hiểu công nghệ, xây dựng hệ thống, xử lý dữ liệu và hoàn thiện báo cáo. Sự phối hợp và tinh thần làm việc nghiêm túc của các thành viên là yếu tố quan trọng giúp đề tài được hoàn thành đúng tiến độ.

Mặc dù đã nỗ lực nghiên cứu và thực hiện, do hạn chế về thời gian, kinh nghiệm thực tế cũng như phạm vi của đề tài, báo cáo khó tránh khỏi những thiếu sót nhất định. Nhóm rất mong nhận được những ý kiến nhận xét và góp ý từ quý thầy cô để có thể hoàn thiện hơn trong các nghiên cứu và dự án tiếp theo.

Nhóm xin chân thành cảm ơn!

PHÂN CÔNG CÔNG VIỆC VÀ ĐÁNH GIÁ

1. Phần làm chung

Trước khi tiến hành thiết kế và triển khai hệ thống, nhóm đã thực hiện quá trình phân tích tổng thể bài toán, từ việc khảo sát yêu cầu nghiệp vụ đến nghiên cứu chi tiết các thành phần chức năng của hệ thống. Nhóm đã tìm hiểu các khái niệm nền tảng, các thuật ngữ chuyên ngành liên quan đến lĩnh vực dữ liệu, kho dữ liệu và phân tích chứng khoán, đồng thời nghiên cứu quy trình khai thác, xử lý và sử dụng dữ liệu trong thực tế.

Trên cơ sở đó, nhóm tiến hành xác định các đặc điểm nghiệp vụ cốt lõi, phân tích nhu cầu của người sử dụng, từ đó xây dựng các chức năng và module phù hợp với mục tiêu của hệ thống. Bên cạnh đó, nhóm cũng thiết kế các luồng dữ liệu, kịch bản xử lý dữ liệu và quy trình vận hành nhằm đảm bảo dữ liệu được thu thập, xử lý, lưu trữ và khai thác một cách hiệu quả.

Ngoài ra, phạm vi nghiên cứu, mục tiêu và các yêu cầu của hệ thống cũng được xác định rõ ràng ngay từ giai đoạn đầu. Điều này giúp đảm bảo tính khả thi của đề tài, đồng thời tạo nền tảng cho quá trình thiết kế kiến trúc, xây dựng Data Warehouse, triển khai các mô hình phân tích và phát triển hệ thống trực quan hóa dữ liệu ở các giai đoạn tiếp theo.

2. Phần làm cá nhân

Thành viên nhóm 6	Nội dung thực hiện	Đánh giá	Ký tên
Đỗ Văn Tân	- Thư ký ghi chép lịch sử cuộc họp - Triển khai giao diện web - Thiết kế, phân tích và xây dựng model 4 - Thiết kế dashboard Power BI cho model4	9	
Vũ Minh Phước	- Làm silde - Triển khai giao diện web - Thiết kế dashboard Power BI cho model3 - Thiết kế, phân tích và xây dựng model 3	9	
Hoàng Minh Sơn	- Thiết kế nội dung và triển khai giao diện web - Lên ý tưởng và thiết kế chatbot - Thiết kế dashboard Power BI cho model1 - Thiết kế, phân tích và xây dựng model 1	9	

Nguyễn Đức Sinh (nhóm trưởng)	- Đặt deadline, phân công công việc, định hướng dự án - Làm sạch dữ liệu, tổ chức triển khai và lưu trữ dữ liệu - Thiết kế thông báo Telegram tới quản trị viên để quản lý luồng hoạt động - Thiết kế, triển khai các bảng dữ liệu đầu vào cho các mô hình - Nghiên cứu, lựa chọn hệ quản trị cơ sở dữ liệu, thiết kế các mart data, data warehouse cho dự án - Load, transform dữ liệu, hàng ngày - Triển khai giao diện web - Hướng cải thiện dự án - Thiết kế, phân tích và xây dựng model 5 - Thiết kế dashboard Power BI cho model 1	10	
Nguyễn Quốc Triệu	- Thuyết trình - Xây dựng sườn báo cáo - Extract - Thu thập, tìm kiếm và lưu trữ dữ liệu ban đầu, tạo dữ liệu bản - Thiết kế nội dung web - Thiết kế Features phục vụ cho các mô hình sử dụng để huấn luyện - Thiết kế, phân tích và xây dựng model 2	9.5	

3. Link dự án

Link github: [HQTCSL - stocks](#)

Mã QR:



CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1 Giới thiệu bối cảnh và lý do chọn đề tài

1.1.1 Bối cảnh

Trong những năm gần đây, thị trường chứng khoán Việt Nam đã có sự phát triển mạnh mẽ cả về quy mô giao dịch lẫn số lượng nhà đầu tư tham gia. Khối lượng dữ liệu phát sinh từ hoạt động giao dịch chứng khoán ngày càng lớn, bao gồm dữ liệu giá cổ phiếu, khối lượng giao dịch, thông tin doanh nghiệp và các chỉ số thị trường. Việc khai thác hiệu quả nguồn dữ liệu này có ý nghĩa quan trọng trong việc hỗ trợ phân tích xu hướng thị trường, đánh giá hiệu quả đầu tư và hỗ trợ ra quyết định.

Tuy nhiên, dữ liệu chứng khoán thường được phân tán ở nhiều nguồn khác nhau, có khối lượng lớn và liên tục được cập nhật theo thời gian. Trong thực tế, việc thu thập, lưu trữ, làm sạch, xử lý và khai thác dữ liệu vẫn còn gặp nhiều khó khăn nếu thực hiện thủ công. Bên cạnh đó, nhu cầu trực quan hóa dữ liệu và ứng dụng các mô hình học máy để hỗ trợ dự báo ngày càng trở nên phổ biến.

Xuất phát từ thực tế đó, việc xây dựng một hệ thống pipeline dữ liệu chứng khoán hoàn chỉnh, có khả năng tự động thu thập dữ liệu, làm sạch, lưu trữ tập trung, xây dựng kho dữ liệu và hỗ trợ phân tích trực quan là một yêu cầu cần thiết. Hệ thống không chỉ giúp quản lý dữ liệu hiệu quả mà còn tạo nền tảng cho việc ứng dụng các mô hình dự báo và khai thác dữ liệu trong tương lai.

1.1.2 Lý do chọn đề tài

Hiện nay, dữ liệu chứng khoán là một trong những nguồn dữ liệu có giá trị cao trong lĩnh vực tài chính và đầu tư. Tuy nhiên, phần lớn các nhà đầu tư cá nhân vẫn phải sử dụng nhiều công cụ khác nhau để theo dõi và phân tích dữ liệu, dẫn đến khó khăn trong việc tổng hợp thông tin và đưa ra quyết định.

Bên cạnh đó, các doanh nghiệp và tổ chức tài chính ngày càng có xu hướng xây dựng các hệ thống Data Warehouse, Data Mart và Business Intelligence nhằm khai thác dữ liệu hiệu quả hơn. Điều này cho thấy việc nghiên cứu và xây dựng một hệ thống quản lý dữ liệu chứng khoán theo hướng hiện đại là cần thiết và có tính ứng dụng thực tiễn cao.

Ngoài ra, đề tài còn giúp nhóm vận dụng các kiến thức đã học trong môn Hệ quản trị cơ sở dữ liệu như:

- Thiết kế cơ sở dữ liệu.
- Xây dựng quy trình ETL.
- Thiết kế Data Warehouse.

- Thiết kế Data Mart.
- Quản lý dữ liệu quy mô lớn.
- Trực quan hóa và khai thác dữ liệu.

Vì những lý do trên, nhóm lựa chọn đề tài **“Xây dựng hệ thống pipeline dữ liệu chứng khoán phục vụ phân tích và trực quan hóa”** làm nội dung nghiên cứu và triển khai.

1.2 Mục tiêu đề tài

1.2.1 Mục tiêu tổng quát

Xây dựng hệ thống pipeline dữ liệu chứng khoán có khả năng tự động thu thập, làm sạch, lưu trữ, phân tích và trực quan hóa dữ liệu cổ phiếu Việt Nam, đồng thời cung cấp nền tảng dữ liệu phục vụ các mô hình dự báo và hỗ trợ ra quyết định

1.2.2 Mục tiêu cụ thể

Đề tài hướng đến các mục tiêu cụ thể sau:

- Thu thập dữ liệu lịch sử của khoảng 500 mã cổ phiếu trên thị trường chứng khoán Việt Nam trong giai đoạn từ năm 2015 đến tháng 04 năm 2026.
- Xây dựng quy trình xử lý dữ liệu bao gồm khảo sát dữ liệu, phát hiện lỗi và làm sạch dữ liệu.
- Thiết kế hệ thống lưu trữ dữ liệu tập trung trên ClickHouse.
- Xây dựng kho dữ liệu (Data Warehouse) phục vụ phân tích.
- Xây dựng các Data Mart phục vụ các mục đích phân tích khác nhau.
- Tạo tập đặc trưng (Feature Store) phục vụ các mô hình học máy.
- Xây dựng các mô hình dự báo liên quan đến giá cổ phiếu, lợi suất, tín hiệu giao dịch và cảnh báo rủi ro.
- Thiết kế hệ thống dashboard phục vụ trực quan hóa dữ liệu.
- Tự động hóa toàn bộ quy trình xử lý dữ liệu thông qua workflow định kỳ.

1.3 Phạm vi đề tài

1.3.1 Phạm vi dữ liệu

Đề tài sử dụng dữ liệu giao dịch cổ phiếu trên thị trường chứng khoán Việt Nam với khoảng 500 mã cổ phiếu. Khoảng thời gian dữ liệu: Từ năm 2015 đến tháng 04 năm 2026.

Các thuộc tính dữ liệu chính bao gồm:

- Mã cổ phiếu (Symbol).
- Ngày giao dịch.
- Giá mở cửa (Open).
- Giá cao nhất (High).
- Giá thấp nhất (Low).

- Giá đóng cửa (Close).
- Khối lượng giao dịch (Volume).
- Tên doanh nghiệp.
- Nhóm ngành.

1.3.2 Phạm vi hệ thống

Hệ thống được xây dựng với các chức năng:

- Thu thập dữ liệu chứng khoán.
- Làm sạch dữ liệu.
- Lưu trữ dữ liệu.
- Xây dựng Data Warehouse.
- Xây dựng Data Mart.
- Xây dựng Dashboard trực quan hóa.
- Hỗ trợ phân tích và dự báo dữ liệu.

1.3.3 Phạm vi dự đoán

Trong phạm vi đề tài, nhóm triển khai năm mô hình dự báo:

- Dự báo giá đóng cửa trong tương lai.
- Dự báo lợi suất 5 ngày tiếp theo.
- Phân loại tín hiệu giao dịch BUY/HOLD/SELL.
- Dự báo khả năng vượt benchmark.
- Cảnh báo rủi ro giảm giá hoặc biến động mạnh.

Kết quả dự báo chỉ mang tính chất tham khảo phục vụ nghiên cứu và học tập, không được xem là khuyến nghị đầu tư chính thức.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm:

- Dữ liệu giao dịch cổ phiếu trên thị trường chứng khoán Việt Nam.
- Quy trình ETL và Data Pipeline.
- Hệ quản trị cơ sở dữ liệu ClickHouse.
- Mô hình Data Warehouse và Data Mart.
- Các phương pháp trực quan hóa dữ liệu.
- Các mô hình học máy phục vụ phân tích dữ liệu tài chính.

1.5 Phương pháp thực hiện

Đề tài được thực hiện theo các bước chính sau:

- Bước 1: Thu thập dữ liệu
Thu thập dữ liệu cổ phiếu từ các nguồn dữ liệu trực tuyến thông qua thư viện VnStocks và các API hỗ trợ.

- Bước 2: Khảo sát và làm sạch dữ liệu
Tiến hành khảo sát chất lượng dữ liệu, phát hiện các lỗi dữ liệu và thực hiện các quy trình làm sạch nhằm đảm bảo tính chính xác và nhất quán của dữ liệu.
- Bước 3: Xây dựng Data Warehouse
Thiết kế và triển khai hệ thống lưu trữ dữ liệu tập trung trên ClickHouse.
- Bước 4: Xây dựng mô hình dự báo
Sử dụng các mô hình học máy để thực hiện dự báo và phân loại tín hiệu giao dịch.
- Bước 5: Xây dựng Data Mart và Insight
Tổng hợp dữ liệu phục vụ từng mục đích phân tích và hỗ trợ dashboard.
- Bước 6: Trực quan hóa dữ liệu
Xây dựng dashboard phục vụ khai thác dữ liệu và hỗ trợ người dùng theo dõi thông tin.
- Bước 7: Đánh giá và hoàn thiện hệ thống
Đánh giá hiệu năng hệ thống, chất lượng dữ liệu và hiệu quả của các mô hình dự báo.

1.6 Ý nghĩa thực tiễn

- Về mặt học thuật
 - + Giúp vận dụng kiến thức về cơ sở dữ liệu, kho dữ liệu và khai phá dữ liệu.
 - + Minh họa quy trình xây dựng một hệ thống Business Intelligence hoàn chỉnh.
- Về mặt ứng dụng
 - + Hỗ trợ quản lý và khai thác dữ liệu chứng khoán hiệu quả.
 - + Hỗ trợ trực quan hóa và theo dõi biến động thị trường.
 - + Cung cấp các chỉ số và dự báo phục vụ phân tích đầu tư.
 - + Làm nền tảng cho việc mở rộng sang các hệ thống phân tích tài chính trong tương lai.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG

2.1 Tổng quan về dữ liệu chứng khoán

2.1.1 Khái niệm dữ liệu chứng khoán

Dữ liệu chứng khoán là tập hợp các thông tin phản ánh hoạt động giao dịch của các mã cổ phiếu trên thị trường tài chính. Đây là nguồn dữ liệu có tính thời gian (time-series data), được cập nhật liên tục theo từng phiên giao dịch.

Trong đề tài này, dữ liệu được thu thập từ thị trường chứng khoán Việt Nam thông qua thư viện VnStocks và các nguồn dữ liệu trực tuyến khác.

Mỗi bản ghi dữ liệu tương ứng với một mã cổ phiếu tại một ngày giao dịch xác định.

Ví dụ:

Symbol	Date	Open	High	Low	Close	Volume
FPT	2025-01-10	138000	140500	137500	140000	5.200.000

2.1.2 Các thuộc tính cơ bản của dữ liệu chứng khoán

- Giá mở cửa (Open)
Là mức giá giao dịch đầu tiên của cổ phiếu trong phiên giao dịch.
- Giá cao nhất (High)
Là mức giá cao nhất đạt được trong phiên giao dịch.
- Giá thấp nhất (Low)
Là mức giá thấp nhất đạt được trong phiên giao dịch.
- Giá đóng cửa (Close)
Là mức giá giao dịch cuối cùng trong phiên.
- Khối lượng giao dịch (Volume)
Thể hiện tổng số lượng cổ phiếu được giao dịch trong ngày.

2.1.3 Đặc điểm của dữ liệu chứng khoán

Dữ liệu chứng khoán có các đặc điểm: Trong đó:

- Có tính chuỗi thời gian.
- Khối lượng dữ liệu lớn.
- Liên tục phát sinh dữ liệu mới.
- Có thể xuất hiện dữ liệu thiếu hoặc bất thường.

- Chịu ảnh hưởng bởi nhiều yếu tố kinh tế và thị trường.
- Do đó cần xây dựng hệ thống Data Pipeline để xử lý hiệu quả.

2.2 Tổng quan về Data Pipeline


2.2.1 Khái niệm Data Pipeline

Data Pipeline là tập hợp các quy trình tự động dùng để thu thập, xử lý, chuyển đổi và lưu trữ dữ liệu từ nguồn đến hệ thống đích.

Mục tiêu của Data Pipeline là:

- Tự động hóa luồng dữ liệu.
- Đảm bảo dữ liệu luôn được cập nhật.
- Giảm thao tác thủ công.
- Tăng khả năng mở rộng hệ thống.

Trong đề tài, Data Pipeline được sử dụng để:



2.2.2 Các thành phần của Data Pipeline

Một hệ thống Data Pipeline thường bao gồm:

- Data Source: Nguồn dữ liệu ban đầu.
- Data Ingestion: Thu thập dữ liệu từ nguồn
- Data Processing: Làm sạch và chuẩn hóa dữ liệu.
- Data Storage: Lưu trữ dữ liệu.
- Data Consumption: Khai thác dữ liệu phục vụ dashboard và phân tích.

2.2.3 Vai trò của Data Pipeline trong đề tài

Data Pipeline giúp:

- Tự động thu thập dữ liệu mỗi ngày.
- Tự động làm sạch dữ liệu.

- Tự động cập nhật Data Warehouse.
- Tự động huấn luyện mô hình.
- Tự động sinh insight.
- Tự động cảnh báo và đưa ra kết quả tổng quát


2.3 ETL và ELT

2.3.1 Khái niệm ETL

ETL là viết tắt của

- Extract
- Transform
- Load

Quy trình ETL thực hiện:




2.3.2 Khái niệm ELT

ELT là viết tắt của:

- Extract
- Load
- Transform

Quy trình:



2.3.3 Mô hình được sử dụng trong đề tài

Hệ thống sử dụng mô hình kết hợp giữa ETL và ELT:

- ETL áp dụng cho:

- + Làm sạch dữ liệu Dirty.
- + Chuẩn hóa dữ liệu.
- ELT áp dụng cho:
 - + Upload dữ liệu vào ClickHouse.
 - + Tạo Feature Store.
 - + Sinh Data Mart.

2.4 Data Warehouse


2.4.1 Khái niệm Data Warehouse

Data Warehouse là kho dữ liệu tập trung dùng để lưu trữ dữ liệu lịch sử phục vụ phân tích và ra quyết định. Đặc điểm:

- Hướng chủ đề.
- Tích hợp dữ liệu.
- Có tính lịch sử.
- Tối ưu cho truy vấn phân tích.

2.4.2 Kiến trúc Data Warehouse

Hệ thống Data Warehouse trong đề tài gồm:



2.4.3 Staging Area

- Staging Area là vùng lưu trữ tạm thời.
- Trong đề tài **data/dirty/** đóng vai trò Staging Area.
- Dữ liệu mới được đưa vào đây trước khi xử lý.

2.4.4 Data Warehouse trong hệ thống

- Data Warehouse được xây dựng trên ClickHouse.
- Các bảng chính:
 - + stock_prices
 - + stock_symbols
 - + symbol_sector_encoding
 - + features_all

2.5 Data Mart

2.5.1 Khái niệm Data Mart

Data Mart là tập con của Data Warehouse được xây dựng cho một mục đích phân tích cụ thể. Data Mart giúp:

- Tăng tốc truy vấn.
- Đơn giản hóa khai thác dữ liệu.
- Hỗ trợ Dashboard.

2.5.2 Vai trò Data Mart trong đề tài

Các Data Mart được xây dựng phục vụ:

- Market Analysis
- Sector Analysis
- Price Forecast
- Trading Signals
- Risk Alerts

2.5.3 Các Data Mart sử dụng

- mart_daily_market_summary
- mart_sector_performance
- mart_model1_price_forecast
- mart_model3_trading_signals
- mart_risk_alerts

2.6 Feature Engineering

2.6.1 Khái niệm

Feature Engineering là quá trình xây dựng các biến đặc trưng từ dữ liệu gốc nhằm tăng khả năng học của mô hình.

2.6.2 Các Feature sử dụng trong đề tài

- **Return:** Lợi suất của cổ phiếu.
- **Moving Average:** Trung bình động MA5, MA20.
- **Volatility:** Độ biến động giá.
- **Volume Change:** Mức thay đổi khối lượng giao dịch.
- **High-Low Ratio:** Tỷ lệ giữa giá cao nhất và thấp nhất.
- **Open-Close Ratio:** Tỷ lệ giữa giá mở cửa và đóng cửa.

2.6.3 Feature Store

Toàn bộ đặc trưng được lưu trong: stock.features_all, và được sử dụng chung cho tất cả các mô hình.

2.7 Các mô hình học máy sử dụng

2.7.1 XGBoost

XGBoost là thuật toán Boosting dựa trên cây quyết định.

Ưu điểm:

- Tốc độ huấn luyện nhanh.
- Hiệu quả cao với dữ liệu dạng bảng.
- Khả năng chống overfitting tốt.

Được sử dụng trong model: 1, 3, 5

2.7.2 LightGBM

LightGBM là thuật toán Gradient Boosting tối ưu cho dữ liệu lớn.

Ưu điểm:

- Tốc độ nhanh.
- Tiêu thụ bộ nhớ thấp.
- Hiệu quả cao với dữ liệu lớn.

Được sử dụng trong model: 2, 4

2.8 ClickHouse

2.8.1 Giới thiệu ClickHouse

ClickHouse là hệ quản trị cơ sở dữ liệu dạng cột (Column-Oriented Database Management System) được phát triển bởi Yandex

2.8.2 Đặc điểm của ClickHouse

- Lưu trữ theo cột.
- Tốc độ truy vấn rất cao.
- Hỗ trợ dữ liệu lớn.
- Phù hợp cho OLAP.

2.8.3 Lý do lựa chọn ClickHouse

- Khối lượng dữ liệu lớn.
- Truy vấn phân tích nhanh.
- Hỗ trợ Data Warehouse.
- Dễ tích hợp Python.
- So sánh với PostgreSQL

Tiêu chí	ClickHouse	PostgreSQL
Kiến trúc lưu trữ	Columnar (lưu theo cột)	Row-based (lưu theo dòng)

Mục đích chính	OLAP, Analytics, Data Warehouse	OLTP, giao dịch; có thể dùng cho analytics quy mô vừa
Tốc độ truy vấn tổng hợp (SUM, COUNT, GROUP BY)	Rất nhanh, tối ưu cho hàng tỷ bản ghi	Chậm hơn đáng kể khi dữ liệu lớn
Hiệu năng trên dữ liệu lớn	Rất tốt (TB–PB)	Tốt ở quy mô GB–TB nhỏ/trung bình
Nén dữ liệu	Cao (3–10x hoặc hơn)	Thấp hơn
Concurrent writes	Tốt nhưng không phải thế mạnh chính	Rất mạnh
ACID transactions	Hạn chế hơn PostgreSQL	Hỗ trợ đầy đủ ACID
JOIN phức tạp	Có hỗ trợ nhưng không tối ưu bằng PostgreSQL	Rất mạnh
UPDATE / DELETE thường xuyên	Không phù hợp	Rất phù hợp
Real-time analytics	Xuất sắc	Khá tốt nhưng giới hạn ở dữ liệu lớn
Materialized Views	Mạnh, dùng nhiều trong aggregation	Có nhưng ít mạnh mẽ hơn
Partitioning	Tối ưu cho warehouse	Có nhưng phức tạp hơn
Horizontal Scaling	Native distributed cluster	Cần extension hoặc giải pháp ngoài
Chi phí hạ tầng	Hiệu quả hơn cho analytics lớn	Tốn tài nguyên hơn khi warehouse lớn
Learning curve	Trung bình	Dễ tiếp cận hơn
Ecosystem BI	Tốt (Superset, Metabase, Grafana, Tableau...)	Rất tốt
Backup & Recovery	Tốt	Rất trưởng thành

2.9 Công nghệ sử dụng

- **Python**: Ngôn ngữ chính xây dựng Pipeline
- **VnStocks**: Thu thập dữ liệu chứng khoán
- **ClickHouse**: Kho dữ liệu phân tích
- **GitHub Actions**: Tự động hóa workflow hằng ngày
- **Telegram Bot**: Thông báo trạng thái pipeline.

CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 Phân tích yêu cầu nghiệp vụ

3.1.1 Bài toán thực tế

Thị trường chứng khoán Việt Nam mỗi ngày phát sinh lượng lớn dữ liệu giao dịch từ hàng trăm mã cổ phiếu thuộc nhiều nhóm ngành khác nhau. Dữ liệu này được cập nhật liên tục theo từng phiên giao dịch và có giá trị quan trọng trong hoạt động phân tích thị trường cũng như hỗ trợ ra quyết định đầu tư.

Tuy nhiên, dữ liệu thường được phân tán ở nhiều nguồn khác nhau và chưa được tổ chức thành một hệ thống quản lý tập trung. Việc thu thập, lưu trữ và khai thác dữ liệu theo phương pháp thủ công gây khó khăn trong quá trình phân tích, đồng thời làm giảm hiệu quả sử dụng dữ liệu.

Do đó cần xây dựng một hệ thống có khả năng:

- Thu thập dữ liệu tự động.
- Làm sạch dữ liệu.
- Lưu trữ tập trung.
- Hỗ trợ truy vấn nhanh.
- Phân tích và trực quan hóa dữ liệu.
- Hỗ trợ các mô hình dự báo.

3.1.2 Yêu cầu phi chức năng

Hệ thống cần đáp ứng các chức năng sau:

- Thu thập dữ liệu
 - + Thu thập dữ liệu cổ phiếu hằng ngày.
 - + Hỗ trợ khoảng 500 mã cổ phiếu.
 - + Tự động cập nhật dữ liệu mới.
- Quản lý dữ liệu
 - + Lưu dữ liệu gốc.
 - + Kiểm tra chất lượng dữ liệu.
 - + Làm sạch dữ liệu.
 - + Ghi log quá trình xử lý.
- Quản lý kho dữ liệu
 - + Lưu trữ dữ liệu lịch sử.
 - + Quản lý dữ liệu theo thời gian.
 - + Hỗ trợ truy vấn phân tích.
- Phân tích dữ liệu
 - + Phân tích theo cổ phiếu.

- + Phân tích theo ngành.
- + Phân tích theo thời gian
- Dự báo
 - + Dự báo giá cổ phiếu.
 - + Dự báo lợi suất.
 - + Dự báo tín hiệu giao dịch.
 - + Dự báo rủi ro.
- Dashboard
 - + Hiển thị dữ liệu trực quan.
 - + Hiển thị kết quả dự báo.
 - + Hiển thị các insight

3.1.3 Yêu cầu phi chức năng

- Hiệu năng
 - + Hỗ trợ xử lý hàng triệu bản ghi dữ liệu lịch sử.
 - + Truy vấn dữ liệu nhanh.
- Tự động hóa
 - + Tự động cập nhật dữ liệu hằng ngày.
 - + Tự động huấn luyện mô hình.
 - + Tự động sinh insight.
- Khả năng mở rộng
 - + Dễ dàng bổ sung thêm mã cổ phiếu.
 - + Dễ dàng bổ sung thêm mô hình dự báo.
 - + Dễ dàng mở rộng dashboard.

3.2 Phân tích nguồn dữ liệu

3.2.1 Nguồn dữ liệu

Dữ liệu được thu thập từ:

- VnStocks: Thư viện Python hỗ trợ truy xuất dữ liệu chứng khoán Việt Nam.
- VCI, KBS: Nguồn dữ liệu giá lịch sử.
- Nguồn dữ liệu bổ sung phục vụ đối chiếu và cập nhật.

3.2.2 Phạm vi dữ liệu

- Số lượng mã: khoảng 500 mã
- Khoảng thời gian: từ 01/01/2015 → 01/04/2026

3.2.3 Cấu trúc dữ liệu

Dữ liệu sau khi thu thập bao gồm:

Thuộc tính	Ý nghĩa
------------	---------

symbol	Mã cổ phiếu
date	Ngày giao dịch
open	Giá mở cửa
high	Giá cao nhất
low	Giá thấp nhất
close	Giá đóng cửa
volume	Khối lượng giao dịch
company_name	Tên doanh nghiệp
sector	Nhóm ngành


3.2.4 Đặc điểm dữ liệu


- Dữ liệu có các đặc điểm:
 - + Dữ liệu chuỗi thời gian.
 - + Khối lượng lớn.
 - + Liên tục phát sinh.
 - + Có khả năng xuất hiện lỗi.
- Ví dụ:
 - + Giá âm.
 - + Giá bằng 0.
 - + Khối lượng âm.
 - + Mã cổ phiếu không hợp lệ.
 - + Dữ liệu trùng lặp.

3.3 Thiết kế kiến trúc tổng thể hệ thống

3.3.1 Kiến trúc tổng thể

Hệ thống được thiết kế theo kiến trúc nhiều tầng.





3.3.2 Mô tả các tầng

- **Data Sources:** Nguồn dữ liệu chứng khoán.
- **Data Lake:** Lưu dữ liệu thô và dữ liệu đã làm sạch.
- **ETL Pipeline:** Thực hiện:
 - + Merge dữ liệu
 - + Khảo sát dữ liệu
 - + Làm sạch dữ liệu
- **Data Warehouse:** Lưu trữ dữ liệu phân tích.
- **Feature Store:** Sinh các đặc trưng dùng chung.
- **Machine Learning Layer:** Triển khai 5 mô hình dự báo.
- **Data Mart:** Tổng hợp dữ liệu theo mục đích nghiệp vụ.
- **Dashboard Layer:** Hiển thị dữ liệu trực quan.

3.4 Thiết kế ETL Pipeline

3.4.1 Luồng ETL

Trong dự án, nhóm xây dựng quy trình ETL nhằm tự động thu thập, xử lý và lưu trữ dữ liệu chứng khoán vào hệ quản trị cơ sở dữ liệu ClickHouse. Luồng ETL được thiết kế theo hướng tuần tự, bắt đầu từ dữ liệu thô, sau đó làm sạch, chuẩn hóa, tạo thêm các đặc trưng kỹ thuật và cuối cùng lưu vào các bảng phục vụ phân tích, dashboard và mô hình dự đoán.

Quy trình ETL tổng quát của hệ thống gồm các bước chính:

1. Thu thập dữ liệu giá cổ phiếu theo ngày, bao gồm các trường như mã cổ phiếu, ngày giao dịch, giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch.
2. Chuẩn hóa dữ liệu đầu vào, chuyển đổi định dạng ngày, chuẩn hóa mã cổ phiếu, ép kiểu dữ liệu số và loại bỏ các bản ghi không hợp lệ.
3. Làm sạch dữ liệu, xử lý giá trị thiếu, loại bỏ dữ liệu trùng lặp theo cặp symbol và trading_date, đồng thời kiểm tra các lỗi cơ bản như giá âm, volume âm hoặc dữ liệu OHLC không hợp lệ.

4. Tạo bảng dữ liệu đặc trưng features_all từ dữ liệu OHLCV ban đầu. Đây là bảng trung tâm, được dùng làm đầu vào cho nhiều mô hình dự đoán trong dự án.
5. Huấn luyện và đánh giá các mô hình dự đoán, sau đó tạo ra các bảng data mart như dự đoán giá, dự đoán lợi suất, tín hiệu BUY/HOLD/SELL, outperform benchmark và cảnh báo rủi ro.
6. Nạp toàn bộ dữ liệu đã xử lý và các kết quả phân tích vào ClickHouse để phục vụ truy vấn, dashboard và báo cáo.

Nhờ luồng ETL này, dữ liệu trong hệ thống không chỉ được lưu trữ đơn thuần mà còn được biến đổi thành các bảng có ý nghĩa phân tích cao hơn, hỗ trợ trực tiếp cho việc trực quan hóa và ra quyết định.

3.4.2 Giai đoạn Extract

Giai đoạn Extract là bước đầu tiên trong quy trình ETL, có nhiệm vụ thu thập dữ liệu từ các nguồn bên ngoài và đưa vào hệ thống để phục vụ cho các bước xử lý tiếp theo. Trong đề tài này, nhóm sử dụng thư viện VnStocks của Python để khai thác dữ liệu lịch sử của khoảng 500 mã cổ phiếu trên thị trường chứng khoán Việt Nam.

Nguồn dữ liệu sử dụng: Dữ liệu được thu thập từ hai nguồn chính được hỗ trợ bởi thư viện VnStocks:

- Nguồn KBS: Nguồn dữ liệu KBS được sử dụng để thu thập dữ liệu giao dịch lịch sử của các mã cổ phiếu. Các thuộc tính được lấy bao gồm:
 - + Symbol (Mã cổ phiếu)
 - + Trading Date (Ngày giao dịch)
 - + Open (Giá mở cửa)
 - + High (Giá cao nhất)
 - + Low (Giá thấp nhất)
 - + Close (Giá đóng cửa)
 - + Volume (Khối lượng giao dịch)

Đây là nguồn dữ liệu chính phục vụ cho việc xây dựng Data Warehouse và các mô hình dự báo.

- Nguồn VCI: Nguồn dữ liệu VCI được sử dụng để thu thập các thông tin mô tả doanh nghiệp dựa trên mã cổ phiếu, bao gồm:
 - + Tên doanh nghiệp (Company Name)
 - + Nhóm ngành (Sector)

Thông tin này được sử dụng để bổ sung dữ liệu định danh doanh nghiệp và phục vụ các phân tích theo ngành trong các Data Mart và Dashboard.

Quy trình thu thập dữ liệu:

- Khởi tạo danh sách các mã cổ phiếu cần thu thập.

- Sử dụng API của KBS thông qua thư viện VnStocks để lấy dữ liệu giao dịch lịch sử.
- Sử dụng API của VCI để lấy thông tin doanh nghiệp và nhóm ngành tương ứng với từng mã cổ phiếu.
- Thực hiện ghép nối dữ liệu giao dịch và dữ liệu doanh nghiệp thông qua trường khóa `symbol`.
- Lưu dữ liệu thu thập được vào các tệp CSV tại khu vực lưu trữ trung gian (Staging Area).

Kiểm soát tần suất truy vấn: Do sử dụng gói miễn phí của thư viện VnStocks nên số lượng yêu cầu gửi đến máy chủ bị giới hạn nhằm tránh quá tải hệ thống. Nếu gửi quá nhiều yêu cầu liên tiếp trong thời gian ngắn, địa chỉ IP có thể bị tạm thời hạn chế truy cập. Để đảm bảo quá trình thu thập dữ liệu diễn ra ổn định, hệ thống áp dụng cơ chế nghỉ ngẫu nhiên (Random Sleep) giữa các lần truy vấn. Thời gian nghỉ được sinh ngẫu nhiên trong khoảng: **90 giây đến 110 giây**. Việc sử dụng khoảng nghỉ ngẫu nhiên giúp:

- Giảm nguy cơ bị giới hạn truy cập từ phía nhà cung cấp dữ liệu.
- Mô phỏng hành vi truy cập tự nhiên của người dùng.
- Tăng độ ổn định của quá trình thu thập dữ liệu kéo dài trên nhiều giờ.
- Hạn chế lỗi kết nối và lỗi quá tải máy chủ.

Kết quả của giai đoạn Extract: Sau khi hoàn thành giai đoạn Extract, hệ thống thu được tập dữ liệu lịch sử của khoảng 500 mã cổ phiếu trong giai đoạn từ năm 2015 đến tháng 04 năm 2026. Dữ liệu sau khi thu thập được lưu dưới dạng các tệp CSV trong khu vực Staging Area và tiếp tục được chuyển sang giai đoạn Transform để thực hiện khảo sát và làm sạch dữ liệu

3.4.3 Giai đoạn Transform

Giai đoạn Transform là bước quan trọng nhất trong pipeline, vì dữ liệu sau khi thu thập thường chưa thể sử dụng trực tiếp cho phân tích hoặc huấn luyện mô hình. Trong dự án, dữ liệu được xử lý qua nhiều bước nhằm đảm bảo tính nhất quán, đầy đủ và phù hợp với yêu cầu của các mô hình dự đoán.

Trước hết, dữ liệu được chuẩn hóa về định dạng. Cột ngày giao dịch được chuyển về kiểu thời gian, mã cổ phiếu được chuẩn hóa về chữ in hoa và loại bỏ khoảng trắng thừa. Các cột giá và khối lượng như `open`, `high`, `low`, `close`, `volume` được ép về kiểu số để tránh lỗi khi tính toán. Những dòng thiếu các thông tin quan trọng như mã cổ phiếu, ngày giao dịch hoặc giá đóng cửa sẽ bị loại bỏ.

Tiếp theo, hệ thống thực hiện làm sạch dữ liệu. Các bản ghi trùng lặp theo cùng một mã cổ phiếu và ngày giao dịch được loại bỏ để đảm bảo mỗi cổ phiếu chỉ có một dòng dữ liệu trong một ngày. Ngoài ra, hệ thống cũng kiểm tra các điều kiện bất thường như

giá nhỏ hơn hoặc bằng 0, volume âm, giá cao nhất nhỏ hơn giá thấp nhất, hoặc giá mở cửa/đóng cửa nằm ngoài khoảng high-low.

Sau khi dữ liệu cơ bản được làm sạch, hệ thống tiến hành tạo đặc trưng kỹ thuật cho bảng features_all. Các feature này được xây dựng từ dữ liệu OHLCV, bao gồm:

- Lợi suất theo nhiều khoảng thời gian như return_1d, return_3d, return_5d, return_10d, return_20d.
- Trung bình động như ma_5, ma_20, ma_50.
- Khoảng cách giữa giá đóng cửa và đường trung bình như price_vs_ma20, ma5_vs_ma20.
- Độ biến động như volatility_5d, volatility_20d, volatility_change.
- Chỉ số drawdown như rolling_max_20d, drawdown_20d.
- Các feature liên quan đến khối lượng như volume_ma_5, volume_ma_20, volume_ratio_5_20, volume_change_1d.
- Các đặc trưng nền như daily_range, body_ratio, close_position.

Ngoài các feature kỹ thuật, dự án còn bổ sung thông tin ngành thông qua trường encode_sector. Trường này giúp các mô hình có thêm thông tin về nhóm ngành của từng cổ phiếu, thay vì chỉ dựa vào biến động giá và khối lượng.

Đối với từng mô hình, dữ liệu tiếp tục được biến đổi thành các target khác nhau. Model 1 và Model 2 tập trung vào dự đoán giá hoặc lợi suất trong tương lai. Model 3 chuyển bài toán thành phân loại tín hiệu BUY, HOLD, SELL dựa trên ngưỡng lợi suất tương lai. Model 4 tạo nhãn cho biết cổ phiếu có outperform benchmark hay không. Model 5 tạo nhãn rủi ro dựa trên khả năng giảm giá trong tương lai.

Kết quả của giai đoạn Transform là các bảng dữ liệu sạch, có cấu trúc rõ ràng, bao gồm bảng feature dùng chung và các bảng kết quả riêng cho từng mô hình.

3.4.4 Giai đoạn Load

Sau khi dữ liệu đã được xử lý và tạo feature, hệ thống thực hiện giai đoạn Load để đưa dữ liệu vào ClickHouse. Đây là nơi lưu trữ tập trung cho dữ liệu giá, dữ liệu feature, kết quả mô hình và các bảng data mart phục vụ dashboard.

Dữ liệu gốc sau khi làm sạch được nạp vào bảng stock.stock_prices. Bảng này lưu thông tin giao dịch theo ngày của từng mã cổ phiếu, bao gồm symbol, date, open, high, low, close và volume. Bảng được thiết kế bằng engine MergeTree và sắp xếp theo (symbol, date) để tối ưu cho các truy vấn theo mã cổ phiếu và thời gian.

Thông tin cổ phiếu và ngành được nạp vào các bảng như stock.stock_symbols và stock.symbol_sector_encoding. Các bảng này đóng vai trò như bảng dimension, hỗ trợ việc join thêm thông tin công ty, sector và mã hóa ngành vào dữ liệu feature hoặc các bảng mart.

Bảng quan trọng nhất sau giai đoạn Load là `stock.features_all`. Đây là bảng feature store trung tâm của dự án, chứa dữ liệu OHLCV đã được bổ sung các đặc trưng kỹ thuật. Nhiều mô hình trong hệ thống sử dụng bảng này làm đầu vào để huấn luyện và dự đoán. Việc lưu `features_all` trong ClickHouse giúp các mô hình và dashboard có thể truy vấn dữ liệu nhanh hơn thay vì phải xử lý lại từ file CSV mỗi lần chạy.

Ngoài dữ liệu đầu vào, hệ thống còn nạp các kết quả mô hình vào các bảng data mart. Một số mart quan trọng gồm:

- `mart_model1_price_forecast`: lưu kết quả dự báo giá hoặc lợi suất của Model 1.
- `mart_model2_future_return`: lưu kết quả dự đoán lợi suất 5 phiên của Model 2.
- `mart_model3_trading_signals`: lưu tín hiệu giao dịch BUY/HOLD/SELL của Model 3.
- `mart_model4_benchmark_outperformance`: lưu kết quả dự đoán cổ phiếu có outperform benchmark hay không.
- `mart_model5_risk_alerts`: lưu cảnh báo rủi ro của Model 5.

Các bảng mart này giúp tách biệt dữ liệu phục vụ phân tích khỏi dữ liệu thô. Dashboard không cần xử lý lại kết quả mô hình mà chỉ cần truy vấn trực tiếp các mart đã được chuẩn hóa.

Trong quá trình load, hệ thống sử dụng cơ chế tạo bảng nếu chưa tồn tại, xóa hoặc truncate dữ liệu cũ khi cần upload lại, sau đó insert dữ liệu mới vào ClickHouse. Một số script cũng hỗ trợ upload theo chunk để giảm rủi ro lỗi khi dữ liệu lớn. Ngoài ra, hệ thống còn đọc metadata từ `system.tables` và `system.columns` của ClickHouse để hiển thị danh sách bảng, schema và preview dữ liệu trên giao diện web.

Nhờ giai đoạn Load, toàn bộ dữ liệu sau xử lý được lưu trữ tập trung, có thể truy vấn nhanh và phục vụ nhiều mục đích khác nhau như kiểm tra chất lượng dữ liệu, trực quan hóa, đánh giá mô hình và tạo insight chứng khoán.

3.5 Thiết kế Data Warehouse

3.5.1 Mục tiêu thiết kế Data Warehouse

Sau khi dữ liệu được thu thập và làm sạch, hệ thống cần một môi trường lưu trữ tập trung nhằm phục vụ các nhu cầu:

- Lưu trữ dữ liệu lịch sử trong thời gian dài.
- Hỗ trợ truy vấn phân tích trên tập dữ liệu lớn.
- Làm nguồn dữ liệu cho Feature Engineering.
- Làm nguồn dữ liệu cho các mô hình Machine Learning.
- Cung cấp dữ liệu cho Data Mart và Dashboard.

Để đáp ứng các yêu cầu trên, nhóm lựa chọn xây dựng Data Warehouse trên nền tảng ClickHouse.

3.5.2 Lựa chọn ClickHouse làm Data Warehouse

ClickHouse là hệ quản trị cơ sở dữ liệu dạng cột (Column-Oriented Database Management System) được thiết kế tối ưu cho các bài toán phân tích dữ liệu (OLAP).

Nhóm lựa chọn ClickHouse thay vì các hệ quản trị cơ sở dữ liệu truyền thống như MySQL hoặc PostgreSQL vì các lý do sau:

Hỗ trợ dữ liệu lớn: Dữ liệu của hệ thống bao gồm:

- Khoảng 500 mã cổ phiếu.
- Giai đoạn từ năm 2015 đến tháng 04 năm 2026.
- Hàng triệu bản ghi giao dịch.

ClickHouse có khả năng xử lý khối lượng dữ liệu lớn mà vẫn đảm bảo tốc độ truy vấn.

3.6 Thiết kế Feature Store

3.6.1 Mục tiêu

Tạo nguồn dữ liệu dùng chung cho:

- Dashboard
- Data Mart
- Machine Learning

Dễ dàng truy vấn và sử dụng vào các mục đích sau này của hệ thống

3.6.2 Feature Engineering

- **return_1d**: lợi suất 1 ngày, được tính bằng (giá đóng cửa hôm nay / giá đóng cửa hôm qua) - 1
- **return_3d**: lợi suất 3 ngày, được tính bằng (giá đóng cửa hôm nay / giá đóng cửa 3 ngày trước) - 1
- **return_5d**: lợi suất 5 ngày, được tính bằng (giá đóng cửa hôm nay / giá đóng cửa 5 ngày trước) - 1
- **return_10d**: lợi suất 10 ngày, được tính bằng (giá đóng cửa hôm nay / giá đóng cửa 10 ngày trước) - 1
- **return_20d**: lợi suất 20 ngày, được tính bằng (giá đóng cửa hôm nay / giá đóng cửa 20 ngày trước) - 1
- **ma_5**: đường trung bình động 5 ngày của giá đóng cửa
- **ma_20**: đường trung bình động 20 ngày của giá đóng cửa
- **ma_50**: đường trung bình động 50 ngày của giá đóng cửa
- **price_vs_ma20**: so sánh giá đóng cửa hôm nay với đường trung bình động 20 ngày, được tính bằng (giá đóng cửa hôm nay / ma_20) - 1

- **ma5_vs_ma20**: so sánh đường trung bình động 5 ngày với đường trung bình động 20 ngày, được tính bằng $(ma_5 / ma_20) - 1$
- **volatility_5d**: độ biến động 5 ngày, được tính bằng độ lệch chuẩn rolling 5 ngày của lợi suất hàng ngày
- **volatility_20d**: độ biến động 20 ngày, được tính bằng độ lệch chuẩn rolling 20 ngày của lợi suất hàng ngày
- **volatility_change**: mức thay đổi độ biến động, được tính bằng $(volatility_5d / volatility_20d) - 1$
- **rolling_max_20d**: giá đóng cửa cao nhất trong cửa sổ rolling 20 ngày gần nhất
- **drawdown_20d**: mức sụt giảm so với đỉnh rolling 20 ngày, được tính bằng $(giá\ đóng\ cửa\ hôm\ nay / rolling_max_20d) - 1$
- **volume_ma_5**: trung bình động 5 ngày của khối lượng giao dịch
- **volume_ma_20**: trung bình động 20 ngày của khối lượng giao dịch
- **volume_ratio_5_20**: tỷ lệ giữa trung bình động khối lượng 5 ngày và 20 ngày, được tính bằng $(volume_ma_5 / volume_ma_20)$
- **volume_change_1d**: mức thay đổi khối lượng giao dịch trong 1 ngày, được tính bằng $(khối\ lượng\ hôm\ nay / khối\ lượng\ hôm\ qua) - 1$
- **daily_range**: biên độ dao động giá trong ngày được chuẩn hóa theo giá đóng cửa, được tính bằng $(giá\ cao\ nhất - giá\ thấp\ nhất) / giá\ đóng\ cửa$
- **body_ratio**: tỷ lệ thân nến so với biên độ dao động trong ngày, được tính bằng $abs(giá\ đóng\ cửa - giá\ mở\ cửa) / (giá\ cao\ nhất - giá\ thấp\ nhất)$
- **close_position**: vị trí của giá đóng cửa trong biên độ giá trong ngày, được tính bằng $(giá\ đóng\ cửa - giá\ thấp\ nhất) / (giá\ cao\ nhất - giá\ thấp\ nhất)$

3.7 Thiết kế tầng Machine Learning - Data Mart tương ứng

3.7.1 Model 1 – Price Forecasting

3.7.1.1. Tổng quan bài toán và mục tiêu

Model 1 được thiết kế nhằm phục vụ bài toán dự báo giá đóng cửa của cổ phiếu trong tương lai ngắn hạn, cụ thể là sau 5 phiên giao dịch tiếp theo. Đây là bài toán hồi quy có giám sát, trong đó đầu ra của mô hình là một giá trị liên tục biểu diễn giá đóng cửa tương lai của từng mã cổ phiếu.

Mục tiêu chính của Model 1 là sử dụng dữ liệu lịch sử và các đặc trưng kỹ thuật của cổ phiếu để dự đoán predicted_close, tức giá đóng cửa kỳ vọng sau 5 phiên giao dịch. Kết quả này có thể được sử dụng trong Dashboard để so sánh giữa giá thực tế và giá dự đoán, đánh giá sai số mô hình, theo dõi độ ổn định của mô hình và hỗ trợ người dùng quan sát xu hướng giá trong ngắn hạn.

3.7.1.2. Dữ liệu đầu vào

Nguồn dữ liệu đầu vào của Model 1 là bảng : stock.features_all

Dữ liệu được lấy từ ClickHouse thông qua module data_loader.py. Bảng này được xây dựng từ dữ liệu giá cổ phiếu đã làm sạch và các đặc trưng kỹ thuật đã được tạo trong tầng Feature Store.

3.7.1.3. Các đặc trưng sử dụng

Model 1 sử dụng các nhóm đặc trưng chính sau:

Nhóm đặc trưng	Các biến sử dụng
Đặc trưng ngành	encode_sector
Giá giao dịch	open, high, low, close, volume
Lợi suất quá khứ	return_1d, return_3d, return_5d, return_10d, return_20d
Trung bình động	ma_5, ma_20, ma_50
Xu hướng giá	price_vs_ma20, ma5_vs_ma20
Thanh khoản	volume_ma_5, volume_ma_20, volume_ratio_5_20, volume_change_1d
Biến động	volatility_5d, volatility_20d, volatility_change
Rủi ro giảm giá ngắn hạn	rolling_max_20d, drawdown_20d
Cấu trúc nền giá	daily_range, body_ratio, close_position

Danh sách đặc trưng được khai báo tập trung trong file config.py, giúp việc quản lý, tái sử dụng và điều chỉnh feature được thuận tiện

3.7.1.4. Biến mục tiêu

Biến mục tiêu của model 1 là : target_close

Công thức : target_close = close[t + 5]

Trong đó :

- close[t] : là giá đóng cửa tại ngày giao dịch hiện tại
- close[t + 5] : là giá đóng cửa say 5 phiên giao dịch của cùng một mã cổ phiếu
- target_close : là giá trị mà mô hình cần học và dự đoán

Biến này được tạo bằng cách nhóm dữ liệu theo từng mã cổ phiếu symbol, sắp xếp theo trading_date, sau đó dịch cột close lên 5 phiên. Các dòng không có đủ dữ liệu tương lai để tạo nhãn sẽ bị loại bỏ khỏi tập huấn luyện.

3.7.1.5. Thuật toán lựa chọn

Model 1 sử dụng thuật toán : XGBoost Regressor

Lý do lựa chọn :

- phù hợp với dữ liệu dạng bảng có nhiều đặc trưng kỹ thuật
- có khả năng học quan hệ phi tuyến giữa giá, thanh khoản, biến động và xu hướng
- Hoạt động hiệu quả với dữ liệu tài chính có nhiễu
- Hỗ trợ regularization để giảm overfitting
- Có thể trích xuất feature importance để phục vụ phân tích mô hình

Các tham số chính đang sử dụng gồm :

- N_estimators = 1000
- Learning_rate = 0.02
- Max_depth = 4
- Min_child_weight = 3
- Subsample = 0.8
- Colsample_bytree = 0.8
- Reg_alpha = 0.1
- Reg_lambda = 1.0
- Objective = reg : squarederror
- Eval_metric = rmse

Mô hình được huấn luyện với cơ chế early stopping thông qua tập validation để hạn chế overfitting.

3.7.1.6. Thiết kế chia tập dữ liệu

Dữ liệu được chia theo thời gian thay vì chia ngẫu nhiên. Đây là thiết kế phù hợp với dữ liệu chứng khoán vì mô hình chỉ được phép học từ dữ liệu quá khứ và kiểm thử trên dữ liệu tương lai.

Tỷ lệ chia dữ liệu

- Train set = 70%
- Validation set = 15%
- Test set = 15%

Quy trình chia

- Dữ liệu được sắp xếp theo trading_date
- 70% giai đoạn đầu dùng để huấn luyện
- 15% giai đoạn tiếp theo dùng để validation và early stopping
- 15% giai đoạn cuối cùng để kiểm thử mô hình

3.7.1.7. Thiết kế kiểm định mô hình

Model 1 được kiểm định bằng các chỉ số hồi quy trên tập test.

Các chỉ số chính gồm :

Chỉ số	Ý nghĩa
MAE	Sai số tuyệt đối trung bình giữa giá thật và giá dự đoán
RMSE	Sai số bình phương trung bình, nhạy hơn với lỗi lớn
MAPE	Sai số phần trăm trung bình
R2	Mức độ giải thích biến động của giá đóng cửa tương lai
Directional Accuracy	Tỷ lệ dự đoán đúng chiều tăng/giảm, chỉ là chỉ số phụ suy ra từ giá

Kết quả hiện tại :

- MAE : 1.0021
- RMSE : 3.4783
- MAPE : 4.1789 %
- R2 = 0.9766
- Directional Accuracy = 50.97%

3.7.1.8. Thiết kế đầu ra của mô hình

Đầu ra chính của Model 1 là : predicted_close = giá đóng cửa sau 5 phiên giao dịch do mô hình dự đoán

Các thông tin đầu ra quan trọng :

Đầu ra	Ý nghĩa
Prediction_date	Ngày dùng để lấy features đầu vào
Target_date	Ngày tương lai sau 5 phiên giao dịch
Symbol	Mã cổ phiếu
Real_close	Giá đóng cửa thực tế tại target_date, dùng để đánh giá
Predicted_close	Giá đóng cửa tương lai do model dự đoán
Price_error	Sai số tuyệt đối hoặc chênh lệch giữa giá dự đoán và giá thật
Error_pct	Sai số phần trăm giữa giá dự đoán và giá thật

3.7.1.9. Thiết kế Data Mart và Insight cho Model 1

Kết quả dự đoán của Model 1 được chuẩn hóa thành các Data Mart để phục vụ Dashboard :

- Mart_model1_backtest_daily : Bảng chứa kết quả backtest theo từng ngày của chiến lược chọn cổ phiếu dựa trên kết quả model 1
- Mart_model1_metrics: Bảng chứa các chỉ số đánh giá chất lượng model 1 theo từng lần chạy
- Mart_model1_price_forecast : Bảng chứa kết quả dự báo giá đóng cửa tương lai của model 1. Mục đích để hiển thị dự báo giá đóng cửa sau 5 phiên, so sánh giá thật và giá dự đoán, vẽ biểu đồ actual và predicted_close
- Mart_model1_daly_insight : Bảng chứa các câu insight tự động được sinh từ kết quả model 1

3.7.2 Model 2 – Future Return Prediction

a. Mục tiêu chính

Model 2 được thiết kế nhằm dự đoán **lợi suất kỳ vọng của cổ phiếu trong 5 phiên giao dịch tiếp theo**. Kết quả dự đoán giúp hệ thống xếp hạng các mã cổ phiếu theo mức sinh lời kỳ vọng, từ đó phục vụ tầng Data Mart, Insight và Dashboard.

Mô hình này thuộc nhóm bài toán **hồi quy**, vì giá trị cần dự đoán là một số thực biểu diễn tỷ lệ lợi suất.

b. Dữ Liệu đầu vào

Nguồn dữ liệu đầu vào của Model 2 là bảng: stock.features_all

Bảng này được tạo từ dữ liệu giá cổ phiếu đã làm sạch và các đặc trưng kỹ thuật đã được xây dựng trước đó. Model không đọc trực tiếp từ file CSV mà lấy dữ liệu từ ClickHouse thông qua module data_loader.py.

c. Các đặc trưng sử dụng (Features)

Model 2 sử dụng các nhóm đặc trưng chính sau:

Nhóm đặc trưng	Ví dụ
Giá giao dịch	open, high, low, close
Thanh khoản	volume, volume_ma_5, volume_ma_20, volume_ratio_5_20
Lợi suất quá khứ	return_1d, return_3d, return_5d, return_10d, return_20d
Xu hướng giá	ma_5, ma_20, ma_50, price_vs_ma20, ma5_vs_ma20
Biến động	volatility_5d, volatility_20d, volatility_change
Rủi ro ngắn hạn	rolling_max_20d, drawdown_20d
Đặc trưng nền giá	daily_range, body_ratio, close_position

Nhóm ngành	encode_sector
------------	---------------

Danh sách feature được khai báo tập trung trong file config.py

d. Biến mục tiêu (Target)

Biến mục tiêu của mô hình là : **future_return_5d**

Công thức: $\text{future_return_5d} = \text{close}[t+5] / \text{close}[t] - 1$

Trong đó:

- $\text{close}[t]$ là giá đóng cửa tại ngày hiện tại.
- $\text{close}[t+5]$ là giá đóng cửa sau 5 phiên giao dịch.
- Kết quả thể hiện mức lợi suất sau 5 phiên.

Biến này được tạo trong hàm `create_features()` bằng cách dịch giá đóng cửa của từng mã cổ phiếu lên 5 phiên.

e. Thuật toán lựa chọn

Mô hình sử dụng thuật toán: LightGBM Regressor

Lý do lựa chọn:

- Phù hợp với dữ liệu dạng bảng.
- Có khả năng học quan hệ phi tuyến giữa các đặc trưng.
- Tốc độ huấn luyện nhanh.
- Phù hợp với dữ liệu có nhiều mã cổ phiếu và nhiều feature.
- Có thể trích xuất feature importance để phục vụ phân tích.

f. Thiết kế chia tập dữ liệu

Dữ liệu được chia theo thời gian thay vì chia ngẫu nhiên.

Mốc chia dữ liệu:

- `TEST_START_DATE = 2024-01-01`

Thiết kế chia dữ liệu:

- Dữ liệu trước 2024-01-01 → Train set
- Dữ liệu từ 2024-01-01 trở đi → Test set

Cách chia này phù hợp với dữ liệu chứng khoán vì đảm bảo mô hình chỉ học từ dữ liệu quá khứ và kiểm thử trên dữ liệu tương lai.

g. Thiết kế kiểm định Walk-forward

Ngoài train/test split, nhóm xây dựng thêm module walk-forward validation để kiểm định mô hình theo cửa sổ thời gian.

Thiết kế:

- Train window = 500 dòng
- Test window = 50 dòng

Mỗi lần mô hình được huấn luyện trên một cửa sổ dữ liệu quá khứ và kiểm thử trên cửa sổ dữ liệu ngay sau đó. Kết quả đánh giá chính là MAE

h. Thiết kế đầu ra của mô hình

Model 2 sinh ra các thông tin:

Đầu ra	Ý nghĩa
predicted_future_return_5d	Lợi suất 5 phiên do mô hình dự đoán
actual_future_return_5d	Lợi suất thực tế sau 5 phiên
prediction_error	Sai số dự đoán
abs_error	Sai số tuyệt đối
signal	Tín hiệu suy ra từ predicted return

Tín hiệu được chia thành:

- STRONG_BUY
- BUY
- HOLD
- SELL
- STRONG_SELL

Dựa trên ngưỡng lợi suất dự đoán

i. Thiết kế Data Mart và Insight cho Model 2

Kết quả dự đoán được chuẩn hóa và lưu vào bảng mart:

mart_future_return_prediction

Bảng mart gồm các thông tin chính:

Cột	Ý nghĩa
symbol	Mã cổ phiếu
trading_date	Ngày giao dịch
close	Giá đóng cửa
volume	Khối lượng giao dịch
actual_future_return_5d	Lợi suất thực tế
predicted_future_return_5d	Lợi suất dự đoán
prediction_error	Sai số
abs_error	Sai số tuyệt đối

signal	Tín hiệu giao dịch
model_name	Tên mô hình
created_at	Thời điểm tạo dữ liệu

Thiết kế này giúp Dashboard không phải đọc file output rời rạc mà có thể truy vấn trực tiếp từ ClickHouse.

3.7.3 Model 3 – Trading Signal Classification

3.7.3.1. Tổng quan bài toán và mục tiêu

Model 3 được thiết kế nhằm phục vụ bài toán phân loại tín hiệu giao dịch chứng khoán. Đây là bài toán phân loại đa lớp có giám sát (Supervised Multi-class Classification). Mục tiêu của mô hình là dự báo tín hiệu hành động cho các mã cổ phiếu trong ngắn hạn (5 phiên giao dịch tiếp theo), chia thành 3 nhóm: **SELL** (Bán/Giảm rủi ro), **HOLD** (Nắm giữ/Chưa có lợi thế) và **BUY** (Mua). Hệ thống tập trung tối ưu hóa độ tin cậy (Precision) của các tín hiệu hành động, đóng vai trò trực tiếp hỗ trợ nhà đầu tư ra quyết định.

3.7.3.2. Dữ liệu đầu vào

Nguồn dữ liệu đầu vào của Model 3 là bảng dữ liệu dùng chung của toàn hệ thống: stock.features_all được lưu trữ trên nền tảng ClickHouse Cloud. Các trường dữ liệu thô cơ bản bao gồm:

Trường dữ liệu	Mô tả chi tiết
symbol	Mã chứng khoán
trading_date	Ngày giao dịch
open, high, low, close	Giá mở cửa, mức giá cao nhất, thấp nhất và giá đóng cửa trong ngày
volume	Khối lượng giao dịch trong ngày
created_at	Thời điểm tạo/cập nhật dữ liệu vào hệ thống

3.7.3.3. Các đặc trưng sử dụng

Từ các dữ liệu cơ bản, Model 3 tính toán và sử dụng các nhóm đặc trưng (Features) để giúp mô hình bắt được các quy luật của thị trường:

Nhóm đặc trưng	Các biến đại diện (Features)	Ý nghĩa
Động lực giá (Momentum)	return_1d, return_3d, return_5d, return_10d, return_20d	Đo lường mức độ sinh lời và đà tăng/giảm trong các khoảng thời gian quá khứ.
Xu hướng (Trend)	ma_5, ma_20, ma_50, price_vs_ma20, ma5_vs_ma20	So sánh giá hiện tại với các đường trung bình động để xác định xu hướng.
Thanh khoản (Volume)	volume_ma_5, volume_ma_20, volume_ratio_5_20, volume_change_1d	Đánh giá sự bùng nổ hoặc sụt giảm của dòng tiền so với trung bình.
Biến động (Volatility)	volatility_5d, volatility_20d, volatility_change, rolling_max_20d, drawdown_20d	Phản ánh mức độ rủi ro, dao động giá và biên độ sụt giảm từ đỉnh.
Hành vi giá (Candlestick)	daily_range, body_ratio, close_position	Phân tích cấu trúc nến trong ngày (ví dụ: lực chốt phiên, biên độ nến).

3.7.3.4. Biến mục tiêu (Target Variable)

Biến mục tiêu là nhãn phân loại giao dịch, được xây dựng dựa trên lợi suất tương lai sau 5 ngày ($\text{target_return} = \text{close}[t+5] / \text{close}[t] - 1$):

- **SELL (Lớp 0):** Khi $\text{target_return} \leq -2.5\%$
- **HOLD (Lớp 1):** Khi $-2.5\% < \text{target_return} < 2.5\%$
- **BUY (Lớp 2):** Khi $\text{target_return} \geq 2.5\%$

3.7.3.5. Thuật toán lựa chọn

Hệ thống sử dụng **XGBoost Classifier** làm mô hình chính. Đây là thuật toán Gradient Boosting dạng cây, có khả năng học tốt các quan hệ phi tuyến, phù hợp với dữ liệu

dạng bảng chứa các chỉ báo kỹ thuật, và cung cấp mức độ quan trọng của đặc trưng (Feature Importance) để có thể diễn giải quyết định của mô hình.

3.7.3.6. Thiết kế chia tập dữ liệu

Dữ liệu được phân chia theo trật tự thời gian (Time-series Split) để chống rò rỉ dữ liệu tương lai (Data Leakage):

- **Train set (70%):** Dữ liệu lịch sử đầu tiên dùng để huấn luyện.
- **Validation set (15%):** Dùng để tinh chỉnh và áp dụng *early stopping* chống quá khớp (overfitting).
- **Test set (15%):** Dữ liệu mới nhất (ví dụ: từ tháng 10/2024 đến nay) dùng để kiểm thử tính hiệu quả.

3.7.3.7. Thiết kế kiểm định mô hình

Việc đánh giá được thiết kế chặt chẽ kết hợp giữa chỉ số Machine Learning và kiểm định chiến lược đầu tư thực tế:

- **Chỉ số phân loại:** Tối ưu hóa BUY Precision và SELL Precision (đánh giá mức độ dự báo đúng khi đưa ra quyết định hành động), bên cạnh Accuracy (độ chính xác tổng thể).
- **Confusion Matrix:** Bảng ma trận nhầm lẫn để theo dõi trực tiếp số lượng dự báo sai lệch giữa các lớp.
- **Backtest Metrics:** Hệ thống tự động giả lập giao dịch để tính toán *Cumulative Return* (Lợi nhuận tích lũy), *Sharpe Ratio*, *Hit Rate* (Tỷ lệ thắng) và có tính đến chi phí giao dịch.

3.7.3.8. Thiết kế đầu ra của mô hình

Kết quả đầu ra của Model 3 không chỉ trả về một nhãn duy nhất mà bao gồm cả xác suất và bộ lọc rủi ro, cụ thể:

Trường đầu ra	Mô tả
sell_probability	Xác suất dự báo cổ phiếu sẽ giảm giá (SELL).
hold_probability	Xác suất dự báo cổ phiếu đi ngang (HOLD).
buy_probability	Xác suất dự báo cổ phiếu sẽ tăng giá (BUY).
predicted_signal	Tín hiệu gốc (nhãn có xác suất cao nhất) do mô hình dự đoán.

adjusted_signal	Tín hiệu sau lọc. Nếu xác suất P(BUY) hoặc P(SELL) không đạt ngưỡng tự tin tối thiểu (mặc định ≥ 0.60), tín hiệu sẽ tự động bị hạ cấp về HOLD để giảm rủi ro.
-----------------	---

3.7.3.9. Thiết kế Data Mart và Insight

Đầu ra của mô hình được tự động lưu trữ và tải lên cơ sở dữ liệu ClickHouse thành các bảng Data Mart phục vụ trực quan hóa lên Dashboard:

- mart_model3_trading_signals: Bảng chứa chi tiết tín hiệu (adjusted_signal, predicted_signal) và xác suất của từng mã theo từng ngày.
- mart_model3_signal_summary: Bảng tổng hợp số lượng đếm tín hiệu BUY/HOLD/SELL theo ngày và theo từng nhóm ngành.
- mart_model3_backtest_daily & mart_model3_metrics: Bảng lưu chi tiết biểu đồ đường cong sinh lời qua từng ngày và hệ thống các chỉ số đo lường hiệu suất.
- model3_daily_insights: Bảng cảnh báo insight, cung cấp danh sách Top cổ phiếu có tín hiệu BUY mạnh nhất hoặc Top rủi ro SELL lớn nhất trong phiên giao dịch hiện tại.

3.7.4 Model 4 – Benchmark Outperformance

3.7.4.1. Tổng quan bài toán và mục tiêu

Model 4 được thiết kế nhằm phục vụ bài toán dự đoán khả năng vượt trội của cổ phiếu so với mức trung bình thị trường trong ngắn hạn. Đây là bài toán phân loại nhị phân có giám sát (Supervised Binary Classification), trong đó mô hình dự đoán liệu một mã cổ phiếu có đạt lợi suất cao hơn benchmark thị trường sau 5 phiên giao dịch tiếp theo hay không.

Khái niệm **"vượt benchmark" (Outperformance)** được định nghĩa dựa trên so sánh lợi suất tương lai của từng mã cổ phiếu với mức lợi suất trung bình của toàn bộ thị trường trong cùng thời điểm. Benchmark được tính theo phương pháp **equal-weighted** — tức là trung bình cộng lợi suất tương lai 5 ngày của tất cả các mã cổ phiếu có dữ liệu trong cùng một ngày giao dịch, không phân biệt vốn hóa thị trường.

Mục tiêu chính của Model 4 là hỗ trợ nhà đầu tư xác định nhóm cổ phiếu tiềm năng có khả năng tạo ra lợi suất vượt trội so với danh mục đầu tư thị trường trung bình. Kết quả đầu ra của mô hình bao gồm nhãn phân loại (outperform / không outperform) và xác suất ước lượng tương ứng, phục vụ trực tiếp cho Dashboard phân tích và hỗ trợ ra quyết định đầu tư.

3.7.4.2. Dữ liệu đầu vào

Model 4 đọc dữ liệu trực tiếp từ Nguồn dữ liệu đầu vào: stock.stock_prices. Việc lấy từ stock_prices không khác gì so với việc lấy từ features_all do đều là cùng một nguồn dữ liệu được lưu trữ trên ClickHouse.

Dữ liệu được truy vấn thông qua câu lệnh SQL với alias tên cột:

```
SELECT symbol, date AS trading_date, open, high, low, close, volume FROM  
stock.stock_prices ORDER BY symbol, date
```

3.7.4.3. Các đặc trưng sử dụng

Model 4 sử dụng tổng cộng 23 đặc trưng, được chia thành 6 nhóm chính. Tất cả đặc trưng được tính toán trực tiếp từ dữ liệu OHLCV thô trong pipeline, không phụ thuộc vào Feature Store dùng chung:

Nhóm	Đặc trưng	Ý nghĩa
Ngành	encode_sector	Mã hóa ngành nghề của cổ phiếu (integer encoding)
Lợi suất quá khứ	return_1d, return_3d, return_5d, return_10d, return_20d	Lợi suất tích lũy theo các khung thời gian 1, 3, 5, 10, 20 ngày
Trung bình động	ma_5, ma_20, ma_50, price_vs_ma20, ma5_vs_ma20	Đường MA và vị trí giá so với xu hướng dài hạn
Biến động	volatility_5d, volatility_20d, volatility_change	Độ lệch chuẩn lợi suất và thay đổi biến động ngắn/dài hạn
Drawdown	rolling_max_20d, drawdown_20d	Đỉnh giá 20 ngày và mức sụt giảm từ đỉnh
Thanh khoản	volume_ma_5, volume_ma_20, volume_ratio_5_20, volume_change_1d	Khối lượng trung bình và tỷ lệ khối lượng ngắn/dài hạn
Cấu trúc nến	daily_range, body_ratio, close_position	Biên độ trong ngày, tỷ lệ thân nến, vị trí giá đóng cửa

Danh sách đặc trưng được khai báo tập trung trong biến `FEATURE_COLUMNS` của file `train_benchmark_model.py`, giúp việc quản lý và tái sử dụng nhất quán trong toàn bộ pipeline.

3.7.4.4. Biến mục tiêu (Target Variable)

Biến mục tiêu của Model 4 là nhãn phân loại `outperform`, được xây dựng qua hai bước:

Bước 1 — Tính lợi suất tương lai của từng mã: $\text{future_return} = (\text{close}[t+5] / \text{close}[t]) - 1$, trong đó $\text{close}[t]$ là giá đóng cửa hiện tại và $\text{close}[t+5]$ là giá đóng cửa sau 5 phiên giao dịch.

Bước 2 — Tính benchmark return: $\text{benchmark_return}[\text{ngày } t] = \text{trung bình cộng future_return của tất cả các mã cổ phiếu trong cùng ngày } t \text{ (equal-weighted)}$.

Bước 3 — Gán nhãn:

- `label = 1 (OUTPERFORM)`: $\text{future_return} > \text{benchmark_return}$ — cổ phiếu có lợi suất vượt mức trung bình thị trường.
- `label = 0 (KHÔNG OUTPERFORM)`: $\text{future_return} \leq \text{benchmark_return}$ — cổ phiếu không đạt mức trung bình.

Phân bố nhãn sau khi xử lý: **Label=1: 362.239 dòng (50,5%) — Label=0: 354.537 dòng (49,5%)**. Dữ liệu có phân bố gần cân bằng tự nhiên do cách định nghĩa benchmark — không cần xử lý imbalance.

3.7.4.5. Thuật toán lựa chọn

Model 4 sử dụng thuật toán: **LightGBM Classifier (Light Gradient Boosting Machine)**

Lý do lựa chọn LightGBM:

- Tốc độ huấn luyện nhanh trên tập dữ liệu lớn: với 693.090 dòng và 23 đặc trưng, LightGBM hoàn thành huấn luyện trong vài chục giây trên CPU — nhanh hơn đáng kể so với XGBoost.
- Phù hợp với dữ liệu bảng chứa đặc trưng số liên tục: tất cả 23 features đều là số thực, đây là điểm mạnh của LightGBM so với các thuật toán dựa trên khoảng cách.
- Không yêu cầu chuẩn hóa đặc trưng: các features có thang đo khác nhau ($\text{return_1d} \in [-0.1, 0.1]$ và $\text{volume_ma_20} \in [10^5, 10^7]$) không ảnh hưởng đến hiệu suất của mô hình cây.
- Hỗ trợ trích xuất Feature Importance: giúp giải thích tại sao mô hình đưa ra dự đoán, phục vụ phân tích và báo cáo.

Các tham số chính đang sử dụng:

- `n_estimators` = 300 (số cây boosting)
- `max_depth` = 4 (độ sâu tối đa mỗi cây)
- `learning_rate` = 0.05 (tốc độ học)
- `subsample` = 0.9 (tỷ lệ dòng dữ liệu ngẫu nhiên cho mỗi cây)
- `colsample_bytree` = 0.9 (tỷ lệ features ngẫu nhiên cho mỗi cây)
- `random_state` = 42 (seed cố định để tái tạo kết quả)

Bộ tham số trên đã được kiểm thử thực tế qua nhiều cấu hình và cho kết quả F1/Recall tốt nhất — các cấu hình phức tạp hơn (`n_estimators` lớn hơn, `max_depth` sâu hơn, thêm regularization) đều không cải thiện được F1 trên tập test, cho thấy mô hình đã đạt giới hạn tự nhiên của signal trong dữ liệu chứng khoán.

3.7.4.6. Thiết kế chia tập dữ liệu

Dữ liệu được chia theo thứ tự thời gian (Time-based Split) thay vì chia ngẫu nhiên. Đây là thiết kế bắt buộc đối với dữ liệu chuỗi thời gian tài chính nhằm tránh rò rỉ dữ liệu (Data Leakage) — mô hình chỉ được học từ dữ liệu quá khứ và kiểm thử trên dữ liệu tương lai, mô phỏng đúng bối cảnh triển khai thực tế.

Tỷ lệ và phạm vi chia:

- Train set (80%): 529.958 dòng — giai đoạn 2015-12-04 đến 2024-04-16
- Test set (20%): 163.132 dòng — giai đoạn 2024-04-17 đến 2026-06-01

Quy trình chia:

- Dữ liệu sau khi tính features và label được sắp xếp theo `trading_date` và `symbol`.
- Xác định danh sách các ngày giao dịch duy nhất, lấy 80% số ngày đầu làm tập train.
- Toàn bộ dòng dữ liệu trước cutoff date thuộc train set; từ cutoff date trở đi thuộc test set.
- Các dòng thiếu label (5 ngày cuối chưa có `future_return`) được loại bỏ trước khi chia.

3.7.4.7. Thiết kế kiểm định mô hình

Model 4 là bài toán phân loại nhị phân, do đó hệ thống sử dụng bộ 5 chỉ số đánh giá tiêu chuẩn trên tập test:

Chỉ số	Công thức	Giá trị	Ý nghĩa
--------	-----------	---------	---------

Accuracy	$(TP+TN)/Total$	57,28%	Tỷ lệ dự đoán đúng tổng thể
Precision	$TP/(TP+FP)$	56,55%	Khi dự đoán Outperform, tỷ lệ đúng thực tế
Recall	$TP/(TP+FN)$	61,20%	Tỷ lệ phát hiện đúng các trường hợp Outperform thật
F1-score	$2 \times P \times R / (P+R)$	58,78%	Điểm cân bằng giữa Precision và Recall
ROC-AUC	Diện tích dưới ROC curve	60,85%	Khả năng phân biệt 2 lớp ở mọi ngưỡng quyết định

Confusion Matrix trên tập test (163.132 dòng):

	Dự đoán: Không OP (0)	Dự đoán: Outperform (1)
Thực tế: Không OP (0)	TN = 43.748	FP = 38.185
Thực tế: Outperform (1)	FN = 31.505	TP = 49.694

Nhận xét: Trong lĩnh vực dự đoán thị trường chứng khoán, kết quả **Accuracy 57,28%** và **F1 58,78%** được xem là có giá trị thực tế. Theo lý thuyết Efficient Market Hypothesis, giá cổ phiếu phản ánh hầu hết thông tin hiện có, khiến không mô hình nào có thể đạt độ chính xác cao một cách bền vững. Các nghiên cứu học thuật về dự đoán thị trường thường công bố AUC trong khoảng 0,55–0,65 — kết quả của Model 4 (AUC = 60,85%) nằm trong vùng này và được đạt trên 163.132 điểm dữ liệu thực tế, không có data leakage.

3.7.4.8. Thiết kế đầu ra của mô hình

Kết quả đầu ra của Model 4 bao gồm các thông tin sau cho mỗi cặp (mã cổ phiếu, ngày giao dịch):

- **outperform_probability**: Xác suất liên tục từ 0 đến 1 — ước lượng khả năng cổ phiếu sẽ vượt benchmark thị trường trong 5 ngày tới. Đây là đầu ra trực tiếp của `model.predict_proba()`.
- **predicted_label**: Nhãn dự đoán nhị phân (0 hoặc 1), xác định bằng ngưỡng quyết định mặc định `threshold = 0.5`. `predicted_label = 1` nếu `outperform_probability >= 0.5`.
- **prediction_correct**: Cờ kiểm tra kết quả (1 = dự đoán đúng, 0 = sai), dùng để tính Accuracy và theo dõi hiệu suất mô hình qua các kỳ.

Kết quả được lưu ra file `benchmark_predictions.csv` và đồng thời upload lên ClickHouse Cloud thành bảng `mart_model4_benchmark_outperformance`, phục vụ Dashboard trực tiếp.

3.7.4.9. Thiết kế Data Mart và Insight cho Model 4

Kết quả dự đoán của Model 4 được chuẩn hóa thành 6 bảng Data Mart trên ClickHouse Cloud (database stock), phục vụ Dashboard theo từng góc nhìn nghiệp vụ:

- **mart_model4_benchmark_outperformance** (162.853 dòng): Bảng kết quả dự đoán chi tiết cho từng cặp (symbol, trading_date). Chứa label thực tế, predicted_label, outperform_probability, prediction_correct. Đây là bảng nguồn cho toàn bộ phân tích của Model 4.
- **mart_model4_top_outperformers** (20 dòng): Bảng top 20 cổ phiếu có xác suất outperform cao nhất trong ngày giao dịch mới nhất của tập test. Phục vụ widget "Top picks" trên Dashboard.
- **mart_model4_daily_outperform_summary** (524 dòng): Bảng tổng hợp theo từng ngày giao dịch, chứa: tổng số mã, số mã dự đoán outperform, số mã thực tế outperform, xác suất trung bình, accuracy ngày. Dùng để vẽ biểu đồ xu hướng hiệu suất mô hình theo thời gian.
- **mart_model4_sector_outperform** (19 dòng): Bảng tổng hợp theo ngành (encode_sector), phân tích khả năng outperform và accuracy của mô hình theo từng lĩnh vực kinh tế. Hỗ trợ phân tích ngành nào mô hình dự đoán tốt nhất.
- **mart_model4_metrics**: Bảng lưu lịch sử các chỉ số đánh giá (accuracy, precision, recall, f1, roc_auc) qua từng lần chạy pipeline. Không TRUNCATE — mỗi lần chạy thêm 1 dòng mới — giúp theo dõi sự thay đổi hiệu suất mô hình theo thời gian.
- **mart_model4_feature_importance** (23 dòng): Bảng chứa tầm quan trọng của từng đặc trưng (feature importance score) theo phương pháp đếm số lần feature được sử dụng làm điểm phân nhánh trong toàn bộ cây quyết định. Dùng để vẽ biểu đồ feature importance trên Dashboard và phân tích tín hiệu thị trường.

Toàn bộ 6 bảng mart trên được tạo và cập nhật tự động sau mỗi lần chạy pipeline thông qua file `create_marts.py`, được gọi tự động từ `train_benchmark_model.py` qua subprocess.

3.7.5 Model 5 – Risk Alert

3.7.5.1. Tổng quan bài toán và mục tiêu

Model 5 được thiết kế nhằm phục vụ bài toán cảnh báo rủi ro giảm giá cổ phiếu trong ngắn hạn (5 phiên giao dịch tiếp theo). Khác với các mô hình dự báo giá trực tiếp, đây là bài toán phân loại nhị phân có giám sát (Supervised Binary Classification). Mục tiêu của mô hình là dự báo xác suất một mã cổ phiếu rơi vào nhóm rủi ro cao, đóng vai trò như một hệ thống cảnh báo sớm trong tầng Data Mart và Insights.

3.7.5.2. Dữ liệu đầu vào

Nguồn dữ liệu đầu vào của Model 5 là bảng dùng chung của toàn hệ thống: **stock.features_all** Dữ liệu được lấy từ ClickHouse, chứa thông tin giá đã được làm sạch cùng các đặc trưng kỹ thuật và thông tin ngành đã được mã hóa của từng mã cổ phiếu theo từng ngày giao dịch.

3.7.5.3. Các đặc trưng sử dụng

Model 5 sử dụng các nhóm đặc trưng phản ánh ba yếu tố quan trọng về rủi ro: xu hướng giá, mức độ biến động và thanh khoản. Cụ thể:

- **Đặc trưng ngành:** encode_sector
- **Lợi suất quá khứ:** return_1d, return_3d, return_5d, return_10d, return_20d
- **Trung bình động:** ma_5, ma_20, ma_50
- **So sánh xu hướng giá:** price_vs_ma20, ma5_vs_ma20
- **Biến động:** volatility_5d, volatility_20d, volatility_change
- **Rủi ro giảm giá:** rolling_max_20d, drawdown_20d
- **Thanh khoản:** volume_ma_5, volume_ma_20, volume_ratio_5_20, volume_change_1d
- **Cấu trúc nền giá:** daily_range, body_ratio, close_position

3.7.5.4. Biến mục tiêu

Biến mục tiêu của mô hình là nhãn rủi ro: risk_drop_label. Nhãn này được xây dựng dựa trên lợi suất tương lai 5 ngày ($\text{future_return_5d} = \text{close}[t+5] / \text{close}[t] - 1$):

- risk_drop_label = 1 (cổ phiếu thuộc nhóm HIGH_RISK nếu $\text{future_return_5d} \leq -5\%$).
- risk_drop_label = 0 (cổ phiếu thuộc nhóm LOW_RISK nếu $\text{future_return_5d} > -5\%$).

3.7.5.5. Thuật toán lựa chọn

Hệ thống thiết kế áp dụng 2 thuật toán cho bài toán phân loại nhị phân này:

- **Logistic Regression:** Đóng vai trò là Baseline model (mô hình cơ sở đơn giản) để so sánh và đối chiếu.
- **XGBoost Classifier:** Là mô hình chính (Main model). Thuật toán Boosting này rất phù hợp với dữ liệu tài chính dạng bảng, xử lý tốt quan hệ phi tuyến và

có khả năng giải quyết bài toán mất cân bằng lớp (lớp rủi ro cao thường chiếm thiểu số).

3.7.5.6. Thiết kế chia tập dữ liệu

Để phù hợp với dữ liệu chuỗi thời gian của chứng khoán và tránh rò rỉ dữ liệu (Data Leakage), Model 5 thiết kế cách chia tập dữ liệu theo mốc thời gian:

- **Train set:** Sử dụng khoảng 80% dữ liệu lịch sử đầu tiên.
- **Test set:** Sử dụng khoảng 20% dữ liệu thời gian phía sau để kiểm thử.

Dữ liệu sau khi tạo nhãn được sắp xếp theo `trading_date` và `symbol`. Hệ thống sử dụng tỷ lệ chia: `train_ratio = 0.8`. Tức khoảng 80% thời gian đầu được dùng để huấn luyện, 20% thời gian sau được dùng để kiểm tra. Việc chia theo thời gian giúp mô phỏng đúng bối cảnh thực tế: mô hình được huấn luyện trên dữ liệu lịch sử và dự báo cho các giai đoạn mới hơn.

3.7.5.7. Thiết kế kiểm định mô hình

Với đặc thù là bài toán cảnh báo rủi ro có tập nhãn mất cân bằng, hệ thống không chỉ tập trung vào độ chính xác tổng thể (Accuracy) mà ưu tiên thiết kế đánh giá qua các chỉ số:

- **Recall và F1-score** cho lớp `HIGH_RISK`: Chỉ số cốt lõi đánh giá khả năng mô hình không bỏ sót các cổ phiếu thực sự rủi ro.
- **ROC-AUC và PR-AUC**.
- **Confusion Matrix**: Để theo dõi trực tiếp số lượng nhận diện đúng và bỏ sót rủi ro.

3.7.5.8. Thiết kế đầu ra của mô hình

Model 5 sinh ra các thông tin đầu ra gồm:

- `risk_probability`: Xác suất cổ phiếu thuộc nhóm rủi ro cao (giá trị liên tục từ 0 đến 1).
- `risk_label`: Nhãn cảnh báo rủi ro (`HIGH_RISK` hoặc `LOW_RISK`), được xác định thông qua một ngưỡng (thiết lập mặc định `threshold = 0.6`).

3.7.5.9. Thiết kế Data Mart và Insight cho Model 5

Dữ liệu đầu ra của mô hình được chuẩn hóa và thiết kế lưu vào bảng `mart_risk_alerts`. Cấu trúc cơ bản gồm các thông tin: `symbol`, `prediction_date`, `target_date`, `close`, `volume`, `risk_probability`, `risk_label`. Bảng Data Mart này sẽ phục vụ trực tiếp việc truy vấn Dashboard để hiện Top rủi ro hay phân tích theo ngành.

CHƯƠNG 4: XÂY DỰNG VÀ TRIỂN KHAI HỆ THỐNG

4.1 Xây dựng quy trình thu thập dữ liệu

4.1.1 Mục tiêu thu thập dữ liệu

Mục tiêu của hệ thống là xây dựng tập dữ liệu lịch sử phục vụ phân tích và dự báo thị trường chứng khoán Việt Nam.

Dữ liệu được thu thập cho khoảng 500 mã cổ phiếu thuộc nhiều nhóm ngành khác nhau trong giai đoạn từ năm 2015 đến tháng 04 năm 2026.

Các thông tin chính được thu thập gồm:

- Mã cổ phiếu.
- Ngày giao dịch.
- Giá mở cửa.
- Giá cao nhất.
- Giá thấp nhất.
- Giá đóng cửa.
- Khối lượng giao dịch.
- Tên công ty.
- Nhóm ngành.

4.1.2 Xây dựng module thu thập dữ liệu

Hệ thống sử dụng:

- Thư viện VnStocks.
- Dữ liệu từ VCI.
- Dữ liệu từ KBS.

Dữ liệu được thu thập tự động thông qua script: `main_cao_dl.py`, và lưu thành các tệp CSV theo ngày.

4.1.3 Tự động hóa thu thập dữ liệu

Hệ thống sử dụng GitHub Actions để thực hiện việc thu thập dữ liệu theo lịch

4.2 Xây dựng quy trình xử lý dữ liệu

Trong dự án, quy trình xử lý dữ liệu được thiết kế thành một pipeline tự động, bắt đầu từ dữ liệu cào hằng ngày, sau đó hợp nhất vào tập dữ liệu bản, khảo sát chất lượng, làm sạch và cuối cùng tạo ra tập dữ liệu sạch phục vụ lưu trữ vào ClickHouse cũng như huấn luyện các mô hình. Pipeline chính được điều phối trong file `main.py`, trong đó các bước xử lý dữ liệu gồm: merge dữ liệu hằng ngày, khảo sát dữ liệu, làm sạch dữ liệu, upload bảng `stock_prices`, tạo bảng đặc trưng `features_all`.

4.2.1 Merge dữ liệu hằng ngày

Dữ liệu giao dịch hằng ngày được sinh ra bởi workflow cào dữ liệu và lưu dưới dạng các file CSV có tên dạng `stock_*.csv` trong thư mục `data/dirty`. Để cập nhật dữ liệu mới vào tập dữ liệu bản tổng hợp, hệ thống sử dụng script `ingestion/merge_daily_csv_to_dirty.py`.

Quy trình merge được thực hiện như sau. Đầu tiên, hệ thống đọc file dữ liệu bản hiện tại `data/dirty/Data_500_stocks_dirty.csv` và tạo chỉ mục gồm hai thành phần: danh sách ngày đã tồn tại và cặp khóa (symbol, time). Sau đó, hệ thống duyệt qua toàn bộ các file `stock_*.csv` trong thư mục dữ liệu hằng ngày. Với mỗi file, dữ liệu được chuẩn hóa cột về cấu trúc chung gồm:

time, open, high, low, close, volume, symbol

Nếu file có trạng thái `no_data`, tức ngày đó không có phiên giao dịch hoặc không cào được dữ liệu hợp lệ, file sẽ được bỏ qua. Nếu file thiếu cột bắt buộc, hệ thống cũng không merge để tránh làm hỏng tập dữ liệu chính.

Điểm quan trọng của bước này là cơ chế chống trùng dữ liệu. File hằng ngày chỉ được merge khi ngày giao dịch trong file chưa tồn tại trong tập `dirty`. Ngoài ra, từng dòng còn được kiểm tra theo khóa (symbol, time) để tránh trường hợp cùng một mã cổ phiếu và cùng một ngày bị ghi lặp. Sau khi lọc xong, các dòng mới được sắp xếp theo time và symbol, rồi append vào cuối file `Data_500_stocks_dirty.csv`.

Bước merge này giúp pipeline có thể chạy tự động hằng ngày mà không làm trùng dữ liệu cũ. Đồng thời, nếu một ngày không có dữ liệu mới, pipeline vẫn tiếp tục chạy các bước sau mà không bị dừng.

4.2.2 Khảo sát chất lượng dữ liệu

Sau khi merge, dữ liệu bản được khảo sát bằng script `etl/xu_li_du_lieu/kiemtradl_ghiralog_extract.py`. Mục tiêu của bước này là đánh giá tổng thể chất lượng dữ liệu trước khi làm sạch, đồng thời ghi lại các lỗi để phục vụ kiểm chứng và báo cáo.

Script khảo sát đọc file `data/dirty/Data_500_stocks_dirty.csv`, sau đó kiểm tra nhiều nhóm lỗi khác nhau. Thứ nhất là kiểm tra cấu trúc dữ liệu, bao gồm số dòng, số cột, danh sách cột và kiểu dữ liệu. Thứ hai là kiểm tra giá trị thiếu trên toàn bộ các cột, kết quả được lưu tại `data/khaosatdata/missing_summary.csv` và các dòng thiếu được lưu tại `rows_with_missing.csv`.

Tiếp theo, hệ thống kiểm tra dữ liệu trùng lặp. Có hai loại trùng được khảo sát: trùng toàn bộ dòng và trùng theo khóa nghiệp vụ (symbol, time). Đây là khóa quan trọng vì mỗi mã cổ phiếu tại một ngày giao dịch chỉ nên có một bản ghi.

Bên cạnh đó, hệ thống kiểm tra tính hợp lệ của cột thời gian, mã cổ phiếu và dữ liệu số. Với mã cổ phiếu, script đối chiếu với danh sách mã hợp lệ từ file tham chiếu `data/clean/Data_500_stocks_2015-2026.csv`. Các mã bản hoặc không hợp lệ như `???`, `123`, `NULL`, `A@`, `ZZZZZZ` được phát hiện và ghi log. Với các cột giá và khối lượng, hệ thống kiểm tra giá trị không dương, volume âm, quan hệ OHLC bất hợp lệ, ví dụ `high < low`, `high < open`, hoặc `low > close`.

Theo kết quả khảo sát hiện tại, tập `dirty` có 735,638 dòng, 7 cột và 495 mã hợp lệ trong tập tham chiếu. Một số lỗi đáng chú ý gồm: 18,513 dòng có giá trị thiếu, 16,687 dòng trùng theo (symbol, time), 5,092 dòng có symbol không hợp lệ, 7,520 dòng có giá không dương, 27,135 dòng vi phạm quan hệ OHLC và 7,518 dòng có volume âm.

4.2.3 Làm sạch dữ liệu

Bước làm sạch được thực hiện bởi script `etl/xu_li_du_lieu/clean_db_ghiralog_transform.py`. File đầu vào là `data/dirty/Data_500_stocks_dirty.csv`, file tham chiếu là `data/clean/Data_500_stocks_2015-2026.csv`, và file đầu ra là: `data/clean/Data_500_stocks_clean_ver2.csv`

Quy trình làm sạch gồm nhiều bước. Đầu tiên, hệ thống chuẩn hóa tên cột, đổi time thành date nếu cần, chuẩn hóa symbol về chữ hoa, loại bỏ khoảng trắng và ép kiểu ngày bằng `pd.to_datetime`. Các cột số gồm `open`, `high`, `low`, `close`, `volume` được ép kiểu `numeric` để phát hiện các giá trị không hợp lệ.

Sau đó, hệ thống loại bỏ các dòng có ngày không hợp lệ, mã cổ phiếu không hợp lệ, mã thuộc nhóm `dirty marker` hoặc không nằm trong danh sách mã tham chiếu. Các lỗi này không bị xóa âm thầm mà được lưu lại trong thư mục `data/clean_log`, ví dụ `removed_invalid_symbol.csv`, `dirty_missing_numeric.csv`, `dirty_invalid_ohlc.csv`, `dirty_duplicate_symbol_date.csv`.

Một điểm quan trọng của quy trình làm sạch là cơ chế khôi phục dữ liệu từ file tham chiếu. Với các khóa (symbol, date) đã tồn tại trong file gốc sạch `Data_500_stocks_2015-2026.csv`, hệ thống ưu tiên lấy lại giá trị chuẩn từ file tham chiếu thay vì tin hoàn toàn vào dữ liệu bản. Điều này phù hợp vì dữ liệu `dirty` được tạo ra bằng cách cố ý làm bản từ file sạch ban đầu. Với các ngày mới phát sinh sau phạm vi của file tham chiếu, hệ thống vẫn giữ lại nếu dữ liệu thỏa mãn các quy tắc hợp lệ.

Cuối cùng, dữ liệu sau khôi phục tiếp tục được lọc lần cuối: loại dòng còn thiếu `numeric`, giá không dương, volume âm, OHLC bất hợp lệ và khóa trùng. Dữ liệu đầu ra được format lại với **date dạng thời gian chuẩn, giá làm tròn hai chữ số và volume dạng số nguyên**.

4.2.4 Kết quả dữ liệu sau xử lý

Sau khi hoàn thành xử lý, file dữ liệu sạch cuối cùng được lưu tại:

data/clean/Data_500_stocks_clean_ver2.csv

Theo log hiện tại trong data/clean_log/clean_summary.txt, dữ liệu đầu vào có 735,638 dòng. Sau quá trình chuẩn hóa, khôi phục và lọc lỗi, dữ liệu sạch đầu ra còn 718,621 dòng. Như vậy, hệ thống đã loại bỏ hoặc không đưa vào tập sạch 17,017 dòng so với dữ liệu dirty ban đầu.

Do dữ liệu cổ phiếu được cập nhật hằng ngày thông qua workflow tự động, số lượng bản ghi trong file Data_500_stocks_clean_ver2.csv không phải là một con số cố định. Và 718,621 dòng là được cập nhật đến ngày 04/06/2026. Mỗi khi hệ thống cào được dữ liệu giao dịch mới, dữ liệu sẽ được merge vào tập dirty, sau đó được khảo sát và làm sạch lại để tạo ra phiên bản clean mới. Vì vậy, các số liệu như số dòng đầu vào, số dòng bị loại bỏ, số dòng được giữ lại và số dòng đầu ra trong báo cáo chỉ phản ánh trạng thái dữ liệu tại thời điểm chạy pipeline gần nhất. Khi pipeline chạy ở các ngày tiếp theo, các con số này có thể tiếp tục thay đổi.

Một số kết quả chính:

Chỉ tiêu	Giá trị
Số dòng dirty đầu vào	735,638
Số dòng file tham chiếu	721,477
Số mã cổ phiếu hợp lệ	495
Dòng sai symbol	5,092
Dòng thiếu numeric	17,431
Dòng giá không dương	7,462
Dòng volume âm	7,459
Dòng OHLC bất hợp lệ	26,929
Dòng trùng (symbol, date)	14,990

Ô numeric được khôi phục	79,896
Dữ liệu mới ngoài reference được giữ	6,544
Số dòng sạch đầu ra	718,621

Sau bước làm sạch, file clean được upload vào ClickHouse thông qua bảng stock.stock_prices. Từ bảng này, hệ thống tiếp tục tạo bảng stock.features_all, chứa các đặc trưng dùng chung cho các mô hình như return, moving average, volatility, drawdown, volume ratio và encode_sector. Đây là tầng dữ liệu quan trọng để các mô hình trong thư mục models/ cùng sử dụng một nguồn feature thống nhất.

```

✓ Run full stock pipeline

1  ▼ Run python main.py
2  python main.py
3  shell: /usr/bin/bash -e {0}
4  env:
5    pythonLocation: /opt/hostedtoolcache/Python/3.11.15/x64
6    PKG_CONFIG_PATH: /opt/hostedtoolcache/Python/3.11.15/x64/lib/pkgconfig
7    Python_ROOT_DIR: /opt/hostedtoolcache/Python/3.11.15/x64
8    Python2_ROOT_DIR: /opt/hostedtoolcache/Python/3.11.15/x64
9    Python3_ROOT_DIR: /opt/hostedtoolcache/Python/3.11.15/x64
10   LD_LIBRARY_PATH: /opt/hostedtoolcache/Python/3.11.15/x64/lib
11   CLICKHOUSE_HOST: ***
12   CLICKHOUSE_PORT: ***
13   CLICKHOUSE_USER: ***
14   CLICKHOUSE_PASSWORD: ***
15   CLICKHOUSE_DATABASE:
16   CLICKHOUSE_SECURE:
17 [merge] Daily CSV dir: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/dirty
18 [merge] Dirty CSV: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/dirty/Data_500_stocks_dirty.csv
19 [merge] Existing dirty dates: 2,664

20 [merge] Skip stock_18_5.csv: dates already exist in dirty CSV
21 [merge] Skip stock_19_5.csv: dates already exist in dirty CSV
22 [merge] Skip stock_20_5.csv: dates already exist in dirty CSV
23 [merge] Skip stock_21_5.csv: dates already exist in dirty CSV
24 [merge] Skip stock_25_5.csv: dates already exist in dirty CSV
25 [merge] Skip stock_26_5.csv: dates already exist in dirty CSV
26 [merge] Skip stock_27_5.csv: dates already exist in dirty CSV
27 [merge] Skip stock_28_5.csv: dates already exist in dirty CSV
28 [merge] New data from stock_1_6.csv: 292 rows (2026-06-01)
29 [merge] New data from stock_2_6.csv: 301 rows (2026-06-02)
30 [merge] New data from stock_3_6.csv: 293 rows (2026-06-03)
31 [merge] Total new rows: 886
32 [merge] Appended new rows to: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/dirty/Data_500_stocks_dirty.csv
33 Saved report: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/khaosatdata/khaosat_summary.txt
34 Saved clean file: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/clean/Data_500_stocks_clean_ver2.csv
35 Saved clean logs: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/clean_log

```

```

55 Saved clean logs: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/clean_logs
56 - dirty_rows_in: 735350
57 - reference_rows: 721477
58 - reference_symbols: 495
59 - invalid_date_rows: 0
60 - invalid_symbol_rows: 5090
61 - missing_numeric_rows: 17431
62 - non_positive_price_rows: 7462
63 - negative_volume_rows: 7459
64 - invalid_ohlcv_rows: 26929
65 - duplicate_symbol_date_rows: 14990
66 - restored_numeric_cells: 79896
67 - valid_dirty_rows_after_symbol_date_filter: 730260
68 - valid_dirty_unique_keys: 722765
69 - removed_keys_not_in_reference: 0
70 - new_keys_not_in_reference_kept: 6258
71 - rows_restored_before_final_rules: 722765
72 - final_missing_numeric_rows_removed: 0
73 - final_non_positive_price_rows_removed: 21
74 - final_negative_volume_rows_removed: 0
75 - final_invalid_ohlcv_rows_removed: 4409
76 - final_duplicate_keys_removed: 0
77 - rows_out: 718335
78 - rows_removed_vs_dirty: 17015
79 - rows_missing_vs_reference: 3142
80 Connected to ClickHouse: ***:*** (Secure: True)
81 [clickhouse] Truncated table: stock.stock_prices
82 Uploaded 718335 rows to stock.stock_prices
83 Connected to ClickHouse: ***:*** (Secure: True)
84 Uploaded 500 rows to stock.stock_symbols
85
86 Uploaded 500 rows to stock.symbol_sector_encoding
87 Saved symbol encoding CSV: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/clean/symbol_sector_encoding.csv
88 Saved sector label CSV: /home/runner/work/HQTCSDL_stocks/HQTCSDL_stocks/data/clean/sector_label_encoding.csv
89 Connected to ClickHouse: ***:*** (Secure: True)
90 [clickhouse] Loading prices from stock.stock_prices
91 [features_all] Loaded prices 718,335 rows, 495 symbols
92 [features_all] Loading sector encoding from stock.symbol_sector_encoding
93 [features_all] Loaded sector encodings: 500 symbols
94 [features_all] Built common features: 718,335 rows
95 [features_all] Joined encode_sector for all feature rows.
96 [clickhouse] Recreated table: stock.features_all
97 [clickhouse] Uploaded rows 1-10,000/718,335
98 [clickhouse] Uploaded rows 10,001-20,000/718,335
99 [clickhouse] Uploaded rows 20,001-30,000/718,335
100 [clickhouse] Uploaded rows 30,001-40,000/718,335
101 [clickhouse] Uploaded rows 40,001-50,000/718,335
102 [clickhouse] Uploaded rows 50,001-60,000/718,335
103 [clickhouse] Uploaded rows 60,001-70,000/718,335
104 [clickhouse] Uploaded rows 70,001-80,000/718,335
105 [clickhouse] Uploaded rows 80,001-90,000/718,335
106 [clickhouse] Uploaded rows 90,001-100,000/718,335
107 [clickhouse] Uploaded rows 100,001-110,000/718,335

```

4.3 Xây dựng Data Warehouse trên ClickHouse

4.3.1 Kết nối với ClickHouse bằng Python

Để đảm bảo tính linh hoạt, khả năng tái sử dụng và bảo mật thông tin kết nối, hệ thống không khai báo trực tiếp các thông số truy cập cơ sở dữ liệu trong mã nguồn. Thay vào đó, các thông tin cấu hình được lưu trữ tập trung trong tệp môi trường .env đặt tại thư mục gốc của dự án.

Các thông số được quản lý bao gồm:

- Địa chỉ máy chủ ClickHouse (Host).
- Cổng kết nối (Port).

- Tên người dùng (Username).
- Mật khẩu (Password).
- Tên cơ sở dữ liệu (Database).
- Chế độ kết nối bảo mật SSL/TLS.

```
HQTCSDL_stocks >  .env
1 CLICKHOUSE_HOST=cvzq3t560s.ap-southeast-1.aws.clickhouse.cloud
2 CLICKHOUSE_PORT=8443
3 CLICKHOUSE_USER=default
4 CLICKHOUSE_PASSWORD=K5c1N_57i9pu6
5 CLICKHOUSE_DATABASE=stock
6 CLICKHOUSE_SECURE=true
```

Trong mỗi mô hình và các thành phần của hệ thống, file config.py được sử dụng để đọc các biến môi trường từ tệp .env thông qua thư viện python-dotenv. Sau khi nạp thành công các thông số cấu hình, hệ thống sử dụng thư viện clickhouse-connect để thiết lập kết nối đến ClickHouse.

```
CLICKHOUSE_HOST = os.getenv("CLICKHOUSE_HOST")
CLICKHOUSE_PORT = int(os.getenv("CLICKHOUSE_PORT") or 8443)
CLICKHOUSE_USER = os.getenv("CLICKHOUSE_USER")
CLICKHOUSE_PASSWORD = os.getenv("CLICKHOUSE_PASSWORD")
CLICKHOUSE_DATABASE = os.getenv("CLICKHOUSE_DATABASE", "stock")
CLICKHOUSE_SECURE = os.getenv("CLICKHOUSE_SECURE", "true").lower() == "true"

SOURCE_DATABASE = os.getenv("CLICKHOUSE_SOURCE_DATABASE", "stock")
SOURCE_TABLE = os.getenv("CLICKHOUSE_TABLE", "features_all")
MART_DATABASE = os.getenv("CLICKHOUSE_MART_DATABASE", "stock")
MART_TABLE = os.getenv("MODEL2_MART_TABLE", "mart_future_return_prediction")
```

Việc tập trung quản lý thông tin kết nối trong tệp .env mang lại nhiều lợi ích như:

- Tăng tính bảo mật do không lưu thông tin nhạy cảm trực tiếp trong mã nguồn.
- Dễ dàng thay đổi môi trường triển khai mà không cần chỉnh sửa chương trình.
- Cho phép các mô hình và module trong hệ thống sử dụng chung một cấu hình kết nối.
- Thuận tiện cho việc mở rộng, bảo trì và triển khai hệ thống trên nhiều môi trường khác nhau.

Sau khi kết nối thành công, các module trong hệ thống có thể thực hiện các thao tác đọc dữ liệu từ Data Warehouse, ghi kết quả dự báo, cập nhật Data Mart và phục vụ các chức năng phân tích, trực quan hóa dữ liệu.

4.3.2 Xây dựng bảng stock_prices

Bảng stock_prices là bảng dữ liệu giao dịch gốc sau khi đã được làm sạch. Đây là bảng nền tảng của Data Warehouse, được dùng để lưu dữ liệu OHLCV theo từng mã cổ phiếu và từng ngày giao dịch. Dữ liệu đầu vào của bảng này được lấy từ file:

data/clean/Data_500_stocks_clean_ver2.csv

Trong trường hợp file clean version 2 không tồn tại, hệ thống có thể fallback sang file Data_500_stocks_cleaned.csv. Việc upload dữ liệu được thực hiện trong file:

connect_clickhouse/load_prices_to_click_house.py

Trước khi upload, dữ liệu được chuẩn hóa lại một lần nữa. Cột symbol được strip khoảng trắng và chuyển về chữ hoa. Cột date được ép kiểu thời gian bằng pd.to_datetime. Các cột số gồm open, high, low, close, volume được ép kiểu numeric để đảm bảo dữ liệu đưa vào ClickHouse có kiểu phù hợp.

Schema của bảng stock.stock_prices như sau:

```
CREATE TABLE IF NOT EXISTS stock.stock_prices
(
    symbol String,
    date DateTime,
    open Float64,
    high Float64,
    low Float64,
    close Float64,
    volume Float64
)
ENGINE = MergeTree
ORDER BY (symbol, date)
```

Trong đó, symbol là mã cổ phiếu, date là ngày giao dịch, open, high, low, close lần lượt là giá mở cửa, cao nhất, thấp nhất và đóng cửa, còn volume là khối lượng giao dịch.

Bảng sử dụng engine MergeTree, phù hợp với dữ liệu dạng lớn và cần truy vấn theo thời gian. Khóa sắp xếp ORDER BY (symbol, date) giúp tối ưu các truy vấn theo mã cổ phiếu và khoảng ngày. Trước mỗi lần chạy pipeline, bảng stock_prices được truncate để đảm bảo dữ liệu trong ClickHouse phản ánh đúng phiên bản clean mới nhất, tránh tình trạng dữ liệu cũ bị lặp lại.

Trong lần chạy workflow gần nhất, hệ thống đã upload khoảng 718,949 dòng vào bảng stock.stock_prices. Tuy nhiên, con số này có thể thay đổi sau mỗi ngày vì dữ liệu mới liên tục được cào, merge và làm sạch lại.

stock_prices							
#	symbol	date	open	high	low	close	volume
1	ACM	2015-09-28 07:00:00	3.49	3.53	3.34	3.34	84100
2	BBS	2015-09-28 07:00:00	7.22	7.24	6.78	6.78	200
3	ACB	2015-09-28 07:00:00	3.13	3.16	3.06	3.06	265140
4	CDO	2015-09-28 07:00:00	13.69	13.76	13.56	13.69	1064130
5	CCR	2015-09-28 07:00:00	6	6	5.96	5.96	500
6	CTI	2015-09-28 07:00:00	11.75	11.75	11.62	11.62	4000
7	DHM	2015-09-28 07:00:00	2.46	2.46	2.29	2.38	9540
8	CSM	2015-09-28 07:00:00	13.74	13.89	13.6	13.6	116470
9	CSV	2015-09-28 07:00:00	3.96	3.96	3.92	3.92	3210
10	DBC	2015-09-28 07:00:00	4.05	4.05	4.03	4.03	28000
11	CYC	2015-09-28 07:00:00	2.96	3.25	2.96	3.25	1190
12	DGH	2015-09-28 07:00:00	4.57	4.57	4.55	4.56	50280
13	D2D	2015-09-28 07:00:00	2.98	2.98	2.89	2.89	90
14	DCL	2015-09-28 07:00:00	9.28	9.28	9.08	9.08	1010
15	DAG	2015-09-28 07:00:00	8.49	8.76	8.16	8.49	371510
16	DLG	2015-09-28 07:00:00	6.26	6.26	5.99	5.99	985730
17	DRH	2015-09-28 07:00:00	4.56	4.62	4.36	4.62	236600
18	DPR	2015-09-28 07:00:00	6.16	6.16	6.16	6.16	1000
19	DXV	2015-09-28 07:00:00	3.87	4.06	3.87	4.06	1070
20	G20	2015-09-28 07:00:00	8.92	9.12	8.88	8.96	105500
21	FDC	2015-09-28 07:00:00	18.5	18.5	17.3	18	1620
22	GSP	2015-09-28 07:00:00	4.69	4.73	4.69	4.73	1190

718,949 rows

4.3.3 Xây dựng bảng stock_symbols

Bảng stock_symbols đóng vai trò là bảng danh mục cổ phiếu. Nếu stock_prices là bảng dữ liệu giao dịch, thì stock_symbols là bảng thông tin mô tả cho từng mã cổ phiếu, bao gồm tên công ty, ngành và ngày niêm yết. Dữ liệu đầu vào của bảng này được lấy từ file:

ingestion/company_infor.csv

Quá trình xây dựng bảng được thực hiện trong file:

connect_clickhouse/load_symbols_to_clickhouse.py

File nguồn yêu cầu các cột:

symbol, company_name, sector, listed_date

Trong quá trình xử lý, hệ thống chuẩn hóa symbol về chữ hoa, chuẩn hóa company_name, xử lý giá trị rỗng ở cột sector, và ép kiểu listed_date sang dạng thời gian. Ngoài ra, hệ thống thực hiện mã hóa nhãn cho cột sector. Mỗi ngành được ánh xạ thành một số nguyên encode_sector. Ví dụ, một ngành như Industrial Goods & Services có thể được mã hóa thành một giá trị số cụ thể. Việc mã hóa này giúp các mô hình học máy có thể sử dụng thông tin ngành như một feature đầu vào.

Schema bảng stock.stock_symbols như sau:

```
CREATE TABLE stock.stock_symbols
(
    symbol String,
    company_name String,
    sector Nullable(String),
    encode_sector Nullable(Int32),
    listed_date Nullable(DateTime)
)
ENGINE = MergeTree
ORDER BY symbol
```

Ngoài bảng stock_symbols, hệ thống còn tạo thêm bảng phụ:

stock.symbol_sector_encoding

Bảng này gồm hai cột:

symbol, encode_sector

Mục đích của bảng phụ là phục vụ join nhanh giữa mã cổ phiếu và mã ngành khi tạo bảng features_all. Đồng thời, hệ thống cũng lưu hai file CSV:

data/clean/symbol_sector_encoding.csv

data/clean/sector_label_encoding.csv

Trong lần chạy gần nhất, hệ thống upload 500 dòng vào bảng stock.stock_symbols và 500 dòng vào bảng stock.symbol_sector_encoding.

Về mặt Data Warehouse, stock_symbols có thể được xem như bảng dimension, còn stock_prices là bảng fact giao dịch. Hai bảng này liên kết logic với nhau thông qua cột symbol.

stock_symbols						Create query	Insert row	Filter	Sort	Group	Refresh
#	symbol	company_name	sector	encode_sector	listed_date						
1	ABR	Công ty Cổ phần Đầu tư Nhân Hiệu Vi...	Industrial Goods & Services	0	2018-06-12 00:00:00						
2	ABT	Công ty Cổ phần Xuất nhập khẩu Thủy...	Food & Beverage	1	2006-12-25 00:00:00						
3	ACB	Ngân hàng Thương mại Cổ phần Á Châu	Banks	2	2006-11-21 00:00:00						
4	ACC	Công ty Cổ phần Đầu tư và Xây dựng ...	Construction & Materials	3	2011-06-30 00:00:00						
5	ACL	Công ty Cổ phần Xuất nhập khẩu Thủy...	Food & Beverage	1	2007-09-05 00:00:00						
6	ACM	Công ty Cổ phần Tập đoàn Khoáng sản...	Basic Resources	4	2015-07-23 00:00:00						
7	ACV	Tổng Công ty Cảng Hàng không Việt N...	Industrial Goods & Services	0	2016-11-21 00:00:00						
8	ADC	Công ty Cổ phần MI thuật và Truyền ...	Media	5	2010-12-24 00:00:00						
9	AFX	Công ty Cổ phần Xuất Nhập khẩu Nông...	Retail	6	2016-12-02 00:00:00						
10	AG1	Công ty Cổ phần 28.1	Personal & Household Goods	7	2018-01-10 00:00:00						
11	AGG	Công ty Cổ phần Đầu tư và Phát triển...	Real Estate	8	2020-01-09 00:00:00						
12	AGP	Công ty Cổ phần Dược phẩm AGIMEXPHA...	Health Care	9	2015-10-06 00:00:00						
13	AGX	Công ty Cổ phần Thực phẩm Nông sản ...	Retail	6	2015-09-14 00:00:00						
14	ALV	Công ty Cổ phần Tập đoàn MCST	Construction & Materials	3	2010-09-17 00:00:00						
15	ANT	Công ty Cổ phần Rau quả Thực phẩm A...	Food & Beverage	1	2016-12-22 00:00:00						
16	ANV	Công ty Cổ phần Nam Việt	Food & Beverage	1	2007-12-07 00:00:00						
17	APF	Công ty Cổ phần Nông sản Thực phẩm ...	Food & Beverage	1	2017-06-08 00:00:00						
18	APG	Công ty Cổ phần Chứng khoán APG	Financial Services	10	2016-11-30 00:00:00						
19	APP	Công ty Cổ phần Phát triển Phụ gia ...	Chemicals	11	2010-10-05 00:00:00						
20	ARM	Công ty Cổ phần Xuất nhập khẩu Hàng...	Industrial Goods & Services	0	2010-10-26 00:00:00						
21	ASM	Công ty Cổ phần Tập đoàn Sao Mai	Food & Beverage	1	2010-01-18 00:00:00						
22	ATS	Công ty Cổ phần Tập đoàn Đầu tư ATS	Travel & Leisure	12	2016-03-29 00:00:00						
500 rows						< 1 of 17 >					

symbol_sector_encoding			Create query	Insert row	Filter	Sort	Group	Refresh
#	symbol	encode_sector						
1	ABR	0						
2	ABT	1						
3	ACB	2						
4	ACC	3						
5	ACL	1						
6	ACM	4						
7	ACV	0						
8	ADC	5						
9	AFX	6						
10	AG1	7						
11	AGG	8						
12	AGP	9						
13	AGX	6						
14	ALV	3						
15	ANT	1						
16	ANV	1						
17	APF	1						
18	APG	10						
19	APP	11						
20	ARM	0						
21	ASM	1						
22	ATS	12						
500 rows			< 1 of 17 >					

4.3.4 Xây dựng bảng features_all

Bảng features_all là bảng đặc trưng dùng chung cho toàn bộ các mô hình trong dự án. Đây là bảng quan trọng nhất ở tầng Data Warehouse/Feature Store, vì các mô hình không đọc trực tiếp từ file CSV nữa mà lấy dữ liệu bằng câu lệnh SELECT từ bảng này trên ClickHouse.

Quy trình tạo bảng features_all được thực hiện trong file:

connect_clickhouse/features_all.py

Nguồn dữ liệu chính là bảng:

stock.stock_prices

Khi đọc dữ liệu từ stock_prices, hệ thống đổi tên cột date thành trading_date:

```
SELECT
    date AS trading_date,
    symbol,
    open,
    high,
    low,
    close,
    volume
FROM stock.stock_prices
```

Sau đó dữ liệu được chuẩn hóa theo symbol và trading_date, loại bỏ các dòng thiếu thông tin bắt buộc, đồng thời drop duplicate theo khóa (symbol, trading_date).

Từ dữ liệu OHLCV gốc, hệ thống tạo ra nhiều nhóm đặc trưng kỹ thuật.

Nhóm lợi suất gồm: **return_1d, return_3d, return_5d, return_10d, return_20d**

Nhóm trung bình động gồm: **ma_5, ma_20, ma_50**

Nhóm so sánh giá với trung bình động gồm: **price_vs_ma20, ma5_vs_ma20**

Nhóm biến động và drawdown gồm:

- **volatility_5d, volatility_20d, volatility_change,**
- **rolling_max_20d, drawdown_20d**

Nhóm khối lượng gồm:

- **volume_ma_5, volume_ma_20,**

- **volume_ratio_5_20, volume_change_1d**

Ngoài ra, bảng còn có các đặc trưng mô tả nền trong ngày:

- **daily_range**
- **body_ratio**
- **close_position**

Sau khi tạo các feature kỹ thuật, hệ thống join thêm encode_sector từ bảng stock.symbol_sector_encoding. Nhờ đó, mỗi dòng trong features_all không chỉ có dữ liệu giá và chỉ báo kỹ thuật, mà còn có thông tin ngành đã được mã hóa.

Schema chính của bảng stock.features_all gồm:

```
trading_date Date,  
symbol String,  
encode_sector Nullable(Int32),  
open, high, low, close, volume,  
return_1d, return_3d, return_5d, return_10d, return_20d,  
ma_5, ma_20, ma_50,  
price_vs_ma20, ma5_vs_ma20,  
volatility_5d, volatility_20d, volatility_change,  
rolling_max_20d, drawdown_20d,  
volume_ma_5, volume_ma_20,  
volume_ratio_5_20, volume_change_1d,  
daily_range, body_ratio, close_position,  
created_at DateTime
```

Bảng được tạo bằng engine MergeTree và sắp xếp theo:

ORDER BY (symbol, trading_date)

Trong quá trình upload, dữ liệu được insert theo chunk, mặc định 10,000 dòng mỗi lần. Cách này giúp tránh lỗi bộ nhớ khi upload bảng lớn. Sau khi upload xong lên ClickHouse, hệ thống còn export lại bảng features_all ra file:

data/clean/features_all.csv

File CSV này chủ yếu dùng để lưu bản snapshot hoặc kiểm tra lại dữ liệu, còn nguồn chính cho các mô hình vẫn là bảng stock.features_all trên ClickHouse.

Trong lần chạy workflow gần nhất, bảng features_all được tạo từ khoảng 718,949 dòng dữ liệu giá, với 495 mã cổ phiếu. Tương tự các bảng khác, số dòng này có thể thay đổi theo ngày do pipeline tự động cập nhật dữ liệu mới.

4.4 Xây dựng các mô hình dự báo - Data Mart và Insight

4.4.1 Model 1 - Price Forecasting

a. Cấu trúc triển khai

Model 1 được triển khai nhằm dự đoán **giá đóng cửa của cổ phiếu sau 5 phiên giao dịch**. Mô hình được tổ chức thành các module riêng biệt để tách rõ các bước đọc dữ liệu, tiền xử lý, huấn luyện, đánh giá và sinh Data Mart phục vụ dashboard.

File	Chức năng
Config.py	Khai báo cấu hình, danh sách feature, tham số mô hình, đường dẫn lưu model và report
Data_loader	Kết nối clickhouse và đọc dữ liệu từ bảng stock.features_all
Preprocessing.py	Tiền xử lý dữ liệu, tạo biến mục tiêu target_close chia tập train/validation/test
Evaluate.py	Đánh giá mô hình, sinh bảng dự đoán và các chỉ số sai số
backtest.py	Kiểm thử chiến lược chọn cổ phiếu dựa trên kết quả dự báo giá
marts.py	Chuẩn hóa output thành các bảng Data Mart và insight
main.py	Điều phối toàn bộ pipeline của Model 1
test.py	Ứng dụng Streamlit kiểm thử kết quả dự báo theo ngày

b. Cấu hình mô hình

Trong file config.py, Model 1 sử dụng các cấu hình chính :

- Bảng nguồn dữ liệu : stock.features_all
- Horizon dự báo : Horizon = 5
- Biến mục tiêu : target_close
- Mô hình lưu trữ : price_forecasting_xgb.pkl
- Thư mục lưu kết quả : models/model1/reports/

c. Đọc dữ liệu từ ClickHouse

Module data_loader.py thực hiện kết nối tới ClickHouse thông qua các biến môi trường trong file .env. Dữ liệu được lấy từ bảng feature store trung tâm:

```
sql
```

```
SELECT *  
FROM stock.features_all  
ORDER BY symbol, trading_date
```

Sau khi đọc dữ liệu, trường `trading_date` được chuyển về kiểu ngày tháng để phục vụ xử lý chuỗi thời gian và chia tập dữ liệu.

d. Tạo target và xử lý dữ liệu

Trong file `preprocessing.py`, dữ liệu được sắp xếp theo: `symbol`, `trading_date`.

Sau đó hệ thống nhóm dữ liệu theo từng mã cổ phiếu và tạo biến mục tiêu :

```
Target_close = close[t + 5]
```

Tại ngày giao dịch `t`, mô hình học để dự đoán **giá đóng cửa tại phiên giao dịch thứ 5 trong tương lai**.

Ngoài ra, hệ thống cũng tạo thêm `future_trading_date` để xác định ngày thực tế tương ứng với giá đóng cửa tương lai. Các dòng thiếu dữ liệu feature hoặc chưa có đủ dữ liệu tương lai để tạo `target_close` sẽ bị loại bỏ trước khi đưa vào mô hình.

e. Chia tập train / validation / test

Dữ liệu được chia theo thứ tự thời gian, không chia ngẫu nhiên, nhằm tránh rò rỉ dữ liệu tương lai vào quá trình huấn luyện.

Cấu hình hiện tại :

- Train : 70% dữ liệu đầu tiên theo thời gian
- Validation : 15% tiếp theo
- Test : 15% cuối cùng

Ở lần chạy hiện tại, hiện thống ghi nhận :

- Validation start date: 2023-03-31
- Test start date: 2024-10-24

f. Huấn luyện mô hình

Model 1 sử dụng thuật toán **XGBoost Regressor** để giải bài toán hồi quy dự đoán giá đóng cửa.

Các tham số chính :

Tham số	Giá trị
N_estimator	1000
Learning_rate	0.02
Max_depth	4
Min_child_weight	3
Subsample	0.8
Colsample_bytree	0.8
Reg_alpha	0.1
Reg_lambda	1.0
Objective	Reg: squarederror
Eval_metric	Rmse
Random_state	42

g. Dự đoán giá đóng cửa sau 5 phiên

Sau khi huấn luyện, mô hình dự đoán trên tập test và sinh ra cột : predicted_close

Đây là giá đóng cửa dự đoán 5 phiên giao dịch của từng mã cổ phiếu

Output chính :

Cột	Ý nghĩa
Trading_date	Ngày dùng để đưa dữ liệu vào mô hình
Future_trading_date	Ngày tương lai cần dự đoán
Symbol	Mã cổ phiếu
Target_close	Giá đóng cửa thực tế tại ngày tương lai
Predicted_close	Giá đóng cửa do mô hình dự đoán
Price_error	Sai lệch giữa giá dự đoán và giá thực t
Error_pct	Sai số phần trăm

h. Đánh giá mô hình

Model 1 được đánh giá bằng các chỉ số hồi quy:

Metric	Kết quả hiện tại	Ý nghĩa
MAE	1.0021	Sai số tuyệt đối trung bình
RMSE	3.4783	Căn bậc hai sai số bình phương trung bình

MAPE	4.1789%	Sai số phần trăm tuyệt đối trung bình
R ² Score	0.9766	Mức độ giải thích biến động của mô hình

i. Backtest kiểm thử chiến lược

Ngoài đánh giá sai số dự báo giá, hệ thống có thêm bước backtest để kiểm tra khả năng ứng dụng kết quả dự báo vào chiến lược chọn cổ phiếu.

File backtest.py mô phỏng việc chọn một số cổ phiếu mỗi ngày dựa trên kết quả dự báo của mô hình, đồng thời áp dụng các điều kiện lọc như:

Chỉ tiêu	Giá trị
BACKTEST_TOP_K	10
BACKTEST_MIN_VOLUME	100,000
BACKTEST_COST_RATE	0.1%
TRANSACTION_COST_RATE	0.1%
SLIPPAGE_RATE	0.1%

Các kết quả backtest gồm :

- Lợi nhuận trung bình theo ngày
- Lợi nhuận lũy kế
- Lợi nhuận sau chi phí giao dịch
- Hit Rate
- Sharpe Ratio
- So sánh với benchmark

j. Tạo Data Mart và Insight

Sau khi mô hình chạy xong, module marts.py chuẩn hóa output thành các bảng Data Mart phục vụ dashboard.

Các bảng mart hiện tại của Model 1 gồm:

Data Mart	Nội dung	Mục đích
mart_model1_price_forecast.csv	Lưu kết quả dự báo giá đóng cửa tương lai của từng mã cổ phiếu	Là bảng chính cho dashboard tra cứu giá đóng cửa dự đoán

<code>mart_model1_backtest_daily.csv</code>	Lưu kết quả backtest theo từng ngày giao dịch	Hiển thị hiệu quả kiểm thử chiến lược theo thời gian
<code>mart_model1_metrics.csv</code>	Lưu các chỉ số đánh giá mô hình và backtest ở dạng long-format	Hiển thị KPI tổng quan của Model 1
<code>model1_daily_insights.csv</code>	Lưu insight nổi bật theo ngày dự báo mới nhất	Phục vụ dashboard insight/cảnh báo nhanh

k. Dashboard kiểm thử Model 1

Model 1 có thêm file `test.py` sử dụng Streamlit để kiểm thử nhanh kết quả dự báo. Người dùng nhập hoặc chọn ngày dự báo, hệ thống sẽ trả về danh sách các mã cổ phiếu cùng giá đóng cửa dự đoán sau 5 phiên.

Dashboard kiểm thử tập trung vào output chính của Model 1: `predicted_close`

Các thông tin hiển thị gồm:

- Mã cổ phiếu
- Ngày dự báo
- Ngày mục tiêu trong tương lai
- Giá đóng cửa thực tế
- Giá đóng cửa dự đoán
- Sai số giá
- Sai số phần trăm

i. Điều phối pipeline Model 1

Toàn bộ pipeline được điều phối trong file `main.py` với luồng chạy:

1. Load data từ ClickHouse
2. Preprocessing và tạo `target_close`
3. Chia train/validation/test theo thời gian
4. Huấn luyện XGBoost Regressor
5. Dự đoán `predicted_close` trên tập test
6. Đánh giá mô hình bằng MAE, RMSE, MAPE, R^2
7. Chạy backtest kiểm thử chiến lược
8. Lưu model và các report
9. Sinh Data Mart cho dashboard
10. Sinh daily insights
11. Kiểm thử kết quả bằng Streamlit dashboard

Model 1 đóng vai trò là mô hình dự báo giá trong hệ thống, cung cấp dữ liệu đầu ra chính là **giá đóng cửa dự đoán sau 5 phiên giao dịch** cho từng mã cổ phiếu. Các bảng Data Mart được thiết kế để hỗ trợ dashboard theo dõi dự báo giá, sai số mô hình, hiệu quả backtest và insight tổng quan theo ngày.

4.4.2 Model 2 - Future Return Prediction

a. Cấu trúc triển khai

Model 2 được triển khai thành nhiều module riêng biệt nhằm tách rõ từng chức năng:

File	Chức năng
config.py	Khai báo cấu hình, feature, đường dẫn model/report
data_loader.py	Kết nối ClickHouse và đọc dữ liệu
feature_engineering.py	Tạo target và xử lý dữ liệu
train_model.py	Huấn luyện LightGBM
predict.py	Sinh kết quả dự đoán
evaluate.py	Đánh giá mô hình
backtest.py	Kiểm thử chiến lược chọn Top N
insights.py	Sinh insight từ kết quả mô hình
create_mart.py	Tạo và upload mart lên ClickHouse
main.py	Điều phối toàn bộ pipeline Model 2

b. Cấu hình mô hình

Trong file config.py, nhóm cấu hình các thông tin chính:

- SOURCE_TABLE = features_all
- TARGET_COL = future_return_5d
- MODEL_NAME = future_return_lgbm
- TEST_START_DATE = 2024-01-01

Đồng thời khai báo danh sách feature sử dụng cho mô hình, thư mục lưu model và thư mục lưu báo cáo.

c. Đọc dữ liệu từ ClickHouse

File data_loader.py thực hiện kết nối ClickHouse bằng các biến môi trường và đọc toàn bộ dữ liệu từ bảng nguồn:

```
SELECT *
```

FROM stock.features_all ORDER BY symbol, trading_date
--

Sau khi đọc dữ liệu, cột trading_date được chuyển sang kiểu ngày tháng để phục vụ chia train/test theo thời gian

d. Tạo target và xử lý dữ liệu

Trong file feature_engineering.py, dữ liệu được sắp xếp theo:
symbol, trading_date

Sau đó nhóm theo từng mã cổ phiếu để tạo target:

$$\text{future_return_5d} = \text{close}[t+5] / \text{close}[t] - 1$$

Các giá trị vô cực và dữ liệu thiếu ở feature hoặc target được loại bỏ trước khi đưa vào mô hình.

e. Chia tập train/test

Dữ liệu được chia theo mốc: 2024-01-01

Cụ thể:

- Dữ liệu trước 2024-01-01 dùng để huấn luyện.
- Dữ liệu từ 2024-01-01 trở đi dùng để kiểm thử.

Cách chia này tránh rò rỉ dữ liệu tương lai vào quá trình huấn luyện.

f. Huấn luyện mô hình

Mô hình được triển khai bằng LGBMRegressor với các tham số chính:

- n_estimators = 500
- learning_rate = 0.03
- num_leaves = 31
- subsample = 0.8
- colsample_bytree = 0.8
- random_state = 42

Sau khi huấn luyện, mô hình được lưu thành file: future_return_lgbm.pkl

g. Dự đoán lợi suất 5 phiên

Sau khi train xong, mô hình dự đoán trên tập test và sinh ra cột:

predicted_future_return_5d

Đồng thời hệ thống lưu thêm:

- actual_future_return_5d
- prediction_error
- abs_error
- signal

Tín hiệu được tạo từ predicted return theo quy tắc:

Điều kiện	Tín hiệu
-----------	----------

predicted_return >= 0.03	STRONG_BUY
predicted_return >= 0.01	BUY
-0.01 < predicted_return < 0.01	HOLD
predicted_return > -0.03	SELL
Còn lại	STRONG_SELL

h. Đánh giá mô hình

File evaluate.py đánh giá mô hình bằng các chỉ số:

Metric	Ý nghĩa
MAE	Sai số tuyệt đối trung bình
RMSE	Căn bậc hai sai số bình phương trung bình
R ² Score	Mức độ giải thích biến động của mô hình
MAPE	Sai số phần trăm tuyệt đối trung bình

Kết quả được lưu vào: metrics.json

Ngoài ra hệ thống suất:

- feature_importance.csv
- prediction_error.csv

để phục vụ phân tích sau huấn luyện

i. Backtest chiến lược

File backtest.py mô phỏng chiến lược: **Mỗi ngày chọn Top N cổ phiếu có predicted_future_return_5d cao nhất**

Sau đó tính:

Chỉ số	Ý nghĩa
avg_predicted_return	Lợi suất dự đoán trung bình của Top N
avg_actual_return	Lợi suất thực tế trung bình của Top N
win_rate	Tỷ lệ cổ phiếu có lợi nhuận dương
cumulative_return	Lợi nhuận lũy kế

Ngoài ra, hệ thống chạy nhiều cấu hình Top N = 5, 10, 20 để so sánh hiệu quả lựa chọn cổ phiếu.

j. Sinh Insights

File insights.py đọc các output:

- prediction_error.csv
- feature_importance.csv
- backtest_metrics.json

Sau đó sinh file: insights.json

Nội dung insight gồm:

- Top 10 cổ phiếu có predicted return cao nhất.
- Top 10 cổ phiếu có predicted return thấp nhất.
- Top 10 feature quan trọng nhất.
- Thống kê lợi suất dự đoán.
- Thống kê sai số.
- Kết quả backtest.

k. Tạo Data Mart trên ClickHouse

File create_mart.py tạo bảng: mart_future_return_prediction, với engine:

MergeTree ORDER BY (trading_date, symbol)
--

Sau đó dữ liệu dự đoán được insert vào bảng mart. Bảng này là nguồn dữ liệu phục vụ Dashboard và tầng Insight.

l. Điều phối pipeline Model 2

File main.py là entrypoint chính của Model 2.

Luồng chạy:

- | |
|--|
| <ol style="list-style-type: none">1. Load data2. Feature engineering3. Train/Test split4. Train model5. Predict6. Evaluate7. Export feature importance8. Export prediction error9. Backtest10. Backtest sweep11. Generate insights12. Create mart13. Dashboard |
|--|

Ngoài quy trình train/test chính, nhóm xây dựng thêm module walk-forward validation nhằm kiểm định mô hình theo chuỗi thời gian. Module này chia dữ liệu thành các cửa sổ huấn luyện và kiểm thử liên tiếp, giúp đánh giá sự ổn định của mô hình trong các giai đoạn khác nhau. Tuy nhiên, trong phiên bản triển khai hiện tại, module này chưa được tích hợp vào pipeline chính mà đóng vai trò công cụ kiểm thử mở rộng

4.4.3 Model 3 - Trading Signal Classification

4.4.3.1. Cấu trúc triển khai

Model 3 được triển khai dưới dạng các module độc lập, tách biệt rõ ràng giữa các bước xử lý dữ liệu, huấn luyện, đánh giá và sinh báo cáo.

Tên File	Chức năng chính trong Pipeline
src/config.py	Khai báo hằng số cấu hình, danh sách features, tham số XGBoost và đường dẫn lưu kết quả.
src/data_loader.py	Quản lý kết nối và truy vấn toàn bộ dữ liệu thô từ bảng stock.features_all trên ClickHouse.
src/preprocessing.py	Tiền xử lý, tạo nhãn mục tiêu (target_signal_label) và chia tập dữ liệu (Train/Val/Test).
src/train_model.py	Khởi tạo và huấn luyện thuật toán XGBoost Classifier, hỗ trợ early stopping.
src/evaluate.py	Đánh giá độ chính xác, ma trận nhầm lẫn và sinh tín hiệu đã lọc (adjusted_signal).
src/backtest.py	Kiểm thử chiến lược giao dịch Top-K dựa trên xác suất dự đoán và lọc điều kiện thanh khoản.
src/mart.py	Chuẩn hóa kết quả đầu ra thành các bảng Data Mart và tự động chất lọc file Insights.

main.py	Entrypoint (Tập điều phối chính), chạy tuần tự luồng pipeline từ đầu đến cuối.
---------	--

4.4.3.2. Cấu hình mô hình

Mọi thông số vận hành của Model 3 được tập trung tại config.py để dễ dàng tinh chỉnh mà không cần sửa code logic.

Nhóm tham số	Cấu hình	Ý nghĩa
Data Nguồn	SOURCE_TABLE = features_all	Bảng đặc trưng dùng chung chứa dữ liệu đã làm sạch.
Dự báo	HORIZON = 5	Chân trời dự báo là lợi suất 5 phiên tiếp theo.
Tỷ lệ chia	TRAIN : VAL : TEST = 0.7 : 0.15 : 0.15	Chia dữ liệu tuần tự theo thời gian để chống rò rỉ tương lai.
Mô hình	XGB_PARAMS	Dùng XGBClassifier với 1000 estimators, độ sâu 4, tối ưu mlogloss.

4.4.3.3. Đọc dữ liệu từ ClickHouse

Module data_loader.py thực hiện kết nối ClickHouse thông qua clickhouse_connect. Câu truy vấn mặc định lấy toàn bộ lịch sử:

```
sql
SELECT * FROM stock.features_all ORDER BY symbol, trading_date
```

Dữ liệu sau khi đọc sẽ được chuẩn hóa kiểu datetime để phục vụ cho việc chia tách (split) dữ liệu theo trục thời gian.

4.4.3.4. Tiền xử lý và Tạo nhãn mục tiêu

File preprocessing.py đảm nhận việc tạo biến mục tiêu (target_return). Hệ thống nhóm dữ liệu theo từng mã symbol và tính lợi suất 5 ngày tới. Từ lợi suất này, hệ thống phân thành 3 lớp (3-class classification) theo quy tắc:

Điều kiện lợi suất (target_return)	Nhãn hệ thống (Signal)	Lớp (Class ID)
target_return <= -2.5%	SELL (Rủi ro giảm giá)	0
-2.5% < target_return < 2.5%	HOLD (Vùng đi ngang/Nhiều)	1
target_return >= 2.5%	BUY (Cơ hội tăng giá)	2

Các dòng dữ liệu bị thiếu (NaN) hoặc giá trị vô cực (inf) tại các feature quan trọng đều được hệ thống tự động loại bỏ.

4.4.3.5. Đánh giá và Xử lý tín hiệu sau dự đoán

Sau khi huấn luyện XGBoost, mô hình sinh ra 3 mức xác suất: buy_probability, hold_probability, sell_probability. Trong evaluate.py, hệ thống không dùng trực tiếp nhãn có xác suất cao nhất (predicted_signal) mà áp dụng một **bộ lọc độ tự tin** để sinh ra adjusted_signal:

Tín hiệu dự đoán	Điều kiện lọc rủi ro (SIGNAL_MIN_ACTION_PROBABILITY)	Tín hiệu trả ra (adjusted_signal)
BUY	Nếu buy_probability >= 60%	BUY
BUY	Nếu buy_probability < 60%	HOLD (Hạ cấp rủi ro)
SELL	Nếu sell_probability >= 60%	SELL
SELL	Nếu sell_probability < 60%	HOLD (Hạ cấp rủi ro)

Hệ thống đánh giá mô hình bằng: Accuracy tổng thể, BUY Precision, SELL Precision, và Confusion Matrix.

4.4.3.6. Backtest kiểm thử chiến lược

File backtest.py giả lập chiến lược giao dịch mỗi ngày. Thay vì mua toàn bộ, hệ thống lọc khắt khe hơn để mô phỏng tính thực chiến:

Chỉ tiêu Backtest	Giá trị	Giải thích
-------------------	---------	------------

BACKTEST_TOP_K	5	Chỉ chọn tối đa 5 mã cổ phiếu tốt nhất mỗi ngày.
BACKTEST_MIN_BUY_PROBABILITY	0.35	Xác suất BUY tối thiểu để vào lệnh.
BACKTEST_MIN_VOLUME	100,000	Loại bỏ các mã thanh khoản thấp (dưới 100k cổ phiếu/ngày).
TRANSACTION_COST_RATE	0.1%	Tính cả phí giao dịch và độ trượt giá (Slippage) khi tính lợi nhuận.

Kết quả trả ra gồm các số liệu: Lợi nhuận lũy kế (Cumulative Return), Tỷ lệ thắng (Hit Rate), và Sharpe Ratio.

4.4.3.7. Sinh Insights (Cảnh báo thông minh)

File mart.py có hàm build_daily_insights sẽ chắt lọc các thông tin đắt giá nhất của ngày giao dịch mới nhất để sinh ra file model3_daily_insights.csv. Nội dung bao gồm:

1. Thống kê nhanh: Hôm nay có bao nhiêu tín hiệu BUY mạnh, SELL mạnh.
2. Mã cổ phiếu có buy_probability cao nhất thị trường.
3. Mã cổ phiếu rủi ro nhất (Top sell_probability).
4. Các chỉ số test model (Accuracy, Net Return của ngày).

4.4.3.8. Tạo Data Mart phục vụ Dashboard

Cuối cùng, output của Model 3 được chuẩn hóa thành các tệp Data Mart cấu trúc chuẩn, lưu vào thư mục reports/ để sẵn sàng đẩy lên ClickHouse hoặc nối thẳng vào Dashboard BI:

Tên Bảng Data Mart	Nhiệm vụ lưu trữ
mart_model3_trading_signals	Lưu tín hiệu dự đoán, adjusted_signal và 3 xác suất của từng mã.
mart_model3_signal_summary	Thống kê đếm tổng số tín hiệu theo từng Ngày và Nhóm Ngành.
mart_model3_backtest_daily	Lưu đường cong lợi nhuận (Curve) của chiến lược Backtest theo từng ngày.

mart_model3_metrics	Bảng Long-format lưu toàn bộ các chỉ số đánh giá kỹ thuật (Accuracy, F1...).
---------------------	--

4.4.3.9. Điều phối Pipeline (Luồng chạy chính)

Toàn bộ quy trình được tự động hóa trong main.py với các bước chạy tuần tự:

1. load_data()
2. preprocess_data() -> split_train_validation_test_by_time()
3. train_xgboost_model()
4. evaluate_model() -> Tính ma trận và lọc tín hiệu.
5. compute_top_k_backtest() -> run_backtest_sweep() (Quét tham số)
6. save_model() và xuất các file đánh giá.
7. save_model3_marts() -> Tạo Insight và Data Mart cuối cùng.

4.4.4 Model 4 - Benchmark Outperformance

4.4.4.1. Cấu trúc triển khai

Model 4 được triển khai dưới dạng các module độc lập, tách biệt rõ ràng giữa các bước xử lý dữ liệu, huấn luyện, đánh giá và upload kết quả lên Data Warehouse.

File	Vai trò
train_benchmark_model.py	File trung tâm: đọc dữ liệu từ ClickHouse, tính 23 features + benchmark label, train LightGBM, evaluate, lưu model .pkl và output CSV/JSON
upload_predictions.py	Đọc file benchmark_predictions.csv, chuẩn hóa kiểu dữ liệu, TRUNCATE bảng cũ và INSERT 163.132 dòng lên ClickHouse
create_marts.py	Tạo và upload 6 bảng Data Mart phục vụ Dashboard
visualize_results.py	Vẽ 4 biểu đồ kết quả: Feature Importance, Confusion Matrix, ROC Curve, Phân phối xác suất
benchmark_features.py	File phụ trợ: xuất CSV features cho team review, không thuộc pipeline chính

Điểm đặc biệt của thiết kế: toàn bộ pipeline chạy end-to-end chỉ bằng **một lệnh duy nhất**. Hàm main() trong train_benchmark_model.py tự động gọi tiếp

upload_predictions.py và create_marts.py thông qua subprocess.run() sau khi hoàn thành huấn luyện:

```
python models/model4/train_benchmark_model.py
```

4.4.4.2. Cấu hình mô hình

Các thông số vận hành của Model 4 được khai báo tập trung ở phần đầu file train_benchmark_model.py, giúp dễ dàng điều chỉnh mà không cần sửa logic xử lý:

- HORIZON = 5: số phiên giao dịch tương lai dùng để tính lợi suất và benchmark.
- TRAIN_RATIO = 0.8: tỷ lệ dữ liệu dành cho tập huấn luyện.
- DATABASE = "stock": tên database trên ClickHouse Cloud.
- MODEL_PATH: đường dẫn lưu file model — models/model4/models/benchmark_outperformance_lgbm.pkl.
- FEATURE_COLUMNS: danh sách 23 đặc trưng đầu vào, khai báo tập trung để đảm bảo nhất quán giữa train, predict và upload.

Credentials kết nối ClickHouse được đọc từ file .env ở thư mục gốc dự án thông qua thư viện python-dotenv, không hardcode trong code nguồn.

4.4.4.3. Đọc dữ liệu từ ClickHouse

Khác với các mô hình khác trong hệ thống, Model 4 **đọc dữ liệu trực tiếp từ bảng stock.stock_prices** thay vì bảng stock.features_all. Module load_stock_prices() thực hiện kết nối và truy vấn:

```
SELECT symbol, date AS trading_date, open, high, low, close, volume FROM  
stock.stock_prices ORDER BY symbol, date
```

Lý do thiết kế quan trọng: Bảng stock.features_all chứa các đặc trưng rolling window đã tính sẵn. Các dòng đầu của mỗi mã chưa đủ lịch sử sẽ có giá trị NaN. Nếu dùng bảng này để tính benchmark return (trung bình future_return của tất cả mã trong cùng ngày), các dòng NaN bị loại khiến benchmark chỉ tính trên tập con — dẫn đến giá trị benchmark sai và label bị gán không chính xác. Đọc từ stock.stock_prices đảm bảo benchmark được tính trên toàn bộ dữ liệu thô trước khi xử lý NaN.

Đồng thời, module load_sector() đọc thêm bảng stock.symbol_sector_encoding để lấy cột encode_sector — đặc trưng thứ 23 của mô hình.

Sau khi đọc về, dữ liệu gồm 719.246 dòng của 495 mã cổ phiếu, trải dài từ năm 2015 đến tháng 6/2026.

4.4.4.4. Tính benchmark và tạo nhãn mục tiêu

Hàm calc_benchmark_and_label() thực hiện 3 bước liên tiếp:

Bước 1 — Tính lợi suất tương lai từng mã: $\text{future_return} = \text{pct_change}(-\text{HORIZON}) * -1$, tức là lợi suất của mỗi cổ phiếu trong 5 phiên tiếp theo so với hiện tại.

Bước 2 — Tính benchmark return: lấy trung bình cộng (equal-weighted) của future_return của tất cả các mã trong cùng một ngày giao dịch. Đây là mức lợi suất trung bình thị trường trong ngày đó.

Bước 3 — Gán nhãn phân loại: $\text{label} = 1$ nếu $\text{future_return} > \text{benchmark_return}$ (cổ phiếu vượt trội thị trường); $\text{label} = 0$ trong trường hợp ngược lại.

Sau khi gán nhãn, encode_sector được merge vào DataFrame theo cột symbol . Các dòng thiếu future_return hoặc benchmark_return (5 ngày cuối chưa có đủ dữ liệu tương lai) được loại bỏ. Kết quả phân bố nhãn: Label=1 (Outperform): 362.239 dòng — Label=0 (Không Outperform): 354.537 dòng, gần cân bằng tự nhiên.

4.4.4.5. Chia tập train/test

Dữ liệu được chia theo trật tự thời gian (Time-based Split) để tránh rò rỉ dữ liệu tương lai vào quá trình huấn luyện — đây là yêu cầu bắt buộc với dữ liệu chuỗi thời gian tài chính.

Quy trình chia:

- Dữ liệu sau khi tính features và label được sắp xếp theo trading_date và symbol , sau đó loại bỏ các dòng còn NaN. Tổng số trainable rows: 693.090 dòng (từ 719.246 dòng gốc).
- Lấy danh sách các ngày giao dịch duy nhất, xác định ngày cutoff tại vị trí 80%.
- Toàn bộ dữ liệu trước cutoff date thuộc tập train; từ cutoff date trở đi thuộc tập test.

Tập dữ liệu	Khoảng thời gian	Số dòng	Tỷ lệ
Train set	2015-12-04 → 2024-04-16	529.958	~80%
Test set	2024-04-17 → 2026-06-01	163.132	~20%
Cutoff date	2024-04-17	—	—

4.4.4.6. Huấn luyện mô hình

Hàm $\text{train_model}()$ khởi tạo và huấn luyện **LightGBM Classifier** trên tập train với các siêu tham số đã tối ưu:

- `n_estimators = 300`: số cây boosting nối tiếp nhau.
- `max_depth = 4`: độ sâu tối đa mỗi cây, giới hạn để tránh overfitting.
- `learning_rate = 0.05`: tốc độ học tương đối nhỏ, giúp mô hình hội tụ ổn định.
- `subsample = 0.9`: lấy mẫu 90% dòng dữ liệu ngẫu nhiên cho mỗi cây, tăng tính đa dạng.
- `colsample_bytree = 0.9`: lấy mẫu 90% đặc trưng ngẫu nhiên khi xây dựng mỗi cây.
- `random_state = 42`: seed cố định để đảm bảo kết quả tái tạo được.
- `n_jobs = -1`: sử dụng toàn bộ CPU cores để tăng tốc huấn luyện.

Sau khi huấn luyện, model được lưu bằng `joblib.dump()` thành file `benchmark_outperformance_lgbm.pkl`, bao gồm: đối tượng model, danh sách `FEATURE_COLUMNS`, `HORIZON`, và metrics đánh giá — đủ thông tin để tái sử dụng ở bất kỳ đâu mà không cần train lại.

4.4.4.7. Đánh giá mô hình

Hàm `evaluate_model()` chạy dự đoán trên tập test và tính toán bộ 5 chỉ số đánh giá tiêu chuẩn cho bài toán phân loại nhị phân:

Chỉ số	Giá trị	Ý nghĩa
Accuracy	57,28%	Tỷ lệ dự đoán đúng tổng thể trên 163.132 dòng test
Precision	56,55%	Khi dự đoán Outperform, tỷ lệ đúng thực tế
Recall	61,20%	Tỷ lệ phát hiện đúng các trường hợp Outperform thật
F1-score	58,78%	Điểm cân bằng giữa Precision và Recall
ROC-AUC	60,85%	Khả năng phân biệt 2 lớp ở mọi ngưỡng quyết định

Confusion Matrix trên tập test:

- True Negative (TN) = 43.748: dự đoán đúng Không Outperform.
- False Positive (FP) = 38.185: dự đoán nhầm thành Outperform.
- False Negative (FN) = 31.505: bỏ sót Outperform thật.
- True Positive (TP) = 49.694: dự đoán đúng Outperform.

Kết quả được lưu tự động vào 3 file output: benchmark_metrics.json (toàn bộ metrics), benchmark_predictions.csv (163.132 dòng dự đoán), feature_importance.csv (điểm quan trọng của 23 features).

4.4.4.8. Upload lên ClickHouse và tạo Data Mart

Upload predictions — file upload_predictions.py: đọc file benchmark_predictions.csv, chuẩn hóa kiểu dữ liệu (datetime, float, int), thực hiện TRUNCATE bảng cũ trước khi INSERT để tránh nhân đôi dữ liệu, sau đó upload 163.132 dòng lên bảng stock.model4_benchmark_predictions.

Tạo Data Mart — file create_marts.py: đọc lại bảng predictions từ ClickHouse, tổng hợp theo các chiều phân tích khác nhau và tạo 6 bảng mart:

Bảng Mart	Số dòng	Mục đích
mart_model4_benchmark_outperformance	162.853	Bảng kết quả dự đoán chi tiết — nguồn dữ liệu chính
mart_model4_top_outperformers	20	Top 20 cổ phiếu xác suất outperform cao nhất ngày mới nhất
mart_model4_daily_outperform_summary	524	Tổng hợp theo ngày: accuracy, số mã OP dự đoán vs thực tế
mart_model4_sector_outperform	19	Tổng hợp theo 19 ngành kinh tế
mart_model4_metrics	Lịch sử	Metrics qua các lần chạy — KHÔNG TRUNCATE, giữ lịch sử
mart_model4_feature_importance	23	Tầm quan trọng của 23 đặc trưng đầu vào

Riêng bảng mart_model4_metrics được thiết kế **không TRUNCATE** trước khi INSERT — mỗi lần chạy pipeline thêm 1 dòng mới với timestamp, giúp theo dõi sự thay đổi hiệu suất mô hình qua thời gian.

4.4.4.9. Điều phối pipeline (Luồng chạy chính)

Toàn bộ quy trình được tự động hóa trong hàm main() của file train_benchmark_model.py với các bước chạy tuần tự:

- load_features(): kết nối ClickHouse, đọc stock_prices, tính benchmark + label + 22 features kỹ thuật, merge encode_sector, dropna. Xuất ra DataFrame 693.090×24 cột.

- `time_split()`: chia train/test theo thời gian với tỷ lệ 80/20, in ra thông tin cutoff date và số dòng từng tập.
- `train_model()`: khởi tạo LightGBM Classifier và huấn luyện trên tập train.
- `evaluate_model()`: tính 5 metrics + confusion matrix trên tập test, in kết quả ra màn hình.
- `save_model()`: lưu file .pkl bằng joblib, bao gồm model + metadata.
- `save_results()`: lưu benchmark_metrics.json, benchmark_predictions.csv và feature_importance.csv vào folder output/.
- `subprocess.run(upload_predictions.py)`: tự động gọi file upload, đẩy predictions lên ClickHouse.
- `subprocess.run(create_marts.py)`: tự động gọi file tạo mart, xây dựng 6 bảng Data Mart.

Thiết kế subprocess đảm bảo mỗi file vẫn có thể chạy độc lập khi cần (ví dụ: chỉ cập nhật mart mà không train lại), trong khi luồng chính vẫn chạy end-to-end hoàn toàn tự động.

4.4.5 Model 5 - Risk Alert

4.4.5.1. Cấu trúc triển khai

Tương tự cấu trúc tổng thể của hệ thống, Model 5 được triển khai độc lập về tính năng nhưng kết nối chặt chẽ trong luồng pipeline. Các module gồm xử lý đặc trưng, huấn luyện thuật toán, tính toán sai số, và đẩy lên Data Mart thông qua các scripts xử lý riêng biệt.

4.4.5.2. Cấu hình mô hình

Các thông số phục vụ quá trình dự báo rủi ro được thiết lập ở mức cấu hình:

- Bảng nguồn truy vấn: **stock.features_all**
- Tên cột target: **risk_drop_label**
- Ngưỡng cảnh báo rủi ro (Threshold) ấn định: 0.6 (Nếu `risk_probability` $\geq$ 0.6 sẽ gán nhãn HIGH_RISK).
- Tên model lưu trữ: `logistic_regression_baseline.pkl` và `xgboost_risk_alert.pkl`.

4.4.5.3. Đọc dữ liệu từ ClickHouse

Hệ thống sử dụng các biến môi trường cấu hình sẵn để thiết lập kết nối tới ClickHouse. Pipeline sẽ truy vấn lấy toàn bộ dữ liệu từ bảng nguồn `stock.features_all` và thực hiện ép kiểu ngày tháng cho trường `trading_date`.

```

query = f"""
SELECT *
FROM {quote_identifier(database)}.{quote_identifier(table)}
ORDER BY symbol, trading_date
"""

print(f"[risk_features] Loading features from ClickHouse: {database}.{table}")
normalized = normalize_features_all(client.query_df(query))
if normalized.empty:
    print("[risk_features] No features_all rows available after normalization.")
    return normalized

print(
    "[risk_features] Loaded features_all "
    f"{len(normalized):,} rows, "
    f"{normalized['symbol'].nunique():,} symbols, "
    f"{normalized['trading_date'].min().date()} -> "
    f"{normalized['trading_date'].max().date()}"
)
return normalized

```

4.4.5.4. Tạo target và xử lý dữ liệu

Tiến hành nhóm dữ liệu theo từng mã cổ phiếu (symbol). Cột `future_return_5d` được tính toán bằng cách dịch giá đóng cửa lên 5 phiên. Tiếp theo, biến mục tiêu phân loại `risk_drop_label` được gán nhãn. Quá trình này cũng sẽ loại bỏ các dòng bị khuyết thiếu đặc trưng (missing value) và những dòng ngày gần nhất chưa có đủ dữ liệu tương lai để gán nhãn

```

features = normalize_features_all(features_all_df)
if features.empty:
    print("[risk_features] No rows available to create model 5 labels.")
    for column in [
        "future_close_5d",
        "target_date",
        "future_return_5d",
        "risk_drop_label",
        "created_at",
    ]:
        if column not in features.columns:
            features[column] = pd.NA
    return features

group = features.groupby("symbol", group_keys=False)
features["future_close_5d"] = group["close"].shift(-5)
features["target_date"] = group["trading_date"].shift(-5)
features["future_return_5d"] = _safe_divide(
    features["future_close_5d"], features["close"]
) - 1
features["risk_drop_label"] = (
    features["future_return_5d"] <= RISK_DROP_THRESHOLD
).astype("Int64")
features.loc[features["future_return_5d"].isna(), "risk_drop_label"] = pd.NA
features = features.replace([np.inf, -np.inf], np.nan)
features["created_at"] = pd.Timestamp.now().floor("s")

```

4.4.5.5. Chia tập train/test

Quá trình tách dữ liệu được thực hiện chặt chẽ theo dòng thời gian thực tế với mốc phân cắt (Cutoff date) là ngày **2024-04-05**:

- Tập Train: Dữ liệu từ 2015-12-04 đến 2024-04-04 (khoảng 527.394 dòng).
- Tập Test: Dữ liệu từ 2024-04-05 đến 2026-05-14 (khoảng 162.773 dòng).

```

def _time_train_test_split(data: pd.DataFrame, train_ratio: float = 0.8,):
    unique_dates = pd.Series(data["trading_date"].unique()).sort_values().reset_index(
        drop=True
    )
    if len(unique_dates) < 10:
        print("[train] Not enough unique trading dates to split train/test by time.")
        return data.iloc[0:0].copy(), data.iloc[0:0].copy(), pd.NaT

    cutoff_index = int(len(unique_dates) * train_ratio)
    cutoff_index = min(max(cutoff_index, 1), len(unique_dates) - 1)
    cutoff_date = pd.Timestamp(unique_dates.iloc[cutoff_index])

    train_df = data[data["trading_date"] < cutoff_date].copy()
    test_df = data[data["trading_date"] >= cutoff_date].copy()

    if train_df.empty or test_df.empty:
        print("[train] Train/test split produced an empty dataset.")
        return data.iloc[0:0].copy(), data.iloc[0:0].copy(), pd.NaT

    return train_df, test_df, cutoff_date

```

4.4.5.6. Huấn luyện mô hình

Dữ liệu được đưa vào huấn luyện đồng thời 2 mô hình:

- **Logistic Regression:** Các đặc trưng đầu vào được chuẩn hóa qua StandardScaler. Tham số `class_weight="balanced"` được đưa vào để cân bằng số lượng mẫu giữa lớp Rủi ro và An toàn.

```

:
model = Pipeline(
    steps=[
        ("scaler", StandardScaler()),
        (
            "classifier",
            LogisticRegression(
                max_iter=1000,
                class_weight="balanced",
                solver="lbfgs",
                random_state=42,
            ),
        ),
    ],
)
model.fit(x_train, y_train)
return model

```

- **XGBoost Classifier:** Huấn luyện với các siêu tham số đã tối ưu gồm: `n_estimators=300`, `max_depth=4`, `learning_rate=0.05`, `subsample=0.9`, `colsample_bytree=0.9`, `objective="binary:logistic"`. Đặc biệt, dùng `scale_pos_weight` thay vì `class_weight` để nâng độ chú ý của mô hình vào lớp rủi ro cao.

```
scale_pos_weight = negative_count / positive_count if positive_count else 1.0

model = XGBClassifier(
    n_estimators=300,
    max_depth=4,
    learning_rate=0.05,
    subsample=0.9,
    colsample_bytree=0.9,
    objective="binary:logistic",
    eval_metric="logloss",
    tree_method="hist",
    scale_pos_weight=scale_pos_weight,
    random_state=42,
    n_jobs=-1,
)

model.fit(x_train, y_train)
return model
```

Trong đó:

- `n_estimators=300`: số lượng cây boosting.
- `max_depth=4`: giới hạn độ sâu của cây để giảm overfitting.
- `learning_rate=0.05`: tốc độ học tương đối nhỏ, giúp mô hình học ổn định hơn.
- `subsample=0.9`: lấy mẫu một phần dữ liệu cho mỗi vòng boosting.
- `colsample_bytree=0.9`: lấy mẫu một phần đặc trưng khi xây dựng cây.
- `objective="binary:logistic"`: phù hợp với bài toán phân loại nhị phân.
- `eval_metric="logloss"`: dùng log loss để đánh giá trong quá trình học.
- `scale_pos_weight`: cân bằng ảnh hưởng giữa lớp rủi ro cao và rủi ro thấp.

4.4.5.7. Dự đoán cảnh báo rủi ro

Sau khi huấn luyện, nếu thư viện XGBoost khả dụng, hệ thống chọn mô hình `xgboost_risk_alert` làm mô hình chính. Nếu XGBoost không khả dụng, hệ thống có thể fallback về mô hình `logistic_regression_baseline`.

Đầu ra của mô hình là xác suất thuộc lớp rủi ro cao:

`risk_probability = P(risk_drop_label = 1)`

Sau đó, hệ thống dùng ngưỡng phân loại: **`threshold = 0.6`**

Nếu: **`risk_probability >= 0.6`** thì cổ phiếu được gán nhãn: **`HIGH_RISK`**. Ngược lại cổ phiếu được gán nhãn: **`LOW_RISK`**

Như vậy, kiến trúc Model 5 gồm một baseline đơn giản để đối chiếu và một mô hình XGBoost làm mô hình chính. Cách thiết kế này giúp hệ thống vừa có khả năng đánh giá mức cải thiện so với mô hình cơ sở, vừa tận dụng được sức mạnh của thuật toán boosting cho bài toán cảnh báo rủi ro trên dữ liệu chứng khoán.

4.4.5.8. Đánh giá mô hình

Mô hình được đánh giá thông qua các metrics phân loại. Cụ thể thực nghiệm cho thấy:

Bảng kết quả:

Mô hình	Accuracy	Precision HIGH_RISK	Recall HIGH_RISK	F1 HIGH_RISK	ROC-AUC	PR-AUC
Logistic Regression	0.8261	0.3547	0.3361	0.3451	0.7226	0.2999
XGBoost Risk Alert	0.8139	0.3537	0.4410	0.3925	0.7552	0.3495

Kết quả cho thấy Logistic Regression có Accuracy cao hơn một chút, tuy nhiên XGBoost có Recall, F1-score, ROC-AUC và PR-AUC tốt hơn. Đối với bài toán cảnh báo rủi ro, khả năng phát hiện được nhiều trường hợp HIGH_RISK là quan trọng, vì vậy hệ thống lựa chọn xgboost_risk_alert làm mô hình chính.

Mã trận nhầm lẫn của mô hình XGBoost trên tập test:

	Dự đoán LOW_RISK	Dự đoán HIGH_RISK
Thực tế LOW_RISK	122,688	17,890
Thực tế HIGH_RISK	12,406	9,789

4.4.5.9. Sinh Insights

Hệ thống sử dụng file kết quả dự đoán để sinh ra các insights hữu ích nhằm đánh giá rủi ro, ví dụ như: tổng số lượng mã rơi vào rủi ro cao, Top mã cổ phiếu đang ở xác suất rủi ro lớn nhất và cảnh báo rủi ro phân theo nhóm ngành nghề.


4.4.5.10. Tạo Data Mart trên ClickHouse

Kết quả dự đoán của Model 5 sau khi xử lý sẽ được script upload_outputs_to_clickhouse.py tự động đẩy lên Data Warehouse ClickHouse. Dữ liệu được insert vào bảng **mart_risk_predictions**

mart_model5_risk_predictions							
#	prediction_date	target_date	symbol	model_name	risk_probability	risk_label	created_at
1	2025-02-18	2025-02-28	ABR	xgboost_risk_alert	0.3165056407451629	LOW_RISK	2026-06-04 09:19:28
2	2025-02-11	2025-02-24	ABR	xgboost_risk_alert	0.2517393827438354	LOW_RISK	2026-06-04 09:19:28
3	2025-02-14	2025-02-25	ABR	xgboost_risk_alert	0.3023362755775451	LOW_RISK	2026-06-04 09:19:28
4	2025-02-17	2025-02-26	ABR	xgboost_risk_alert	0.3163067278861999	LOW_RISK	2026-06-04 09:19:28
5	2025-02-19	2025-02-27	ABR	xgboost_risk_alert	0.5537281632423481	LOW_RISK	2026-06-04 09:19:28
6	2025-02-28	2025-02-28	ABR	xgboost_risk_alert	0.4522748589515686	LOW_RISK	2026-06-04 09:19:28
7	2025-02-24	2025-03-05	ABR	xgboost_risk_alert	0.2986231446266174	LOW_RISK	2026-06-04 09:19:28
8	2025-02-25	2025-03-06	ABR	xgboost_risk_alert	0.2116742926597595	LOW_RISK	2026-06-04 09:19:28
9	2025-02-26	2025-03-10	ABR	xgboost_risk_alert	0.4326636791229248	LOW_RISK	2026-06-04 09:19:28
10	2025-02-27	2025-03-13	ABR	xgboost_risk_alert	0.4230798780918121	LOW_RISK	2026-06-04 09:19:28
11	2025-02-28	2025-03-14	ABR	xgboost_risk_alert	0.5786306858862744	LOW_RISK	2026-06-04 09:19:28
12	2025-03-05	2025-03-17	ABR	xgboost_risk_alert	0.2892014648914337	LOW_RISK	2026-06-04 09:19:28
13	2025-03-06	2025-03-19	ABR	xgboost_risk_alert	0.5245124697685242	LOW_RISK	2026-06-04 09:19:28
14	2025-03-18	2025-03-20	ABR	xgboost_risk_alert	0.2386913299560547	LOW_RISK	2026-06-04 09:19:28
15	2025-03-13	2025-03-21	ABR	xgboost_risk_alert	0.343677818775177	LOW_RISK	2026-06-04 09:19:28
16	2025-03-14	2025-03-24	ABR	xgboost_risk_alert	0.3094630241394043	LOW_RISK	2026-06-04 09:19:28
17	2025-03-17	2025-03-26	ABR	xgboost_risk_alert	0.7338034510612488	HIGH_RISK	2026-06-04 09:19:28
18	2025-03-19	2025-03-27	ABR	xgboost_risk_alert	0.2223288565874099	LOW_RISK	2026-06-04 09:19:28
19	2025-03-28	2025-03-28	ABR	xgboost_risk_alert	0.3512262185941772	LOW_RISK	2026-06-04 09:19:28
20	2025-03-21	2025-03-31	ABR	xgboost_risk_alert	0.2372396298382276	LOW_RISK	2026-06-04 09:19:28
21	2025-03-24	2025-04-01	ABR	xgboost_risk_alert	0.356586754322852	LOW_RISK	2026-06-04 09:19:28
22	2025-03-26	2025-04-03	ABR	xgboost_risk_alert	0.3020735805918528	LOW_RISK	2026-06-04 09:19:28

4.5 Tự động hóa Pipeline

Toàn bộ hệ thống được điều phối bởi: main.py
Luồng xử lý:



CHƯƠNG 5: TRỰC QUAN HÓA DỮ LIỆU HỆ THỐNG

5.1 Mục tiêu trực quan hóa dữ liệu

5.1.1 Vai trò của trực quan hóa dữ liệu

Trong các hệ thống phân tích dữ liệu hiện đại, việc lưu trữ và xử lý dữ liệu chỉ là bước đầu tiên. Giá trị thực sự của dữ liệu chỉ được phát huy khi người dùng có thể tiếp cận, hiểu và khai thác thông tin một cách trực quan.

Đối với dữ liệu chứng khoán, khối lượng dữ liệu phát sinh hằng ngày rất lớn và có nhiều chiều phân tích khác nhau như:

- Giá cổ phiếu.
- Khối lượng giao dịch.
- Hiệu suất ngành.
- Tín hiệu giao dịch.
- Cảnh báo rủi ro.
- Dự báo lợi suất.

Do đó hệ thống cần xây dựng Dashboard nhằm hỗ trợ người dùng:

- Theo dõi tình hình thị trường.
- Khai thác dữ liệu nhanh chóng.
- So sánh các nhóm ngành.
- Theo dõi kết quả dự báo.
- Hỗ trợ ra quyết định đầu tư.

5.1.2 Mục tiêu của Dashboard

Dashboard được xây dựng nhằm:

- Hiển thị dữ liệu thị trường theo thời gian thực.
- Hiển thị các chỉ số quan trọng của hệ thống.
- Trực quan hóa kết quả từ các mô hình Machine Learning.
- Hiển thị các Insight sinh ra từ Data Mart.
- Hỗ trợ người dùng tra cứu và phân tích dữ liệu.

5.2 Kiến trúc Dashboard

5.2.1 Kiến trúc tổng thể

Dashboard của dự án được xây dựng bằng framework Streamlit, triển khai trong file:

main_web.py

Mục tiêu của dashboard là cung cấp một giao diện trực quan để người dùng có thể theo dõi dữ liệu chứng khoán, kiểm tra chất lượng dữ liệu, xem các bảng Data Mart, khai thác insight và chạy thử một số mô hình dự đoán. Dashboard không đọc trực tiếp

dữ liệu từ file CSV cho các chức năng chính, mà kết nối đến ClickHouse để truy vấn dữ liệu đã được xử lý và lưu trữ trong Data Warehouse.

Kiến trúc tổng thể của dashboard gồm 4 tầng chính:

ClickHouse Database



main_web.py: query + xử lý dữ liệu



Streamlit UI components



Người dùng xem dashboard / chọn symbol / lọc ngày / chạy dự đoán

Ở tầng dữ liệu, dashboard kết nối đến ClickHouse thông qua thư viện `clickhouse_connect`. Các thông tin kết nối như `CLICKHOUSE_HOST`, `CLICKHOUSE_USER`, `CLICKHOUSE_PASSWORD`, `CLICKHOUSE_PORT`, `CLICKHOUSE_SECURE` được lấy từ file `.env` hoặc biến môi trường. Điều này giúp tránh hardcode thông tin nhạy cảm trong source code.

Các bảng dữ liệu chính được dashboard sử dụng gồm:

- **stock.stock_prices**
- **stock.stock_symbols**
- **stock.features_all**

Trong đó, `stock_prices` là bảng dữ liệu giá sau làm sạch, `stock_symbols` là bảng danh mục mã cổ phiếu và ngành, còn `features_all` là bảng feature engineering dùng chung cho các mô hình.

Bên cạnh các bảng Data Warehouse, dashboard còn quét thêm các bảng Data Mart như:

- **stock_mart.***
- **stock_mart_model5_risk_prediction.***

Các bảng mart này dùng để hiển thị kết quả đầu ra của các mô hình, ví dụ dự báo giá, dự báo lợi suất, tín hiệu giao dịch, benchmark outperform và cảnh báo rủi ro.

Về mặt cấu trúc chương trình, `main_web.py` được chia thành các nhóm hàm chính. Nhóm đầu tiên là nhóm cấu hình và helper, gồm các hàm kết nối ClickHouse, tạo tên bảng an toàn, chạy query và lấy danh sách cột. Ví dụ:

- **get_clickhouse_client()**
- **run_query()**
- **get_table_columns()**

- **full_table_name()**
- **sql_string()**

Nhóm thứ hai là các hàm tải mô hình đã huấn luyện bằng joblib, gồm Model 1, Model 2 và Model 3. Các mô hình này được lấy từ thư mục models/modelX/models, sau đó dùng để dự đoán trực tiếp trên dữ liệu feature lấy từ bảng features_all.

Nhóm thứ ba là các hàm render giao diện. Mỗi chức năng lớn của dashboard được tách thành một hàm riêng:

- **render_overview_page()**
- **render_stock_lookup_page()**
- **render_feature_engineering_page()**
- **render_data_mart_page()**
- **render_prediction_models_page()**
- **render_insight_page()**
- **render_data_quality_page()**

Cuối cùng, hàm main() điều khiển điều hướng bằng sidebar của Streamlit. Người dùng có thể chọn một trong các trang: Tổng quan Dashboard, Tra cứu dữ liệu cổ phiếu, Feature Engineering, Data Mart, Mô hình dự đoán, Insight và Chất lượng dữ liệu.

Nhìn tổng thể, dashboard được thiết kế theo hướng tách rõ nguồn dữ liệu, xử lý truy vấn và giao diện hiển thị. Nhờ đó, khi dữ liệu trong ClickHouse được pipeline cập nhật hằng ngày, dashboard có thể tự phản ánh trạng thái mới nhất mà không cần chỉnh sửa thủ công.


Chức năng

- ☐ 1. Tổng quan Dashboard
- ☐ 2. Tra cứu dữ liệu cổ phiếu
- ☐ 3. Feature Engineering
- ☐ 4. Data Mart
- ☒ 5. Mô hình dự đoán
- ☐ 6. Insight
- ☐ 7. Chất lượng dữ liệu

5.2.2 Luồng dữ liệu Dashboard

Luồng dữ liệu của dashboard bắt đầu từ pipeline xử lý dữ liệu. Sau khi dữ liệu được cào, merge, khảo sát, làm sạch và upload vào ClickHouse, dashboard sẽ truy vấn trực tiếp các bảng trong ClickHouse để hiển thị lên giao diện.

Luồng dữ liệu tổng quát như sau:



Ở trang **Tổng quan Dashboard**, hệ thống truy vấn bảng `stock.stock_prices` để lấy tổng số bản ghi, số mã cổ phiếu, ngày đầu, ngày cuối và dữ liệu thanh khoản. Đồng thời, dashboard truy vấn `stock.stock_symbols` để tính số ngành và truy vấn `stock.features_all` để lấy số lượng bản ghi feature. Kết quả được hiển thị dưới dạng

metric card, bảng tóm tắt, biểu đồ giá trung bình, biểu đồ volume và top cổ phiếu theo thanh khoản.

Ở trang **Tra cứu dữ liệu cổ phiếu**, dashboard lấy danh sách mã từ bảng stock.stock_prices, cho phép người dùng chọn một hoặc nhiều symbol, chọn khoảng ngày, sau đó truy vấn dữ liệu OHLCV tương ứng. Dữ liệu trả về được hiển thị dưới dạng bảng, biểu đồ giá đóng cửa và biểu đồ khối lượng giao dịch. Nếu chỉ chọn một mã cổ phiếu, hệ thống hiển thị thêm bảng OHLC preview gần nhất.

Ở trang **Feature Engineering**, dashboard truy vấn bảng stock.features_all. Người dùng có thể chọn symbol và khoảng ngày để xem toàn bộ các đặc trưng đã được tạo như return_5d, ma_20, volatility_20d, drawdown_20d, volume_ratio_5_20, encode_sector. Ngoài bảng dữ liệu, dashboard còn vẽ biểu đồ giá đóng cửa so với các đường MA và biểu đồ return/volatility để người dùng hiểu rõ hơn về đặc trưng đầu vào của mô hình.

Ở trang **Data Mart**, dashboard không cố định danh sách bảng mà truy vấn system.tables của ClickHouse để lấy danh sách các bảng mart hiện có. Hệ thống ưu tiên 5 mart quan trọng nhất, mỗi mart tương ứng với một model chính. Ví dụ:

- mart_model1_price_forecast
- mart_model2_future_return
- mart_model3_trading_signals
- mart_model4_benchmark_outperformance
- mart_model5_risk_alerts

Người dùng có thể chọn một bảng mart, xem schema, chọn symbol, chọn ngày có dữ liệu thật trong mart, sau đó dashboard sinh insight trực tiếp từ bảng mart đó. Phần insight được tạo bằng cách tổng hợp số dòng, số symbol, ngày mới nhất/cũ nhất, phân bố label hoặc tín hiệu, cùng thống kê các chỉ số quan trọng như risk_probability, predicted_return, buy_probability, sell_probability. Bên dưới insight, dashboard hiển thị luôn bảng preview được truy vấn từ ClickHouse và SQL đang chạy.

Ở trang **Mô hình dự đoán**, dashboard cho phép chạy thử các mô hình đã huấn luyện. Với Model 1, hệ thống lấy một dòng feature từ features_all, nạp model dự báo giá/lợi suất và trả về predicted return, predicted close và xu hướng. Với Model 2, dashboard dùng danh sách feature cố định, nạp mô hình LightGBM và dự đoán future_return_5d. Với Model 3, dashboard nạp model phân loại tín hiệu giao dịch và trả về xác suất SELL/HOLD/BUY, sau đó áp dụng ngưỡng confidence để sinh tín hiệu điều chỉnh.

Ở trang **Insight**, dashboard sinh các phân tích nhanh từ features_all theo ngày được chọn. Các insight gồm top cổ phiếu tăng mạnh theo return_5d, top cổ phiếu giảm mạnh, ngành có hiệu suất tốt nhất, cổ phiếu biến động mạnh nhất và cổ phiếu có thanh

khoản cao nhất. Các insight này được tính trực tiếp bằng SQL trên ClickHouse, sau đó hiển thị bằng bảng và biểu đồ.

Ở trang **Chất lượng dữ liệu**, dashboard kiểm tra lại bảng stock.stock_prices trên ClickHouse. Các chỉ số gồm tổng số dòng, số mã, ngày đầu, ngày cuối, số dòng có giá không dương, volume âm, quan hệ OHLC bất hợp lệ và số dòng trùng (symbol, date). Ngoài ra, dashboard còn đọc thêm các file log clean_summary.txt và khaosat_summary.txt để người dùng có thể đối chiếu giữa kết quả ETL và dữ liệu đã upload.

Nhờ luồng dữ liệu này, dashboard vừa đóng vai trò là giao diện giám sát Data Warehouse, vừa là công cụ khai thác kết quả mô hình. Khi pipeline tự động cập nhật dữ liệu mới lên ClickHouse, các trang dashboard sẽ truy vấn lại dữ liệu mới và phản ánh trạng thái hiện tại của hệ thống.

5.3. Các chức năng chính của Dashboard

5.3.1. Tổng quan dashboard

Chức năng Tổng quan Dashboard cung cấp cái nhìn nhanh về quy mô và trạng thái hiện tại của dữ liệu trong hệ thống. Trang này lấy dữ liệu trực tiếp từ các bảng chính trong ClickHouse, gồm stock.stock_prices, stock.stock_symbols và stock.features_all.

Dashboard truy vấn bảng stock_prices để tính tổng số bản ghi giá, số lượng mã cổ phiếu, ngày giao dịch đầu tiên và ngày giao dịch mới nhất. Đồng thời, hệ thống truy vấn stock_symbols để thống kê số lượng ngành, và truy vấn features_all để biết số lượng bản ghi feature đã được tạo.

Các thông tin chính được hiển thị dưới dạng metric card, gồm: tổng số mã cổ phiếu, tổng số bản ghi giá, tổng số bản ghi feature, số ngành và ngày cập nhật mới nhất. Ngoài ra, trang còn hiển thị biểu đồ thanh khoản và giá trung bình gần đây, giúp người dùng quan sát xu hướng thị trường tổng quát. Phần cuối trang hiển thị top cổ phiếu có volume cao nhất trong phiên mới nhất.

Ý nghĩa của chức năng này là giúp người dùng kiểm tra nhanh dữ liệu đã được cập nhật tới ngày nào, dữ liệu có bao nhiêu mã cổ phiếu và quy mô hiện tại của hệ thống.

5.3.2. Tra Cứu Dữ Liệu Cổ Phiếu

Chức năng Tra cứu dữ liệu cổ phiếu cho phép người dùng xem dữ liệu OHLCV của từng mã cổ phiếu theo khoảng thời gian tùy chọn. Nguồn dữ liệu chính của trang này là bảng stock.stock_prices.

Người dùng có thể chọn một hoặc nhiều mã cổ phiếu, chọn khoảng ngày và giới hạn số dòng cần hiển thị. Sau khi chọn bộ lọc, dashboard sinh câu truy vấn SQL đến ClickHouse để lấy các cột:

trading_date, symbol, open, high, low, close, volume

Dữ liệu trả về được hiển thị dưới dạng bảng chi tiết. Bên cạnh đó, dashboard tạo biểu đồ đường cho giá đóng cửa và biểu đồ cột cho khối lượng giao dịch. Nếu người dùng chỉ chọn một mã cổ phiếu, hệ thống hiển thị thêm bảng OHLC preview gồm các phiên gần nhất.

Chức năng này giúp kiểm tra trực tiếp dữ liệu giá sau quá trình ETL và upload lên ClickHouse. Đây cũng là công cụ hữu ích để đối chiếu dữ liệu gốc trước khi phân tích feature hoặc chạy mô hình.

5.3.3. Feature Engineering

Chức năng Feature Engineering dùng để hiển thị và kiểm tra các đặc trưng đã được tạo trong bảng stock.features_all. Đây là bảng feature store dùng chung cho các mô hình trong dự án.

Ở đầu trang, dashboard trình bày danh sách ý nghĩa của các feature như return_1d, return_5d, ma_20, volatility_20d, drawdown_20d, volume_ratio_5_20, close_position và encode_sector. Sau đó, người dùng có thể chọn symbol, khoảng ngày và số dòng giới hạn để truy vấn dữ liệu feature từ ClickHouse.

Kết quả trả về được hiển thị thành bảng đầy đủ. Dashboard tiếp tục trực quan hóa một số nhóm feature quan trọng. Nhóm thứ nhất là biểu đồ giá đóng cửa so với các đường trung bình động như ma_5, ma_20, ma_50. Nhóm thứ hai là biểu đồ return và volatility, ví dụ return_5d, return_20d, volatility_5d, volatility_20d.

Ý nghĩa của chức năng này là giúp người dùng hiểu dữ liệu đầu vào của mô hình, kiểm tra feature có được tạo đúng không và quan sát biến động kỹ thuật của từng mã cổ phiếu.

5.3.4. Data Mart

Chức năng Data Mart dùng để hiển thị các bảng đầu ra phục vụ phân tích và báo cáo. Khác với các trang cố định bảng dữ liệu, trang Data Mart truy vấn trực tiếp system.tables của ClickHouse để lấy danh sách các bảng mart hiện có.

Dashboard quét các database như stock, stock_mart và stock_mart_model5_risk_prediction, sau đó lọc ra các bảng mart. Hệ thống ưu tiên 5 mart trọng tâm, tương ứng với 5 mô hình chính:

- mart_model1_price_forecast
- mart_model2_future_return
- mart_model3_trading_signals
- mart_model4_benchmark_outperformance
- mart_model5_risk_alerts

Người dùng có thể chọn một mart bất kỳ để xem schema, chọn symbol nếu bảng có cột symbol, chọn ngày có dữ liệu thật trong mart và giới hạn số dòng preview. Sau đó, dashboard sinh insight trực tiếp từ mart đã chọn, gồm: số dòng đang phân tích, số symbol, ngày mới nhất/cũ nhất, phân bố label hoặc tín hiệu, thống kê các chỉ số như risk_probability, predicted_return, buy_probability, sell_probability.

Bên dưới phần insight, dashboard hiển thị câu SQL đang chạy và bảng preview lấy trực tiếp từ ClickHouse. Chức năng này giúp biến output của mô hình thành các bảng phân tích có thể xem, lọc và giải thích được.

5.3.5. Mô hình dự đoán

Chức năng Mô hình dự đoán cho phép người dùng chạy thử các mô hình đã huấn luyện ngay trên giao diện dashboard. Dashboard hiện hỗ trợ chạy inference cho Model 1, Model 2 và Model 3.

Với Model 1, hệ thống tải model từ file .pkl, lấy một dòng feature tương ứng với symbol và ngày giao dịch trong bảng features_all, sau đó dự đoán return hoặc giá tương lai. Kết quả hiển thị gồm close hiện tại, return dự đoán, giá đóng cửa dự đoán và xu hướng tăng/giảm. Kết quả dự đoán từ Streamlit còn được ghi lại vào file log trong thư mục report của model1.

Với Model 2, dashboard sử dụng danh sách feature cố định, lấy dữ liệu từ features_all, nạp mô hình LightGBM và dự đoán future_return_5d. Sau đó hệ thống suy ra nhãn nhận định như BUY, HOLD hoặc SELL dựa trên giá trị return dự đoán.

Với Model 3, dashboard nạp mô hình phân loại tín hiệu giao dịch BUY/HOLD/SELL. Người dùng có thể chọn một symbol hoặc tất cả symbol tại một ngày giao dịch. Mô hình trả về xác suất cho từng lớp SELL, HOLD, BUY và dashboard áp dụng ngưỡng confidence để tạo tín hiệu điều chỉnh.

Chức năng này có ý nghĩa như một màn hình demo inference, giúp người dùng kiểm tra mô hình hoạt động trên dữ liệu mới nhất trong ClickHouse.

5.3.6. Insights

Chức năng Insight sinh các nhận định nhanh từ bảng features_all theo ngày giao dịch được chọn. Mục tiêu của trang này là chuyển dữ liệu feature thành các thông tin dễ hiểu hơn cho người dùng cuối.

Người dùng chọn một ngày có dữ liệu trong features_all. Sau đó dashboard chạy nhiều truy vấn SQL để tìm ra các nhóm thông tin đáng chú ý. Các insight chính gồm: top cổ phiếu tăng mạnh nhất theo return_5d, top cổ phiếu giảm mạnh nhất, cổ phiếu có thanh khoản cao nhất, cổ phiếu biến động mạnh nhất và ngành có hiệu suất trung bình tốt nhất.

Để tính hiệu suất theo ngành, dashboard join bảng `features_all` với bảng `stock_symbols` thông qua cột `symbol`. Nhờ đó, hệ thống có thể nhóm dữ liệu theo sector và tính `avg_return_5d`.

Kết quả insight được hiển thị dưới dạng bảng tổng hợp và biểu đồ. Người dùng có thể nhanh chóng nhận biết nhóm cổ phiếu đang tăng/giảm mạnh, ngành nào đang có hiệu suất tốt, hoặc mã nào có biến động đáng chú ý.

5.3.7. Chất lượng dữ liệu

Chức năng Chất lượng dữ liệu dùng để giám sát dữ liệu sau khi đã được upload lên ClickHouse. Nguồn dữ liệu chính là bảng `stock.stock_prices`, kết hợp với các file log sinh ra trong quá trình khảo sát và làm sạch dữ liệu.

Dashboard truy vấn `stock_prices` để tính các chỉ số chất lượng như: tổng số dòng, số mã cổ phiếu, ngày đầu tiên, ngày cuối cùng, số dòng có giá không dương, số dòng có volume âm, số dòng vi phạm quan hệ OHLC và số dòng trùng theo khóa (`symbol`, `date`).

Các chỉ số này được hiển thị bằng metric card để người dùng dễ quan sát. Nếu dữ liệu sau làm sạch tốt, các lỗi như giá không dương, volume âm hoặc OHLC sai nên bằng 0 hoặc rất thấp. Ngoài ra, dashboard còn đọc và hiển thị nội dung hai file log:

- `data/clean_log/clean_summary.txt`
- `data/khaosatdata/khaosat_summary.txt`

Nhờ vậy, người dùng có thể đối chiếu giữa kết quả kiểm tra trên ClickHouse và log xử lý dữ liệu trong pipeline ETL. Chức năng này giúp tăng tính minh bạch của hệ thống và hỗ trợ phát hiện lỗi dữ liệu sau mỗi lần pipeline tự động chạy.

CHƯƠNG 6: ĐÁNH GIÁ KẾT QUẢ, ĐỀ XUẤT QUYẾT ĐỊNH

6.1 Đánh giá chất lượng dữ liệu

6.1.1 Đánh giá dữ liệu trước khi làm sạch

Trước khi làm sạch, hệ thống thực hiện khảo sát chất lượng dữ liệu bằng file `etl/xu_li_du_lieu/kiemtradl_ghiralog_extract.py`. Dữ liệu đầu vào là file `dirty data/dirty/Data_500_stocks_dirty.csv`, gồm 735.638 dòng và 7 cột: `time`, `open`, `high`, `low`, `close`, `volume`, `symbol`. Đây là dữ liệu đã được làm bản có chủ đích từ tập dữ liệu gốc, đồng thời có thể được cập nhật thêm theo ngày từ pipeline cào dữ liệu.

Kết quả khảo sát cho thấy cấu trúc cột đầy đủ, không thiếu cột kỳ vọng. Kiểu dữ liệu cơ bản hợp lệ, trong đó `time` và `symbol` ở dạng chuỗi, các cột giá và khối lượng ở dạng số. Tuy nhiên, chất lượng dữ liệu trước làm sạch tồn tại nhiều vấn đề cần xử lý. Cụ thể, có 18.513 dòng chứa giá trị khuyết thiếu ở ít nhất một trường. Về trùng lặp, có 14.100 dòng trùng hoàn toàn và 16.687 dòng trùng theo khóa `symbol + time`, điều này có thể gây sai lệch khi tính toán chuỗi thời gian và feature kỹ thuật.

Đối với cột thời gian, hệ thống không phát hiện giá trị thời gian không hợp lệ; khoảng thời gian dữ liệu trải từ 28/09/2015 đến 04/06/2026. Tuy nhiên, cột mã cổ phiếu có vấn đề đáng kể: có 5.092 dòng chứa mã không hợp lệ, trong đó 3.075 dòng sai định dạng, 4.042 dòng là marker bản đã được tạo có chủ đích, và 5.092 dòng nằm ngoài danh sách mã tham chiếu hợp lệ. Đây là nguyên nhân khiến một số mã như `ZZZZZZ` cần bị loại bỏ hoàn toàn trước khi đưa dữ liệu vào Data Warehouse.

Ngoài ra, dữ liệu giá và khối lượng cũng có nhiều lỗi nghiệp vụ. Hệ thống ghi nhận 7.520 dòng có giá không dương, 27.135 dòng vi phạm quan hệ OHLC, ví dụ `high < low`, `high < open`, `low > close`,... và 7.518 dòng có volume âm. Các lỗi này nếu không xử lý sẽ ảnh hưởng trực tiếp đến các chỉ báo kỹ thuật như `return`, `moving average`, `volatility`, `drawdown` và các mô hình dự đoán.

Log làm sạch dữ liệu

```
clean_summary
input_path: F:\Documents\CODE\Python\cv_project\stock\HQTCS DL_stocks\data\dirty\Data_500_stocks_dirty.csv
reference_path: F:\Documents\CODE\Python\cv_project\stock\HQTCS DL_stocks\data\clean\Data_500_stocks_2015-2026.csv
output_path: F:\Documents\CODE\Python\cv_project\stock\HQTCS DL_stocks\data\clean\Data_500_stocks_clean_ver2.csv
dirty_rows_in: 735638
reference_rows: 721477
reference_symbols: 495
invalid_date_rows: 0
invalid_symbol_rows: 5092
missing_numeric_rows: 17431
non_positive_price_rows: 7462
negative_volume_rows: 7459
invalid_ohlc_rows: 26929
duplicate_symbol_date_rows: 14990
restored_numeric_cells: 79896
valid_dirty_rows_after_symbol_date_filter: 730546
valid_dirty_unique_keys: 723051
removed_keys_not_in_reference: 0
new_keys_not_in_reference_kept: 6544
rows_restored_before_final_rules: 723051
final_missing_numeric_rows_removed: 0
final_non_positive_price_rows_removed: 21
final_negative_volume_rows_removed: 0
final_invalid_ohlc_rows_removed: 4409
```

Kết quả khảo sát được lưu tại thư mục data/khaosatdata, gồm các file như missing_summary.csv, rows_with_missing.csv, duplicate_symbol_time.csv, invalid_symbol.csv, invalid_ohlc_rows.csv, negative_volume.csv và outlier_summary.csv. Các file này đóng vai trò bằng chứng kiểm tra chất lượng dữ liệu trước xử lý.

Nhóm lỗi	Số dòng trước làm sạch
Missing values	18.513
Duplicate full rows	14.100
Duplicate symbol-time	16.687
Invalid symbol	5.092
Non-positive prices	7.520
Invalid OHLC	27.135
Negative volume	7.518

6.1.2 Kết quả sau khi làm sạch

Sau bước khảo sát, dữ liệu được làm sạch bằng file `etl/xu_li_du_lieu/clean_db_ghiralog_transform.py`. File đầu vào là `data/dirty/Data_500_stocks_dirty.csv`, file tham chiếu là `data/clean/Data_500_stocks_2015-2026.csv`, và file đầu ra sau làm sạch là `data/clean/Data_500_stocks_clean_ver2.csv`.

Quá trình làm sạch bao gồm chuẩn hóa khóa `symbol + date`, chuyển đổi các cột số về đúng kiểu dữ liệu, loại bỏ mã cổ phiếu không hợp lệ, loại bỏ bản ghi sai ngày, xử lý trùng lặp, khôi phục các ô số bị bỏ trống dựa trên file tham chiếu sạch, sau đó kiểm tra lại các ràng buộc nghiệp vụ cuối cùng. Trong lần chạy hiện tại, hệ thống ghi nhận 735.638 dòng đầu vào, 495 mã cổ phiếu hợp lệ trong tập tham chiếu, và đã khôi phục được 79.896 ô dữ liệu số bị bỏ.

Sau khi lọc `symbol/date` hợp lệ, còn 730.546 dòng dirty hợp lệ về mặt khóa. Sau khi loại trùng theo `symbol + date`, còn 723.051 khóa duy nhất. Hệ thống cũng giữ lại 6.544 khóa mới không có trong file tham chiếu, nhằm hỗ trợ dữ liệu cập nhật mới theo ngày. Ở bước kiểm tra cuối, không còn dòng thiếu numeric, không còn volume âm, không còn khóa trùng; chỉ còn 21 dòng giá không dương và 4.409 dòng lỗi OHLC bị loại bỏ ở vòng cuối.

Kết quả cuối cùng thu được 718.621 dòng sạch trong file `Data_500_stocks_clean_ver2.csv`. So với dữ liệu dirty ban đầu, hệ thống đã loại bỏ 17.017 dòng không đạt yêu cầu. So với file tham chiếu gốc, số dòng thiếu là 2.856, tuy nhiên con số này có thể thay đổi theo từng lần chạy vì dữ liệu dirty liên tục được merge thêm từ dữ liệu cào hằng ngày.

#	symbol	date	open	high	low	close	volume
1	AGP	2026-06-08 07:00:00	34.2	35	34	34	2100
2	ACC	2026-06-08 07:00:00	12.55	12.55	12.05	12.5	6900
3	BBH	2026-06-08 07:00:00	10.8	10.8	10.8	10.8	100
4	BCA	2026-06-08 07:00:00	19.1	19.1	17.9	18.9	9400
5	BAF	2026-06-08 07:00:00	34.3	34.55	34.15	34.55	1541900
6	BCM	2026-06-08 07:00:00	53.3	54.2	53	53	331400
7	BCP	2026-06-08 07:00:00	9.3	9.3	9.3	9.3	1100
8	BAB	2026-06-08 07:00:00	11.2	11.2	11.2	11.2	800
9	ACB	2026-06-08 07:00:00	25.7	26	25.15	25.25	27681100
10	AGX	2026-06-08 07:00:00	245.8	245.8	209	209	2000
11	AFX	2026-06-08 07:00:00	10.3	10.35	10	10.3	50600
12	BDW	2026-06-08 07:00:00	27	27	27	27	100
13	ACL	2026-06-08 07:00:00	12.5	12.55	12.3	12.5	1400
14	AVG	2026-06-08 07:00:00	9.2	9.2	9	9.2	12700
15	ABR	2026-06-08 07:00:00	12.15	12.15	12.15	12.15	700
16	ASM	2026-06-08 07:00:00	5.82	5.85	5.75	5.75	289400
17	BHN	2026-06-08 07:00:00	29.8	29.8	29.8	29.8	400
18	APP	2026-06-08 07:00:00	4.4	4.4	4.2	4.2	800
19	BHP	2026-06-08 07:00:00	6.1	6.1	6.1	6.1	100
20	APG	2026-06-08 07:00:00	4.39	4.39	4.25	4.25	296400
21	BLI	2026-06-08 07:00:00	8.4	8.4	8.1	8.1	1500
22	ABT	2026-06-08 07:00:00	55.3	55.3	53.7	53.8	21700

719,246 rows

Toàn bộ log sau làm sạch được lưu tại data/clean_log, gồm clean_summary.txt, removed_invalid_symbol.csv, dirty_missing_numeric.csv, dirty_invalid_ohlc.csv, dirty_negative_volume.csv, dirty_duplicate_symbol_date.csv, final_removed_invalid_ohlc.csv,... Các log này giúp kiểm tra lại từng nhóm lỗi và chứng minh rằng dữ liệu đầu ra đã đạt chất lượng tốt hơn trước khi được nạp vào ClickHouse và sử dụng cho feature engineering, data mart và huấn luyện mô hình.

6.2 Đánh giá Data Warehouse

6.2.1 Đánh giá khả năng lưu trữ

Data Warehouse được triển khai trên ClickHouse.

Các bảng chính bao gồm:

- stock_prices
- stock_symbols
- symbol_sector_encoding
- features_all

Hệ thống hiện lưu trữ:

- Khoảng 500 mã cổ phiếu.
- Dữ liệu từ năm 2015 đến năm 2026.
- Hàng triệu bản ghi giao dịch.

Data Warehouse đáp ứng tốt nhu cầu lưu trữ dữ liệu lịch sử.

6.2.2 Đánh giá khả năng truy vấn

ClickHouse sử dụng cơ chế lưu trữ dạng cột giúp:

- Truy vấn tổng hợp nhanh.
- Truy vấn theo thời gian hiệu quả.
- Hỗ trợ dashboard và mart.

có thể thực hiện nhanh trên tập dữ liệu lớn.

CHƯƠNG 7: HẠN CHẾ, HƯỚNG CẢI TIẾN VÀ KẾT LUẬN

7.1. Hạn chế

7.1.1 Quá trình thu thập dữ liệu còn mất nhiều thời gian và chưa ổn định

Việc cào dữ liệu chứng khoán từ nguồn bên ngoài thường mất khá nhiều thời gian. Trong một số trường hợp, hệ thống gặp giới hạn truy cập, rate limit, khiến quá trình thu thập dữ liệu không thành công dù thời gian chờ có thể kéo dài gần 2 tiếng. Điều này ảnh hưởng đến tính ổn định của pipeline dữ liệu.

7.1.2 Dung lượng dữ liệu lớn gây tốn tài nguyên xử lý

Dataset của dự án có số lượng dòng và cột lớn do bao gồm dữ liệu giá, khối lượng giao dịch và nhiều feature kỹ thuật. Việc lưu trữ, truy vấn, tiền xử lý và huấn luyện mô hình trên tập dữ liệu này tiêu tốn nhiều bộ nhớ, đồng thời làm cho mỗi thao tác xử lý mất nhiều thời gian hơn.

7.1.3 Pipeline tự động hàng ngày còn phụ thuộc vào kết nối và cấu hình hệ thống

Việc chạy tự động hằng ngày có thể phát sinh lỗi nếu không được theo dõi thường xuyên. Một số lỗi liên quan đến kết nối ClickHouse, xác thực tài khoản hoặc thay đổi mật khẩu có thể khiến pipeline không chạy thành công. Nếu không xử lý kịp thời, hệ thống có thể bỏ lỡ dữ liệu của một ngày giao dịch.

7.1.4 Bản chất thị trường chứng khoán khó dự đoán chính xác tuyệt đối

Dữ liệu chứng khoán chịu ảnh hưởng bởi nhiều yếu tố như tâm lý thị trường, tin tức, chính sách kinh tế và các biến động bất thường. Vì vậy, các mô hình dự đoán khó đạt độ chính xác tuyệt đối. Việc tối ưu mô hình cũng trở nên phức tạp hơn do tín hiệu trong dữ liệu có nhiều nhiễu và không ổn định theo thời gian.

7.1.5 Chất lượng dữ liệu đầu vào cần được kiểm tra thường xuyên

Dữ liệu thu thập có thể tồn tại giá trị thiếu, dữ liệu trùng lặp, sai định dạng ngày hoặc bất thường trong các cột giá và khối lượng. Do đó, hệ thống cần có bước làm sạch và kiểm tra chất lượng dữ liệu trước khi đưa vào feature engineering và huấn luyện mô hình.

7.1.6 Mô hình chủ yếu dựa trên dữ liệu lịch sử và feature kỹ thuật

Các mô hình hiện tại chủ yếu sử dụng dữ liệu OHLCV và các chỉ báo kỹ thuật. Dự án chưa tích hợp đầy đủ các nguồn dữ liệu bên ngoài như tin tức, báo cáo tài chính, dữ liệu vĩ mô hoặc tâm lý thị trường, nên khả năng phản ánh các sự kiện bất ngờ còn hạn chế.

7.1.7 Chi phí tính toán tăng khi mở rộng số lượng mô hình

Khi hệ thống có nhiều mô hình chạy song song, thời gian huấn luyện, dự đoán, đánh giá và lưu kết quả tăng lên đáng kể. Điều này đòi hỏi tối ưu tốt hơn về tài nguyên, lịch chạy và cách lưu trữ dữ liệu trung gian.

7.2. Hướng cải tiến

7.2.1 Mở rộng quy mô dữ liệu lịch sử

Trong tương lai, dự án có thể tiếp tục mở rộng dữ liệu về các giai đoạn trước năm 2015 để tăng số lượng bản ghi và giúp mô hình có thêm nhiều góc nhìn lịch sử. Việc có dữ liệu dài hơn sẽ hỗ trợ phân tích các chu kỳ thị trường, các giai đoạn tăng giảm mạnh và cải thiện khả năng tổng quát của mô hình.

7.2.3 Nâng cao chất lượng các mô hình dự đoán

Các mô hình hiện tại có thể tiếp tục được tối ưu về feature, tham số và phương pháp đánh giá. Ngoài các thuật toán machine learning truyền thống, dự án có thể thử nghiệm thêm các mô hình deep learning như LSTM, GRU hoặc Transformer cho dữ liệu chuỗi thời gian. Những mô hình này có khả năng khai thác tốt hơn mối quan hệ theo thời gian trong dữ liệu chứng khoán.

7.2.3 Bổ sung chatbot hỗ trợ tra cứu thông tin

Dự án có thể phát triển thêm một chatbot mini để hỗ trợ người dùng tra cứu các thông tin cơ bản về cổ phiếu, dữ liệu thị trường, kết quả dự đoán và các chức năng trong hệ thống. Chatbot này có thể giúp người dùng tương tác với hệ thống dễ dàng hơn thay vì phải tự tìm kiếm trên dashboard.

7.2.4 Triển khai hệ thống thành một website hoàn chỉnh

Nếu có đủ nguồn lực, dự án có thể được deploy thành một web app hoàn chỉnh, cho phép người dùng truy cập trực tiếp qua trình duyệt. Website có thể tích hợp dashboard, tra cứu dữ liệu, xem kết quả mô hình, insight thị trường và cảnh báo rủi ro trong cùng một giao diện.

7.2.5 Tối ưu pipeline dữ liệu tự động

Cần cải thiện pipeline tự động hằng ngày để giảm lỗi trong quá trình cào dữ liệu, xử lý dữ liệu và upload lên ClickHouse. Có thể bổ sung cơ chế retry, log chi tiết, cảnh báo qua Telegram/email và kiểm tra dữ liệu sau mỗi lần chạy để đảm bảo hệ thống hoạt động ổn định hơn.

7.2.6 Bổ sung thêm nguồn dữ liệu bên ngoài

Ngoài dữ liệu giá và khối lượng giao dịch, dự án có thể tích hợp thêm dữ liệu tin tức, báo cáo tài chính, chỉ số vĩ mô, lãi suất, tỷ giá hoặc dữ liệu sentiment từ mạng xã hội. Các nguồn dữ liệu này có thể giúp mô hình phản ánh tốt hơn các yếu tố ảnh hưởng đến biến động giá cổ phiếu.

7.2.7 Xây dựng hệ thống đánh giá và so sánh mô hình

Dự án có thể bổ sung một module chuyên theo dõi hiệu quả của từng mô hình theo thời gian. Module này sẽ so sánh các chỉ số như accuracy, MAE, RMSE, return backtest, drawdown và tỷ lệ dự đoán đúng để lựa chọn mô hình phù hợp nhất cho từng bài toán.

7.2.8 Tối ưu lưu trữ và truy vấn dữ liệu lớn

Khi dữ liệu ngày càng tăng, cần tối ưu cấu trúc bảng, partition, index, data mart và các truy vấn ClickHouse để giảm thời gian xử lý. Điều này giúp dashboard phản hồi nhanh hơn và giảm tải bộ nhớ khi huấn luyện mô hình.

7.3. Kết luận

Dự án đã xây dựng được một hệ thống quản lý, xử lý và phân tích dữ liệu chứng khoán tương đối hoàn chỉnh, bao gồm các bước từ thu thập dữ liệu, làm sạch dữ liệu, lưu trữ vào ClickHouse, xây dựng feature, huấn luyện mô hình dự đoán, tạo data mart và trực quan hóa kết quả trên giao diện web. Thông qua dự án, nhóm đã hiểu rõ hơn về quy trình xây dựng một hệ thống dữ liệu theo hướng thực tế, trong đó dữ liệu không chỉ được lưu trữ mà còn được khai thác để phục vụ phân tích và hỗ trợ ra quyết định.

Bên cạnh phần quản lý cơ sở dữ liệu, dự án cũng đã tích hợp nhiều mô hình dự đoán với các mục tiêu khác nhau như dự đoán giá, dự đoán lợi suất, phân loại tín hiệu mua/giữ/bán và cảnh báo rủi ro. Các kết quả này được tổ chức lại thành các bảng data mart, giúp việc truy vấn, báo cáo và hiển thị trên dashboard trở nên thuận tiện hơn. Điều này cho thấy vai trò quan trọng của cơ sở dữ liệu trong việc kết nối giữa dữ liệu thô, mô hình học máy và ứng dụng người dùng cuối.

Tuy vẫn còn một số hạn chế như dữ liệu lớn gây tốn tài nguyên, quá trình thu thập dữ liệu chưa hoàn toàn ổn định và việc dự đoán thị trường chứng khoán luôn tồn tại nhiều sai số, dự án vẫn đạt được mục tiêu chính là xây dựng một pipeline dữ liệu chứng khoán có khả năng tự động hóa, phân tích và mở rộng. Trong tương lai, hệ thống có thể tiếp tục được cải thiện bằng cách mở rộng nguồn dữ liệu, tối ưu pipeline, nâng cấp mô hình dự đoán và triển khai thành một ứng dụng web hoàn chỉnh hơn.

Nhìn chung, dự án là nền tảng tốt để nhóm tiếp tục phát triển các chức năng phân tích chứng khoán chuyên sâu hơn, đồng thời cũng là cơ hội để áp dụng kiến thức về cơ sở dữ liệu, xử lý dữ liệu lớn, machine learning và trực quan hóa dữ liệu vào một bài toán thực tế.

TÀI LIỆU THAM KHẢO

- [1] [Vnstock Documentation](#). Trung tâm tài liệu chính thức của thư viện Vnstock, cung cấp hướng dẫn khai thác dữ liệu chứng khoán Việt Nam bằng Python.
- [2] [Vnstock Official Website](#). Nền tảng mã nguồn mở hỗ trợ truy cập, chuẩn hóa và xử lý dữ liệu tài chính, chứng khoán Việt Nam.
- [3] [PostgreSQL Documentation](#). Tài liệu chính thức về hệ quản trị cơ sở dữ liệu PostgreSQL, được sử dụng trong thiết kế cơ sở dữ liệu, truy vấn SQL và quản lý dữ liệu.
- [4] [Apache Airflow ETL/ELT Documentation](#). Tài liệu về xây dựng và điều phối quy trình ETL/ELT trong hệ thống dữ liệu hiện đại.
- [5] [Apache Airflow Documentation](#). Hướng dẫn xây dựng và quản lý workflow dữ liệu tự động bằng Airflow.
- [6] Fundamentals of Data Engineering. O'Reilly Media, 2022. Tài liệu nền tảng về kiến trúc dữ liệu, pipeline, ETL, Data Warehouse và Data Lake.
- [7] The Data Warehouse Toolkit. Wiley, 3rd Edition. Tài liệu kinh điển về mô hình hóa dữ liệu, Data Warehouse và Data Mart.
- [8] Data Pipelines Pocket Reference. O'Reilly Media, 2021. Hướng dẫn thiết kế và triển khai hệ thống pipeline dữ liệu.
- [9] Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media. Tài liệu tham khảo cho việc xây dựng mô hình dự đoán dữ liệu chứng khoán.
- [10] [Scikit-learn Documentation](#). Thư viện học máy được sử dụng để huấn luyện và đánh giá các mô hình dự đoán.
- [11] [Pandas Documentation](#). Tài liệu về xử lý và phân tích dữ liệu dạng bảng trong Python.
- [12] [Matplotlib Documentation](#). Tài liệu về trực quan hóa dữ liệu và xây dựng biểu đồ phân tích.
- [13] [Plotly Documentation](#). Thư viện trực quan hóa dữ liệu tương tác phục vụ dashboard và báo cáo phân tích.
- [14] Database System Concepts. McGraw-Hill. Giáo trình nền tảng về hệ quản trị cơ sở dữ liệu, mô hình dữ liệu và tối ưu truy vấn.
- [15] Designing Data-Intensive Applications. O'Reilly Media, 2017. Tài liệu chuyên sâu về thiết kế hệ thống dữ liệu quy mô lớn, tính nhất quán và xử lý dữ liệu.